Principios de la Robótica Autónoma

Modelos Probabilísticos de Sensores

Ignacio Mas

Sensores para robots móviles

- Sensores de contacto: Paragolpes
- Sensores propioceptivos
  - Acelerómetros (Masa sobre resorte)
  - Giróscopos (Masa girando, haz láser)
  - Brújulas, inclinómetros (campo magnético, gravedad)
- Sensores de proximidad
  - Sonar (tiempo de vuelo -tof)
  - Radar (Fase y frecuencia)
  - Lidars (Laser range-finders: triangulación, tof, fase)
  - Infrarrojo (intensidad)
- Sensores visuales: Cámaras
- Sensores basados en satélites: GPS

Sensores de proximidad

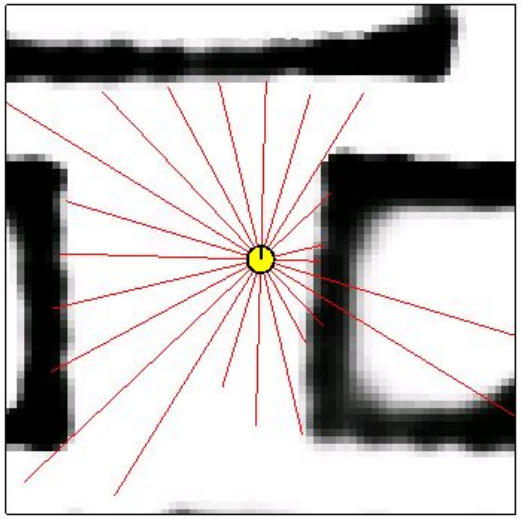

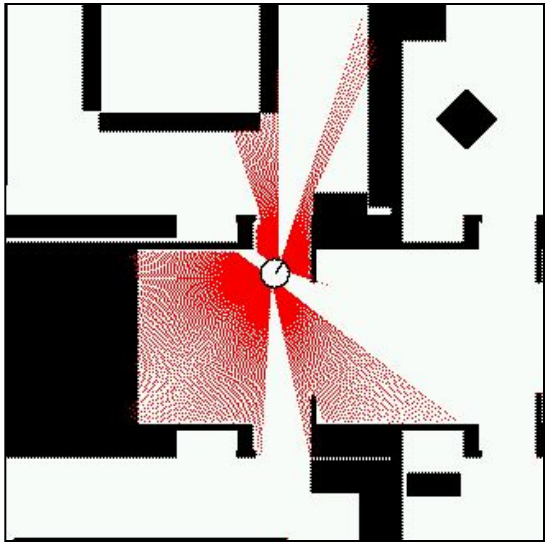

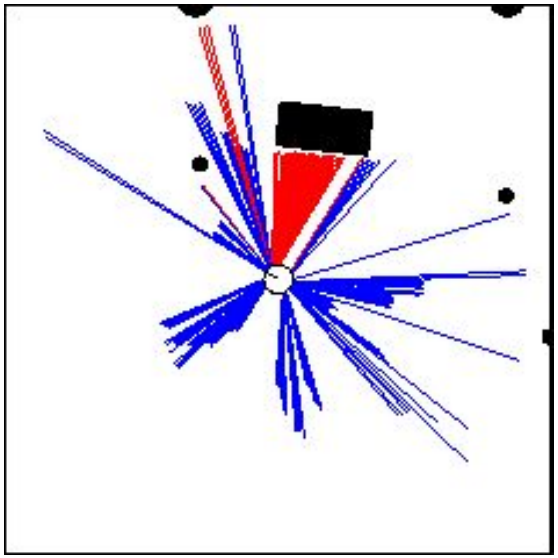

- La idea es determinar *P(z|x,m)*, i.e., la probabilidad de una medición *z* dado que el robot está en la posición *x*.

- **A resolver**: Cómo se puede calcular esa probabilidad?

- **Método**: Tratemos de explicar una medición.

Modelo de sensor basado en haz (beam-based)

- Un barrido *z* consiste de *K* mediciones.

$$z = \{z_1, z_2, \ldots, z_K\}$$

- Suposición: Las mediciones individuales son independientes dada la posición del robot.

$$P(z \mid x, m) = \prod_{k=1}^{K} P(z_k \mid x, m)$$

Modelo de sensor basado en haz (beam-based)

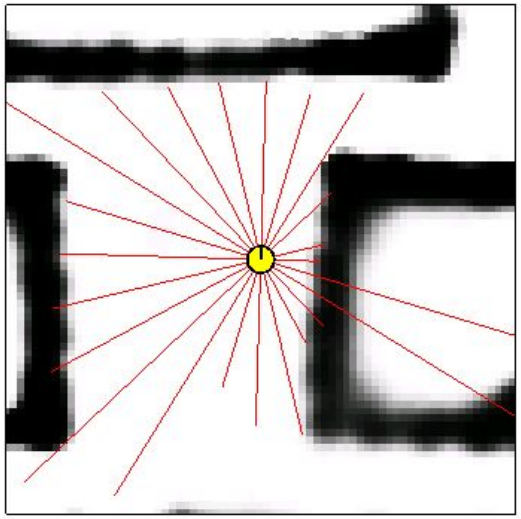

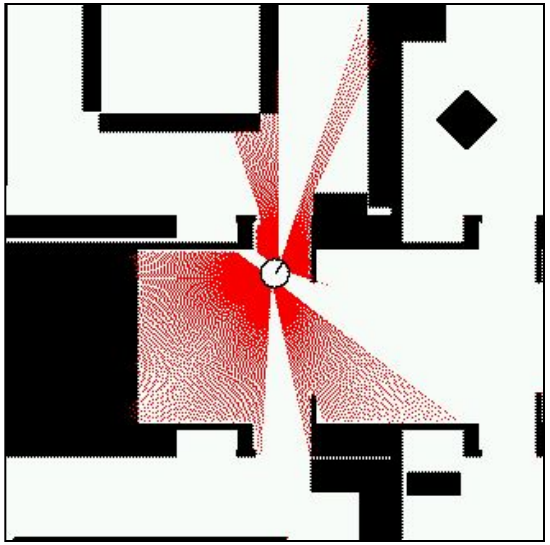

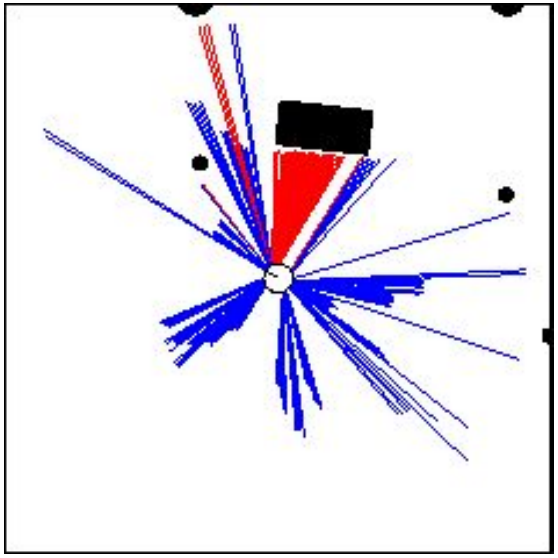

$$P(z \mid x, m) = \prod_{k=1}^{K} P(z_k \mid x, m)$$

A partir de (x, m) debe hacerse ray-casting para comparar con z

Errores de medición de distancia

1. Haz reflejado en obstáculos
2. Haz reflejado en personas o debido a crosstalk
3. Lectura aleatoria
4. Lectura de distancia máxima

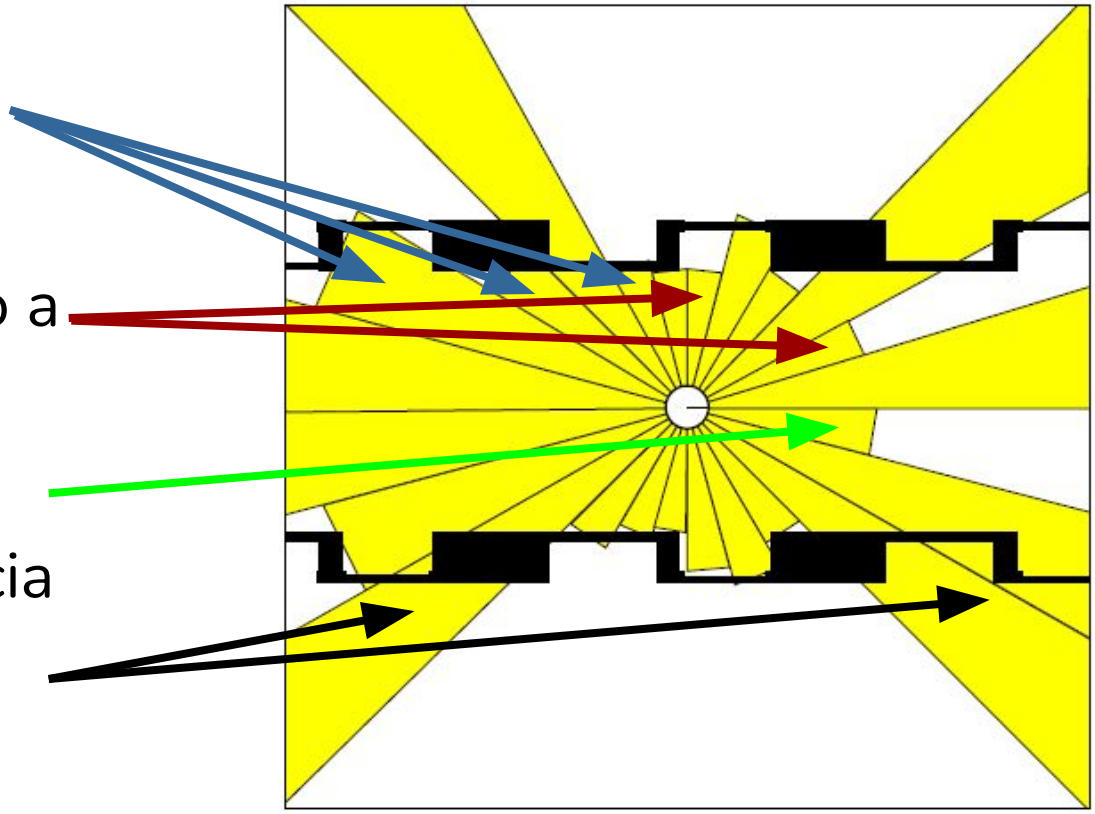

Medición de proximidad

- Una medición se debe a …
  - Un obstáculo conocido.
  - cross-talk.
  - Un obstáculo inesperado (gente, muebles, …).
  - No detección de obstáculos (reflejos, vidrio, …).

- El ruido se debe a incerteza …
  - En la distancia a un obstáculo conocido.
  - En la posición de un obstáculo conocido
  - En la posición de obstáculos adicionales
  - Si un obstáculo no es detectado

Modelo de proximidad basado en haz (beam-based)

Ruido de medición

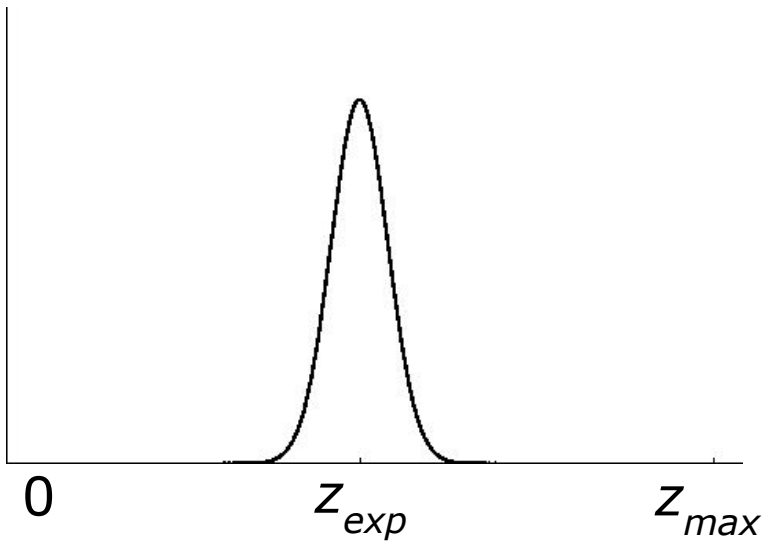

$$P_{hit}(z \mid x, m) = \eta \frac{1}{\sqrt{2\pi b}} e^{-\frac{1}{2}\frac{(z - z_{\exp})^2}{b}}$$

Obstáculos inesperados

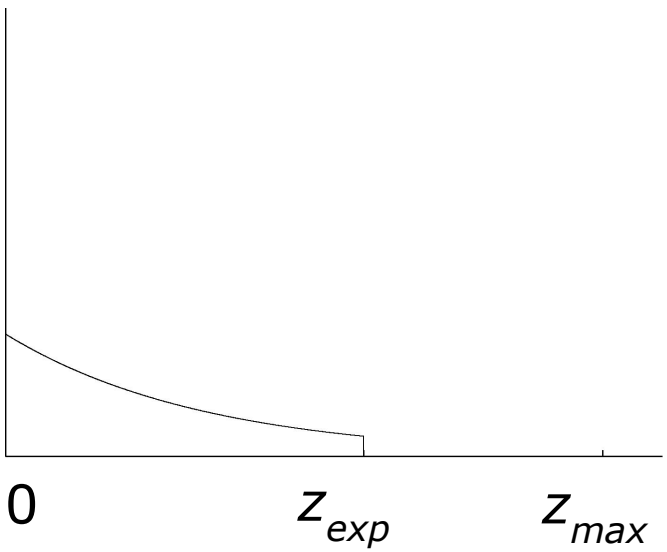

$$P_{\text{unexp}}(z \mid x, m) = \begin{cases} \eta\ \lambda\ \mathrm{e}^{-\lambda z} & z < z_{\exp} \\ 0 & otherwise \end{cases}$$

Modelo de proximidad basado en haz (beam-based)

Medición Aleatoria

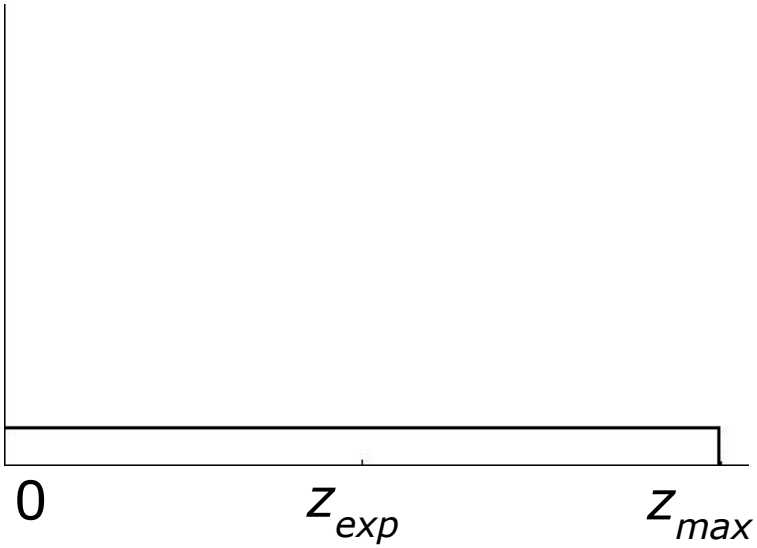

$$P_{rand}(z \mid x, m) = \eta \frac{1}{z_{\max}}$$

Rango máximo

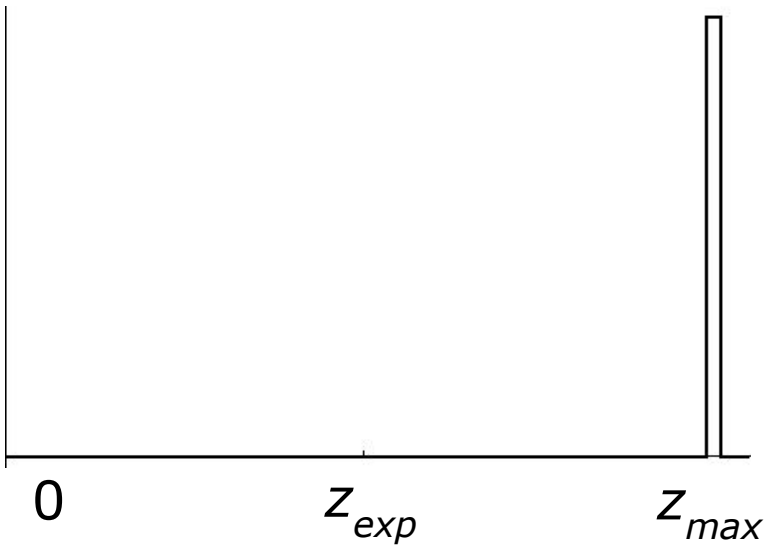

$$P_{\max}(z \mid x, m) = \eta \frac{1}{z_{small}}$$

Mezcla de densidades resultante

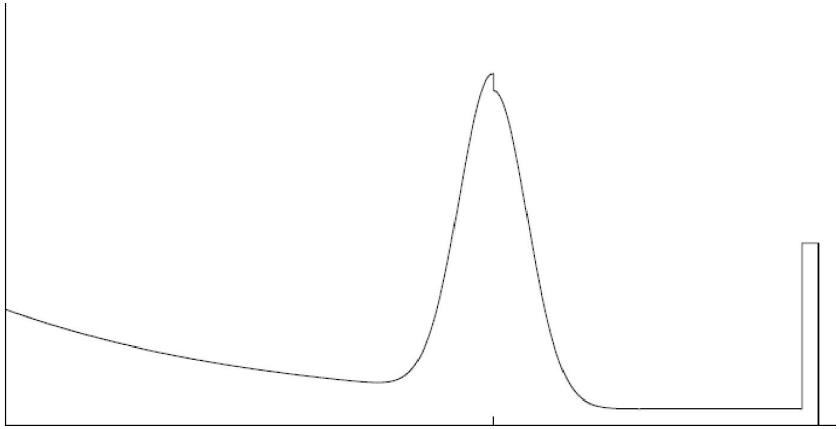

$$P(z \mid x, m) = \begin{pmatrix} \alpha_{\text{hit}} \\ \alpha_{\text{unexp}} \\ \alpha_{\text{max}} \\ \alpha_{\text{rand}} \end{pmatrix}^T \cdot \begin{pmatrix} P_{\text{hit}}(z \mid x, m) \\ P_{\text{unexp}}(z \mid x, m) \\ P_{\text{max}}(z \mid x, m) \\ P_{\text{rand}}(z \mid x, m) \end{pmatrix}$$

Cómo determinar los parámetros del modelo?

Datos crudos de un sensor

Distancias medidas para una distancia esperada de 300cm.

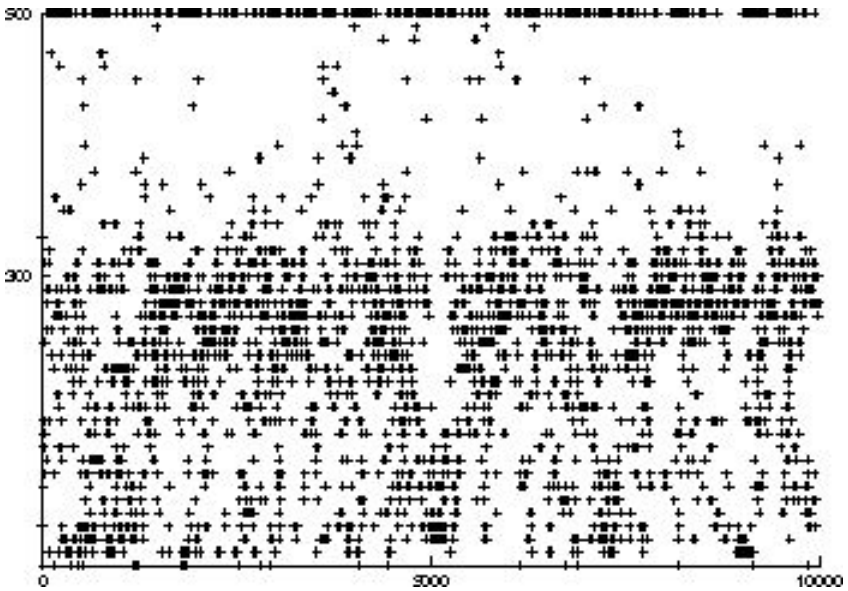

Sonar

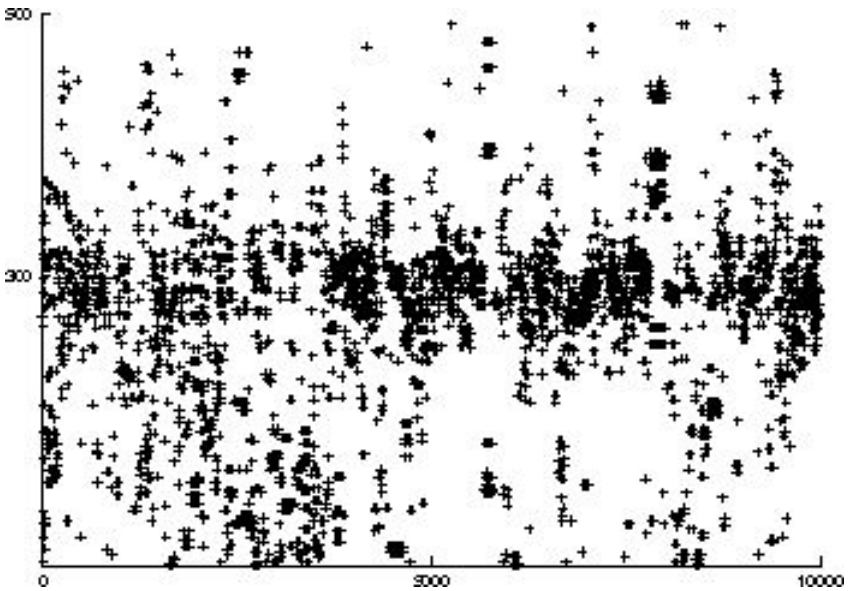

Lidar

Aproximación

- Maximizar el log de la verosimilitud de los datos

$$P(z \mid z_{\exp})$$

- Espacio de búsqueda de n-1 parámetros.
  - Hill climbing
  - Gradient descent
  - Algoritmos genéticos
  - …
- Calcular deterministicamente el n-ésimo parámetro para satisfacer la restricción de normalización

Aproximación - Resultados

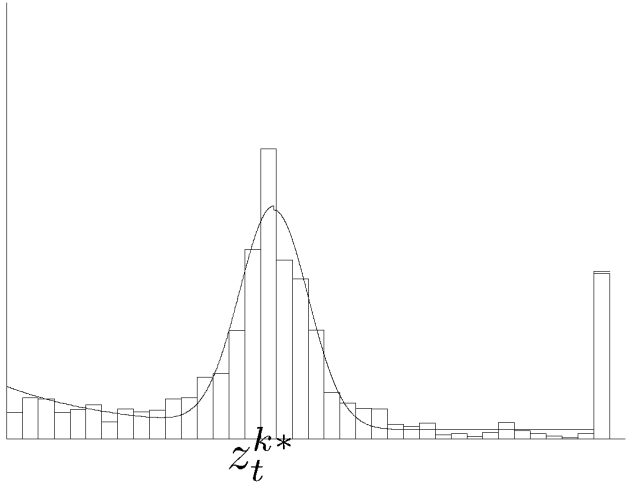

Laser

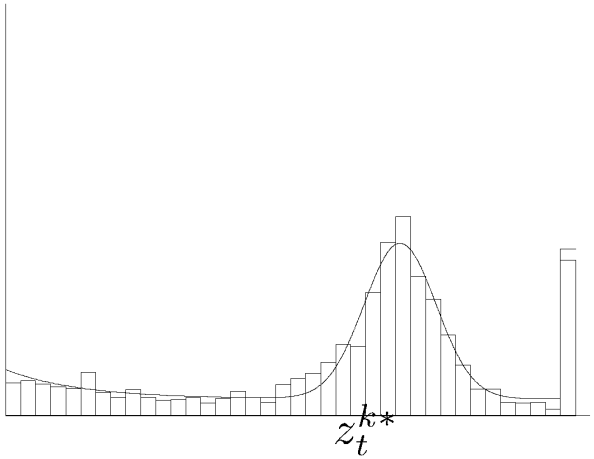

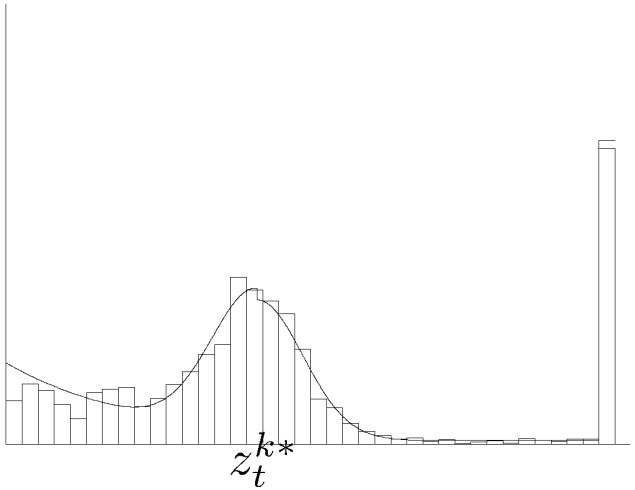

Sonar

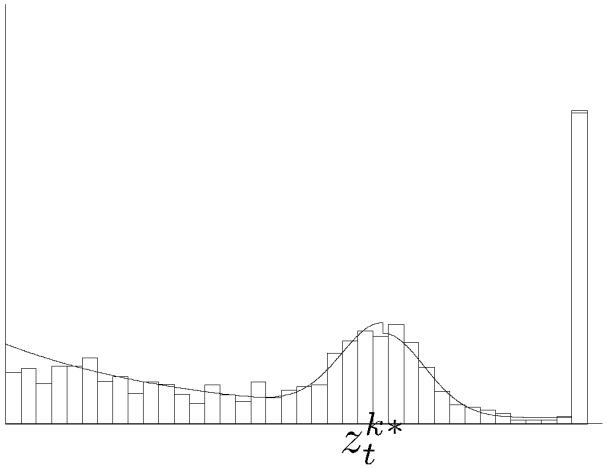

300cm

400cm

Ejemplo

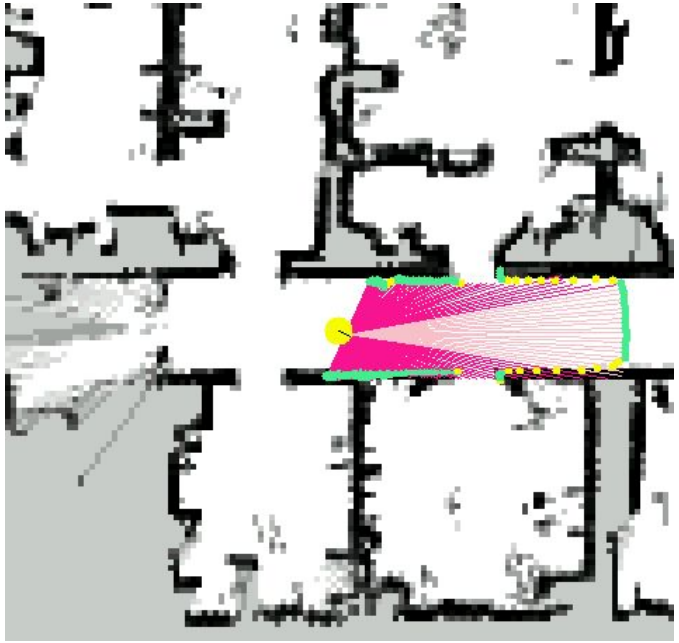

z

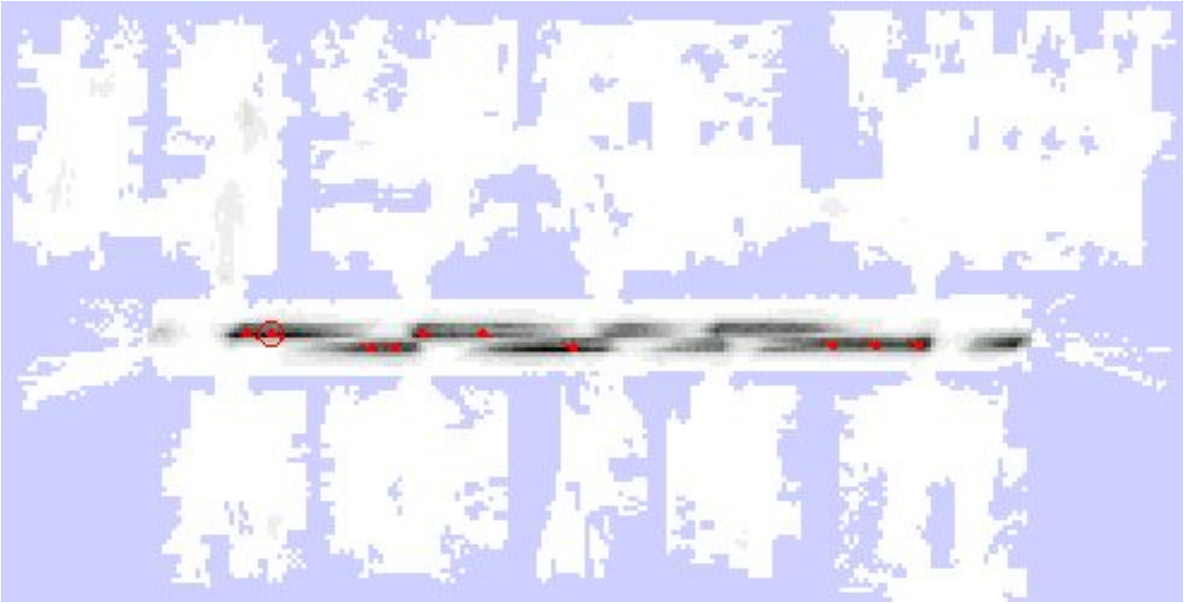

$P(z|x,m)$

Aproximación - Resultados

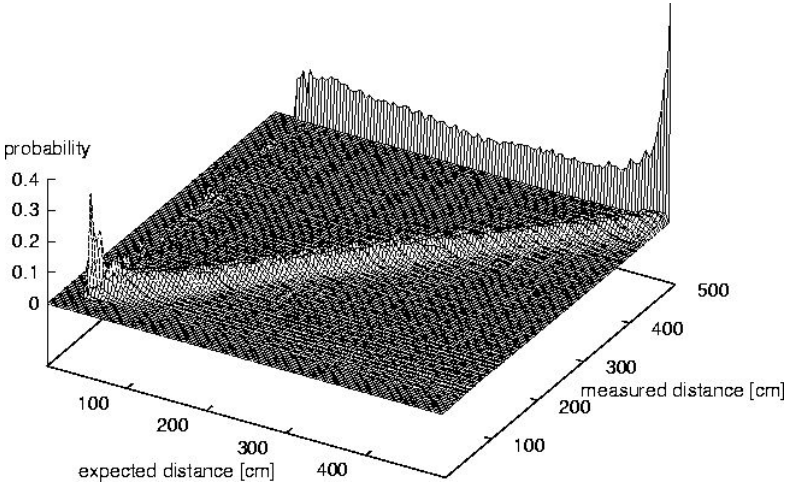

Laser

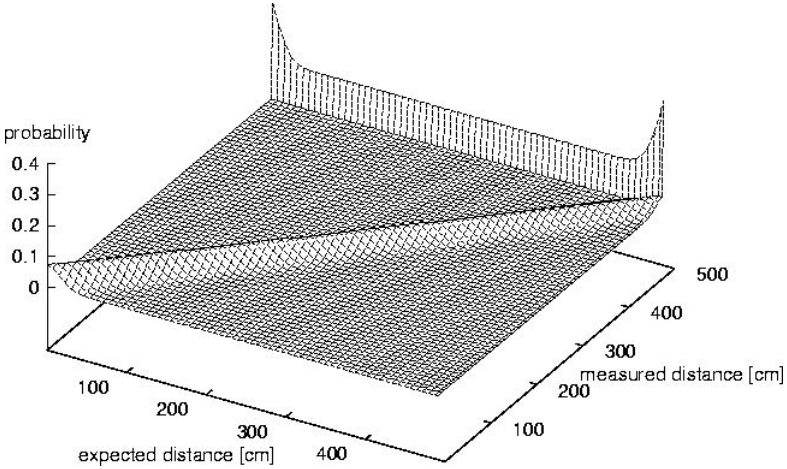

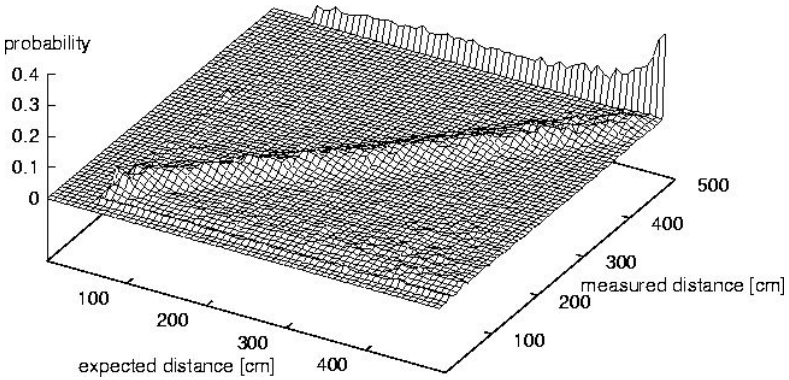

Sonar

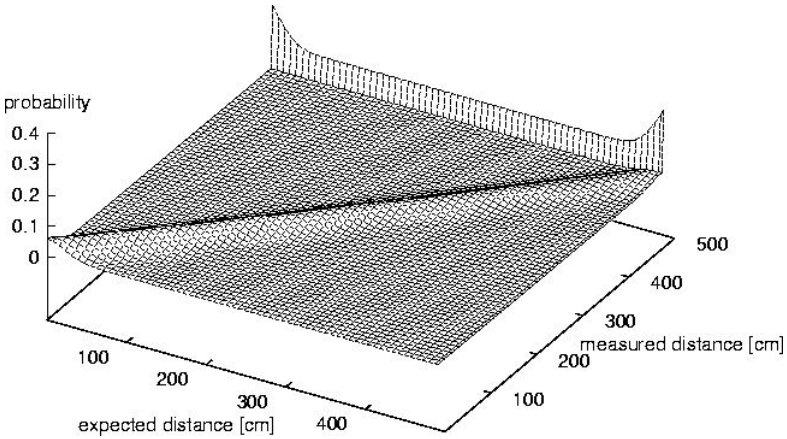

Influencia el ángulo al obstáculo

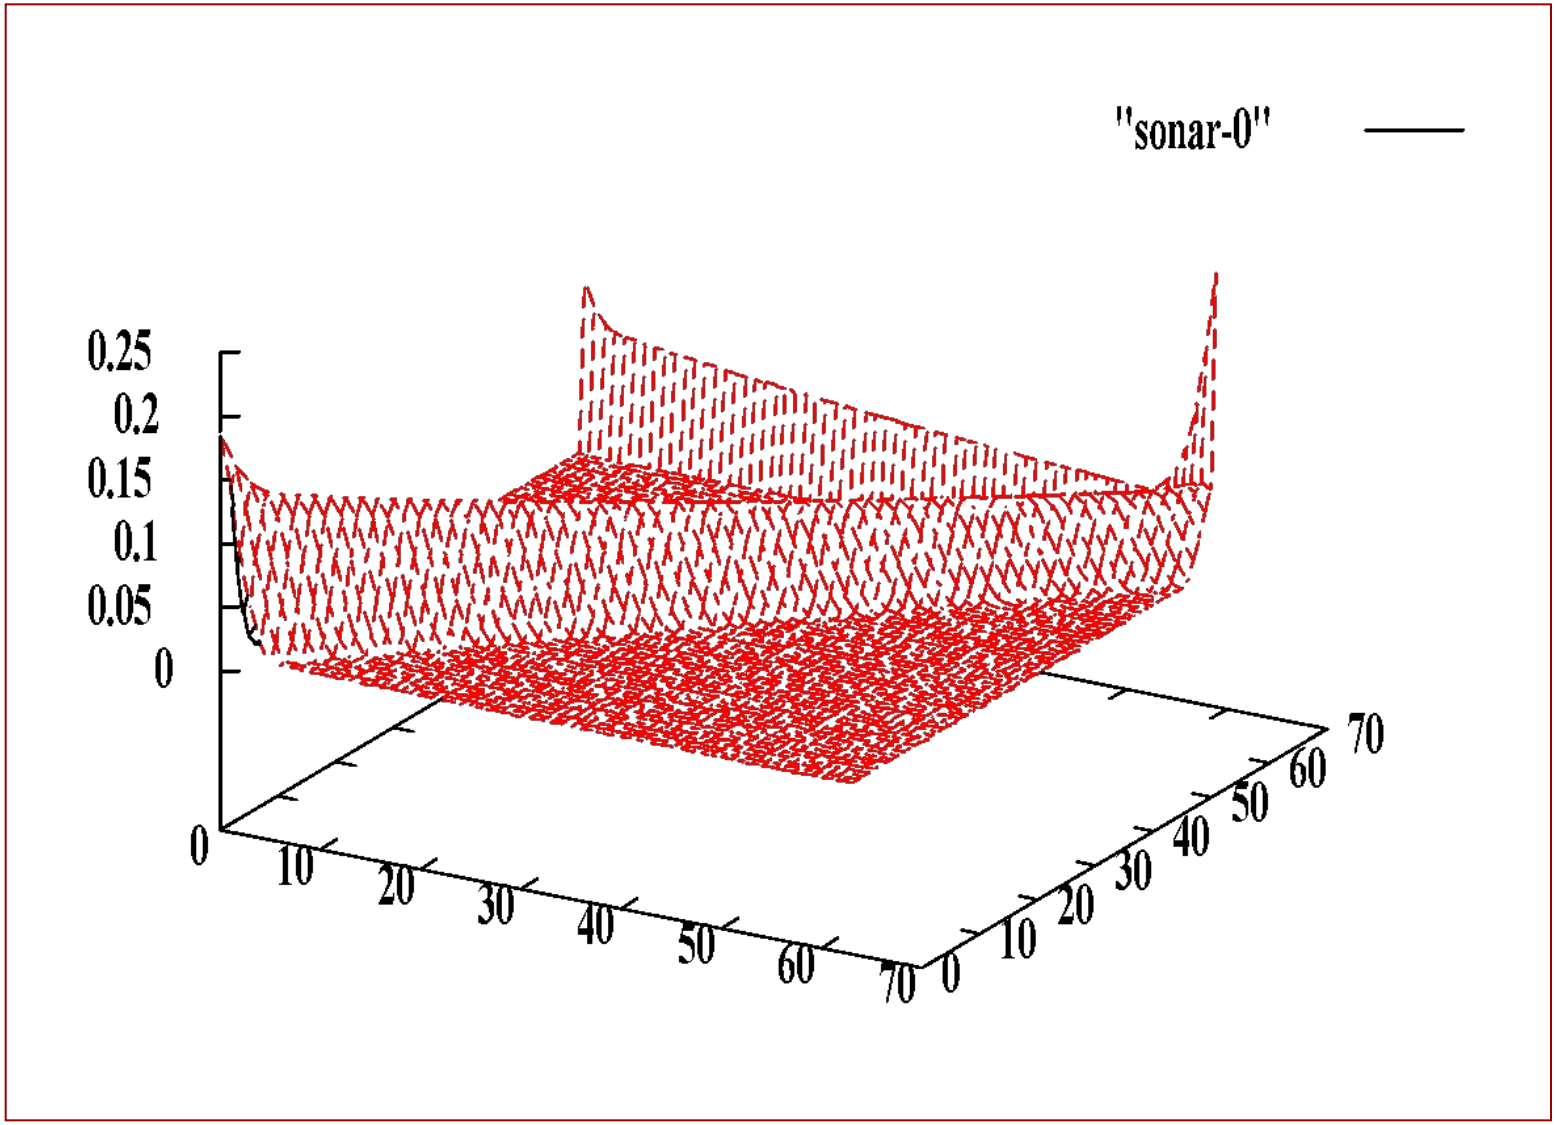

Influencia el ángulo al obstáculo

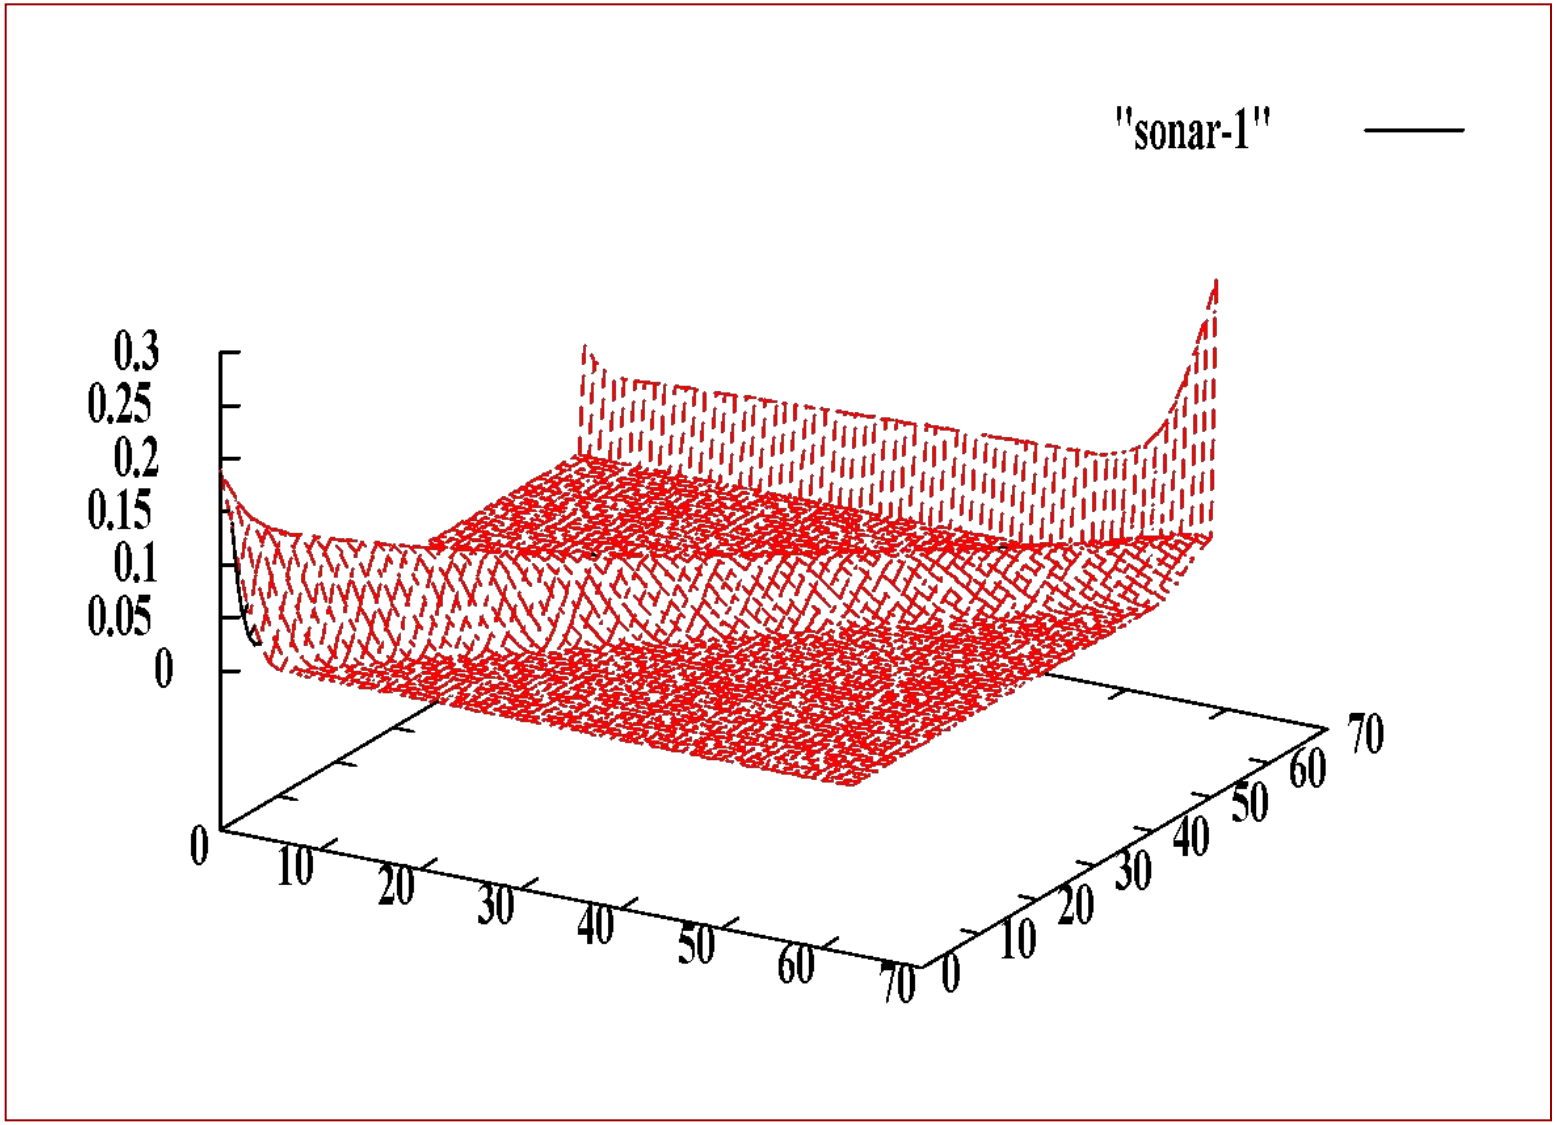

Influencia el ángulo al obstáculo

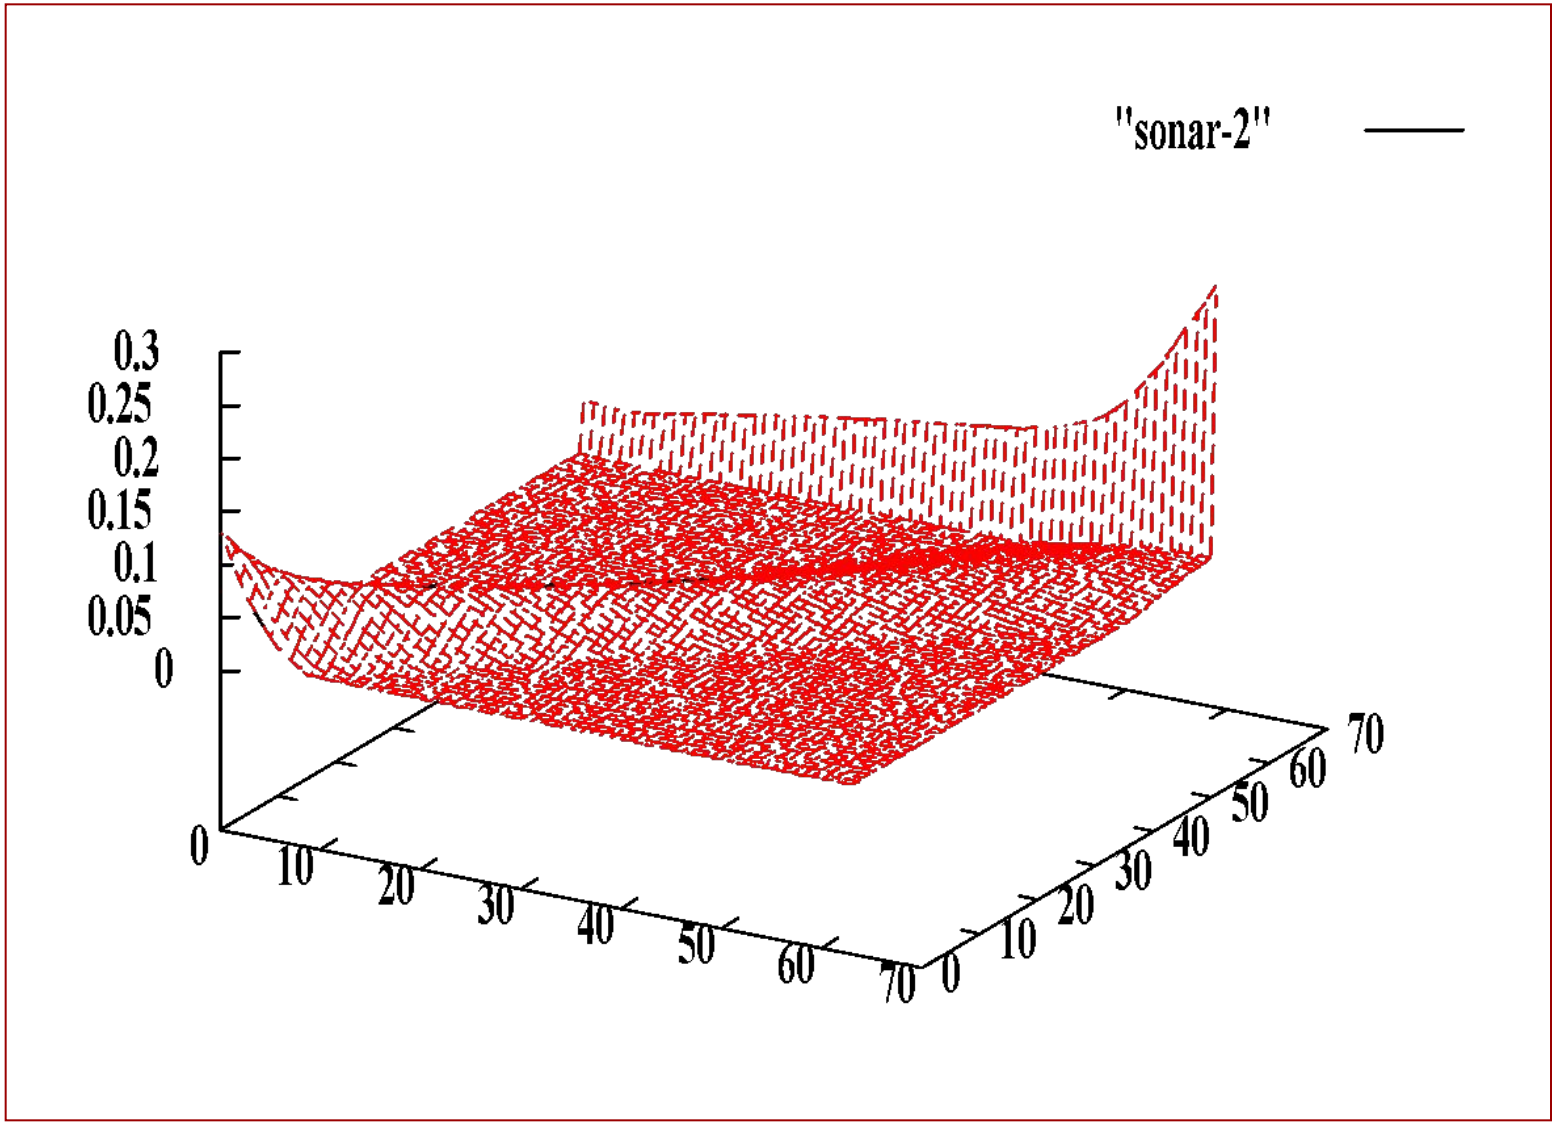

Influencia el ángulo al obstáculo

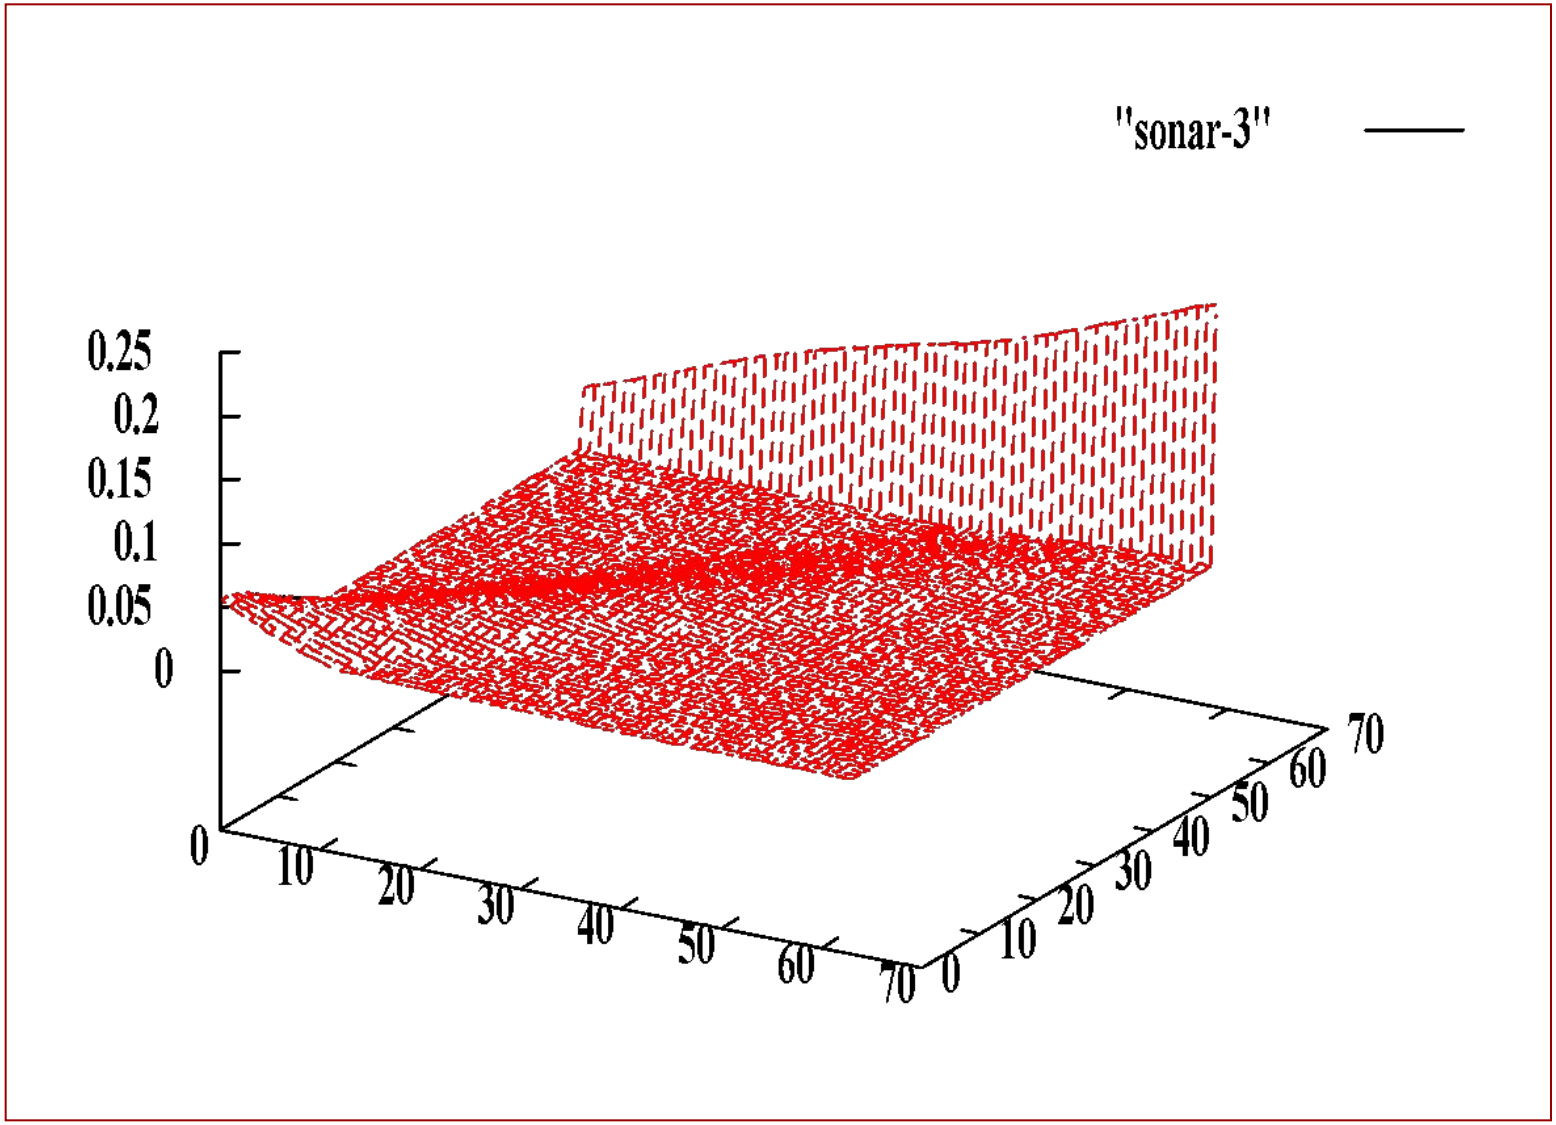

Resumen del modelo basado en haz (beam-based)

- Supone independencia entre haces.
  - ¿Justificación?
- Modela las causas físicas de las mediciones.
  - Mezcla de densidades de estas causas.
  - Supone independencia entre causas. ¿Esta bien eso?
- Implementación
  - Aprender parámetros basándose en datos reales.
  - Determinación de distancias esperadas haciendo ray-casting.
  - Diferentes modelos para diferentes ángulos en los que el haz detecta el obstáculo.
  - Las distancias esperadas pueden ser pre-procesadas

Modelo basado en campos de verosimilitud

- El modelo basado en haz es ...
  - Poco suave para pequeños obstáculos y en bordes.
  - Poco eficiente.

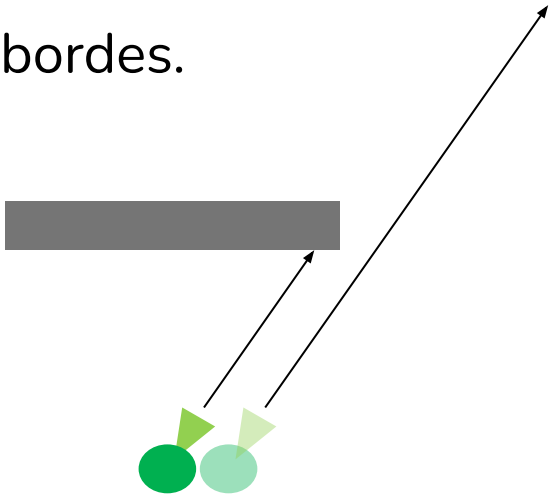

- Idea: En vez de mirar a lo largo del haz,
  chequear solo el punto final.

Modelo basado en campos de verosimilitud

- La probabilidad es una mezcla de …
  - Una distribución Gaussiana centrada en el obstáculo más cercano,
  - Una distribución uniforme por mediciones aleatorias y
  - Una distribución uniforme reducida para mediciones de rango máximo.

- De nuevo, se asume independencia entre los distintos componentes.

Ejemplo

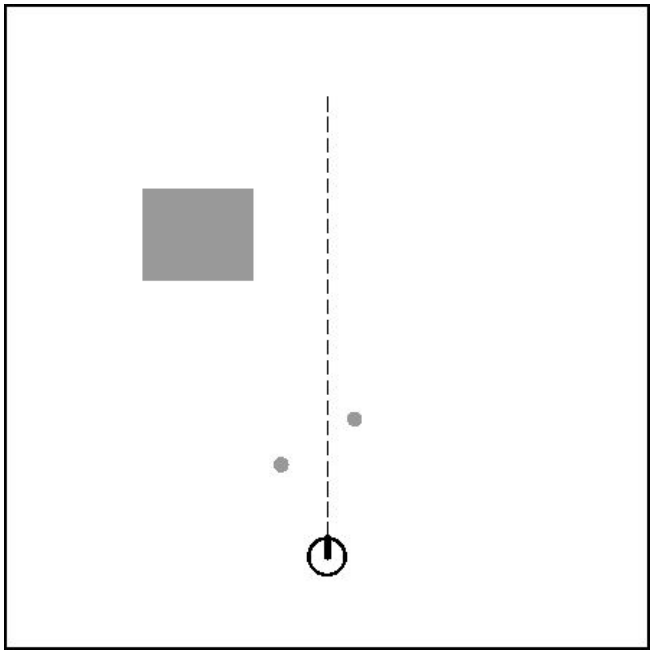

Mapa *m*

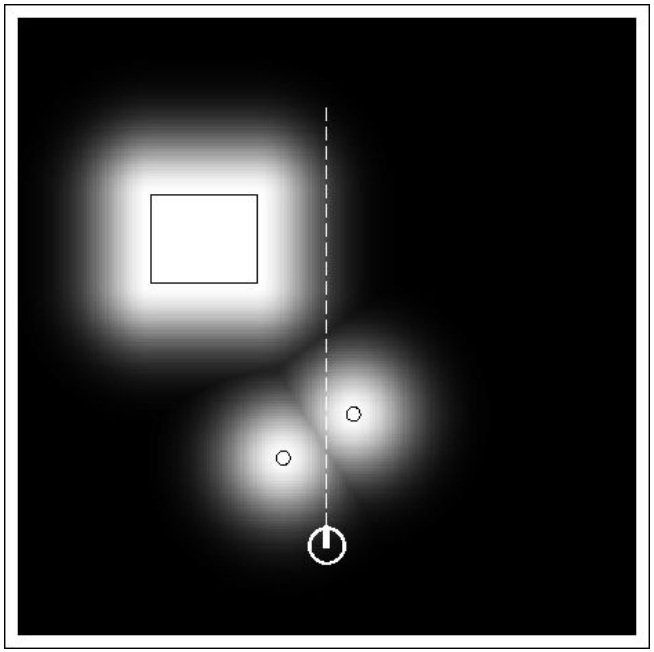

Campo de verosimilitud

(likelihood field)

P(z|x,m)

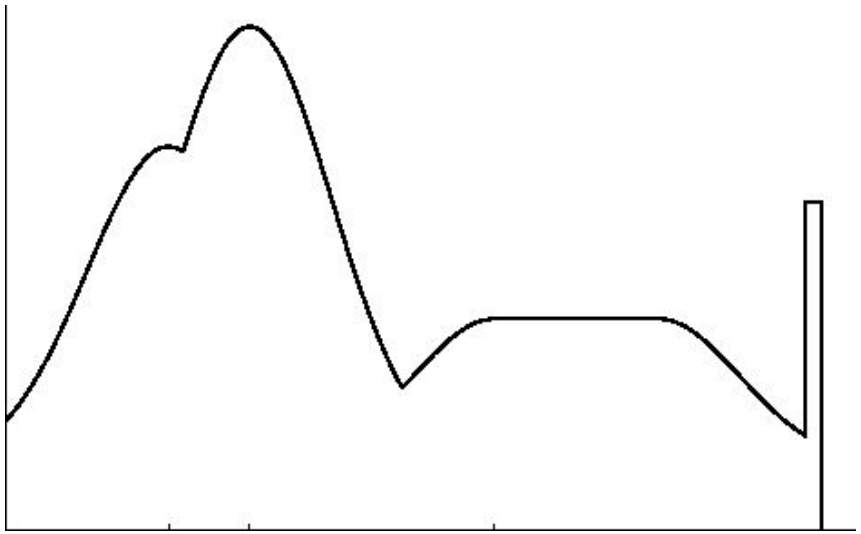

Museo Tecnológico de San José (CA, USA)

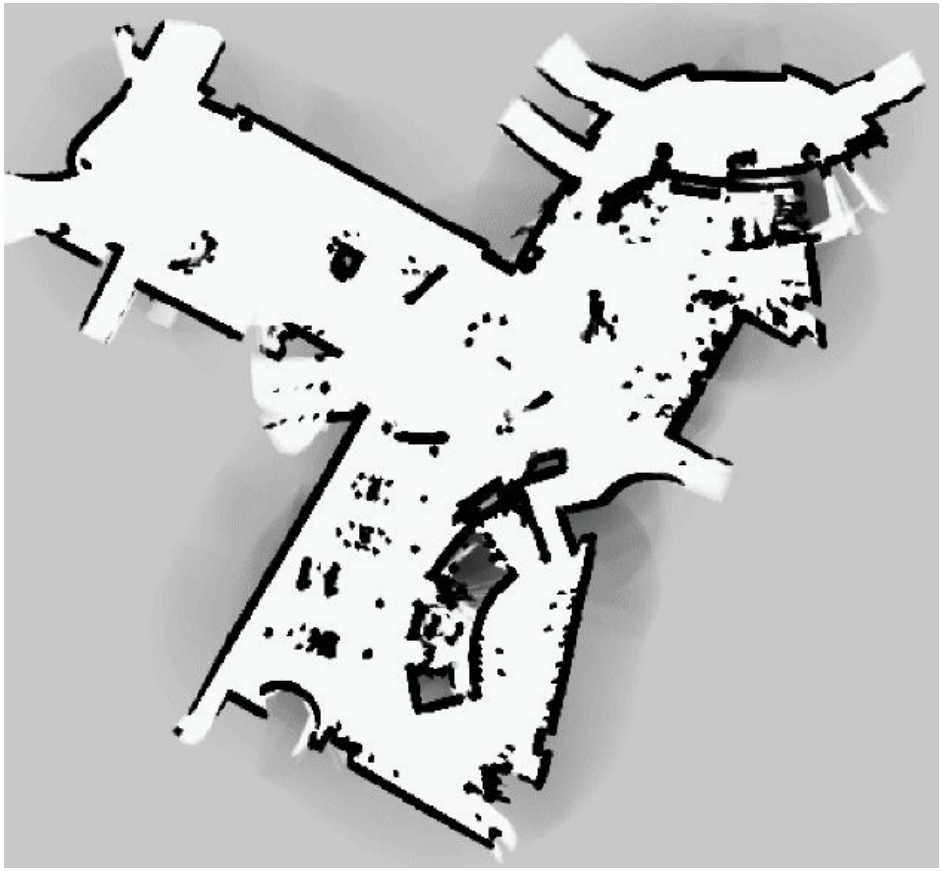

Mapa de grilla de ocupación

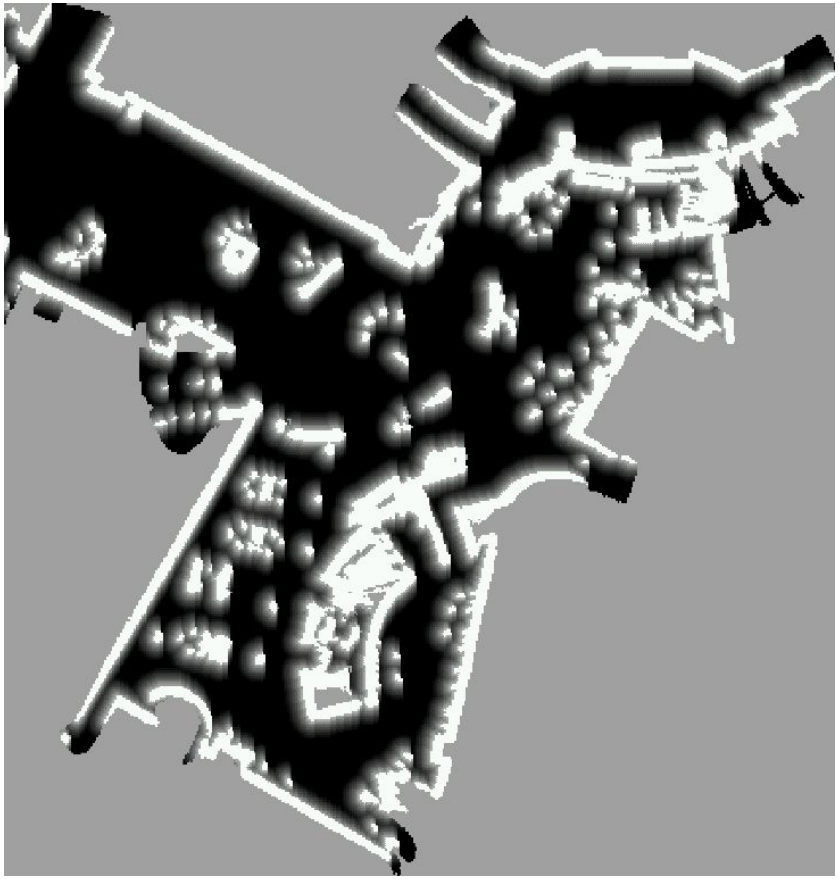

Campo de verosimilitud

Scan matching

- Extracción del campo de verosimilitud de un escaneo y comparación con otro escaneo previo

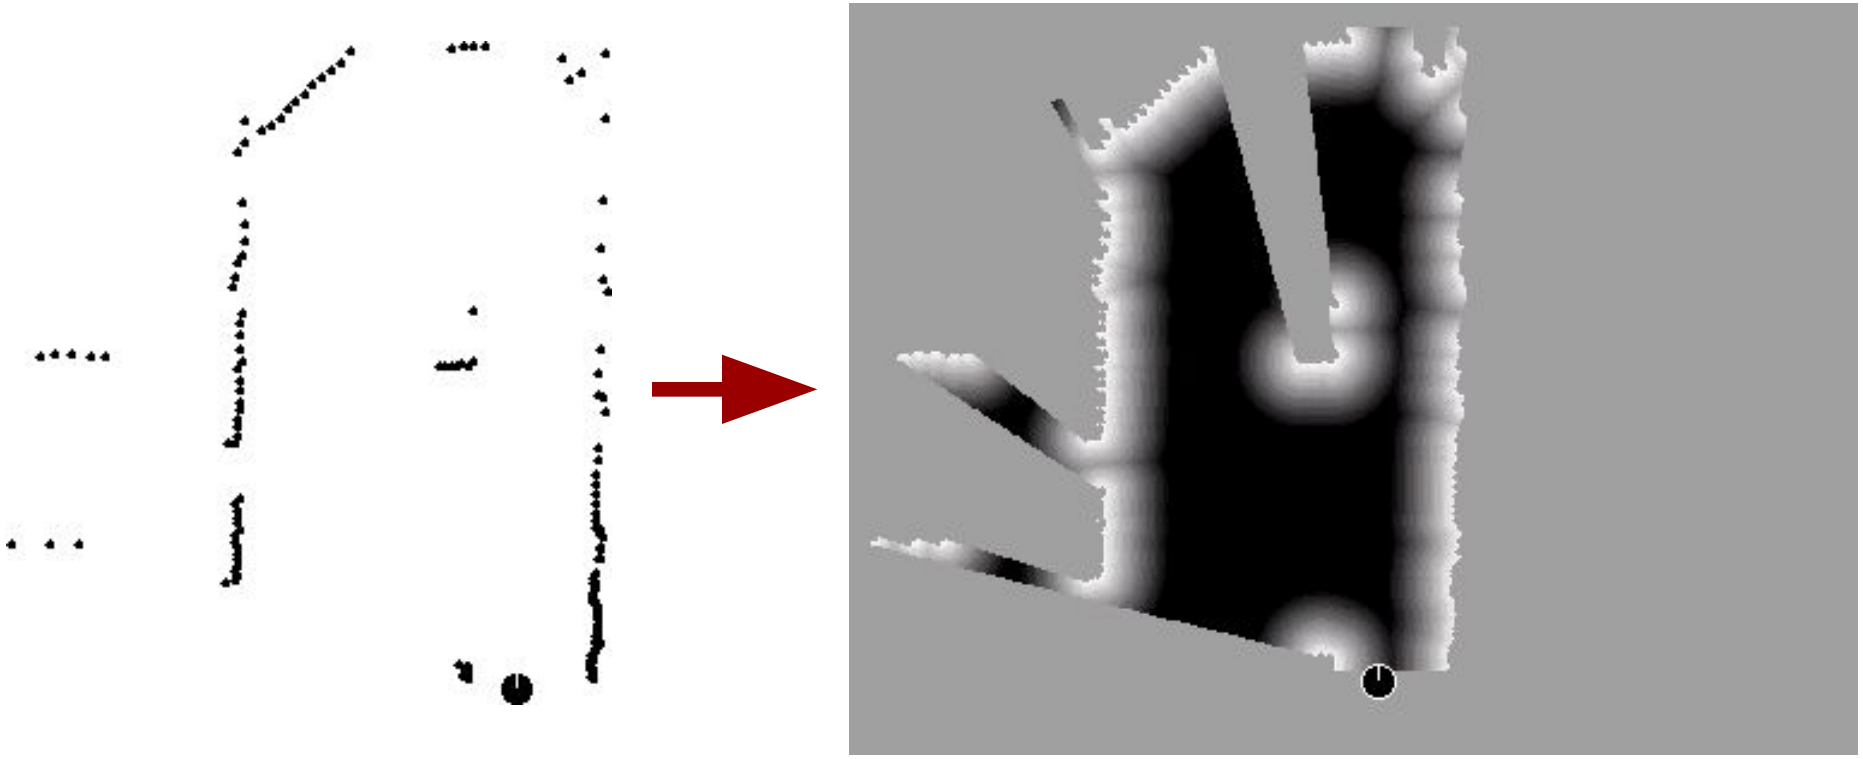

Propiedades del modelo basado en campos de verosimilitud

- Muy eficiente, sólo usa tablas de 2D.
- La grilla de distancias es suave con respecto a pequeñas variaciones en la pose del robot.
- Permite hacer scan matching.
- Ignora las propiedades físicas del haz.

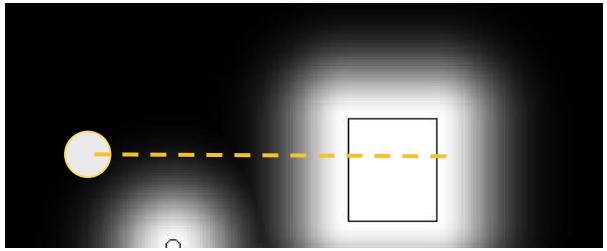

Otros modelos de sensores de proximidad

- Macheo de mapas (sonar, laser): generar pequeños mapas locales con los datos del sensor y machear ese mapa con un modelo global.

- Características o Features (sonar, laser, visión): Extracción de características (puertas, pasillos, etc.) de los datos del sensor.

Marcadores (o landmarks)

- Balizas activas (radio, GPS)
- Marcadores Pasivos (visual, retro-reflexivo)
- Método más común: triangulación

- El sensor provee
  - distancia
  - orientación
  - distancia y orientación.

Distancia y orientación

Sony Aibo

Modelo probabilístico

1. Algoritmo **landmark_detection_model**(z,x,m):

   $z = \langle i, d, \alpha \rangle, x = \langle x, y, \theta \rangle$

2. $\hat{d} = \sqrt{(m_x(i) - x)^2 + (m_y(i) - y)^2}$

3. $\hat{\alpha} = \text{atan2}(m_y(i) - y, m_x(i) - x) - \theta$

4. $p_{\text{det}} = \text{prob}(\hat{d} - d, \varepsilon_d) \cdot \text{prob}(\hat{\alpha} - \alpha, \varepsilon_\alpha)$

5. Return p_{det}

Distribuciones

P(z|x,m)

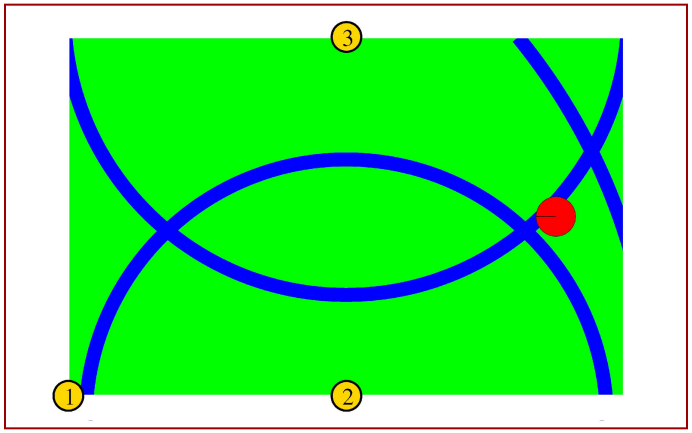

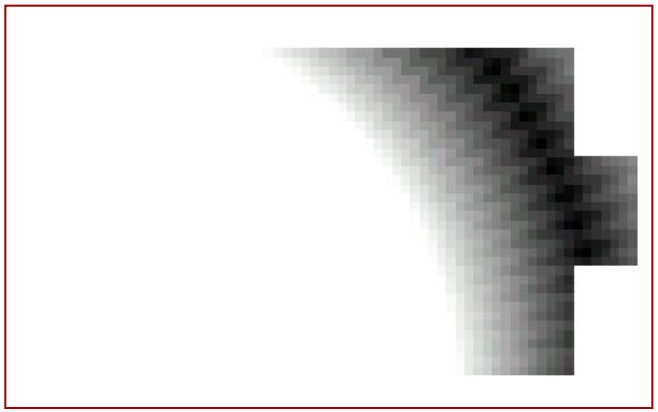

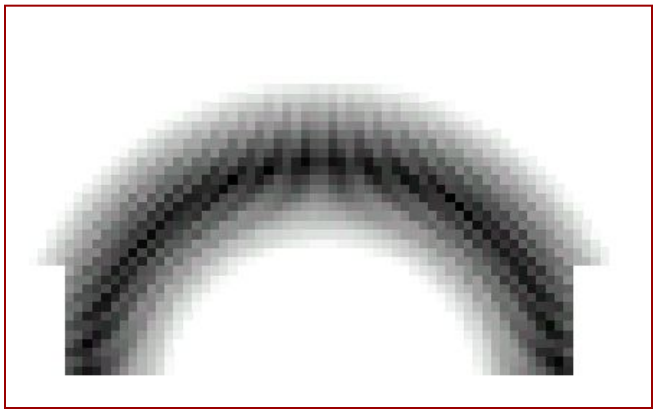

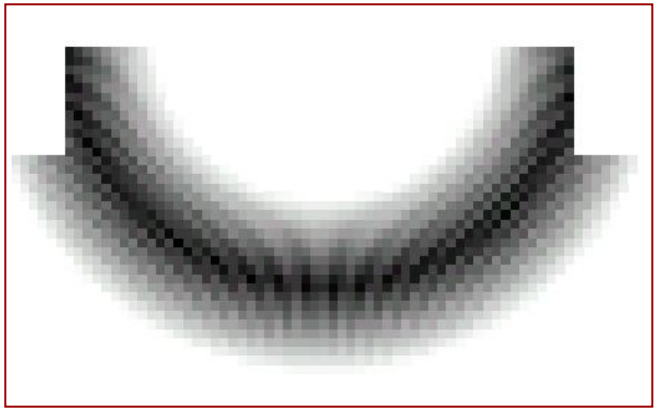

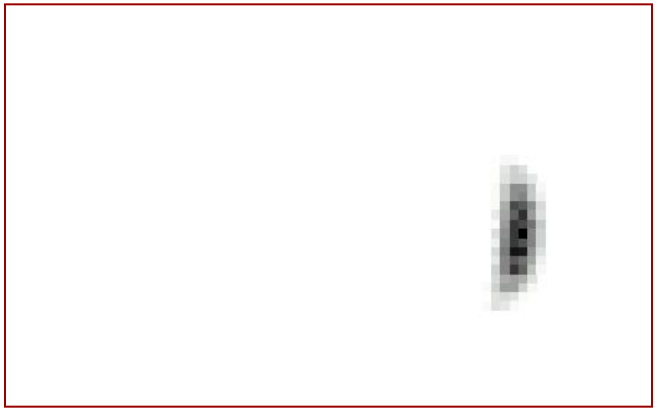

Resumen de modelos de sensores

- Modelado **explícito de la incerteza** en el sensado.
- Muchas veces para tener un buen modelo se busca:
  1. Determinar un modelo paramétrico de la medición sin ruido.
  2. Analizar las fuentes de ruido.
  3. Agregar ruidos adecuados a los parámetros (posiblemente mezclar distribuciones de ruido).
  4. Aprender (y verificar) los parámetros ajustando el modelo a datos.
  5. Finalmente, la probabilidad de la medición está dada por la comparación de una medición obtenida con la esperada.