Principios de la Robótica Autónoma

Filtro de Bayes – Filtro de Kalman Extendido (EKF)

Ignacio Mas

Repaso de Filtro de Bayes

$$bel(x_t) = \eta\, p(z_t \mid x_t) \int p(x_t \mid u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1}$$

- Predicción

$$\overline{bel}(x_t) = \int p(x_t \mid u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1}$$

- Corrección

$$bel(x_t) = \eta\; p(z_t \mid x_t)\, \overline{bel}(x_t)$$

Filtro de Kalman Discreto

Estima el estado *x* de un proceso de tiempo discreto controlado

$$\boxed{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

Con una medición

$$\boxed{z_t = C_t x_t + \delta_t}$$

Componentes del filtro de Kalman

A_t Matriz ($n \times n$) que describe cómo el estado evoluciona de t-1 a t sin control ni ruido.

B_t Matriz ($n \times l$) que describe como el control u_t cambia el estado de t-1 a t.

C_t Matriz ($k \times n$) que describe cómo mapear el estado x_t a una observación z_t.

ε_t δ_t Variables aleatorias que representan el ruido de proceso y de medición que se asumen independientes y normalmente distribuidas con covarianzas Q_t y R_t respectivamente.

Filtro de Kalman en 1D

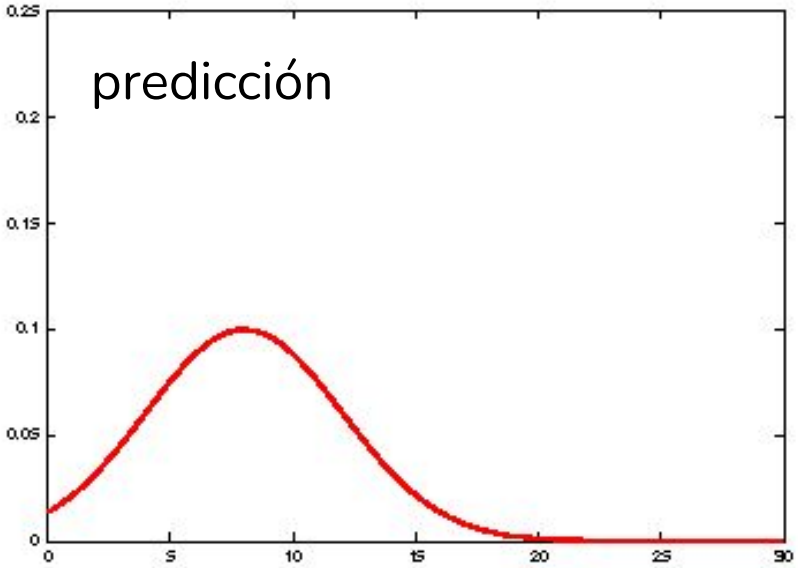

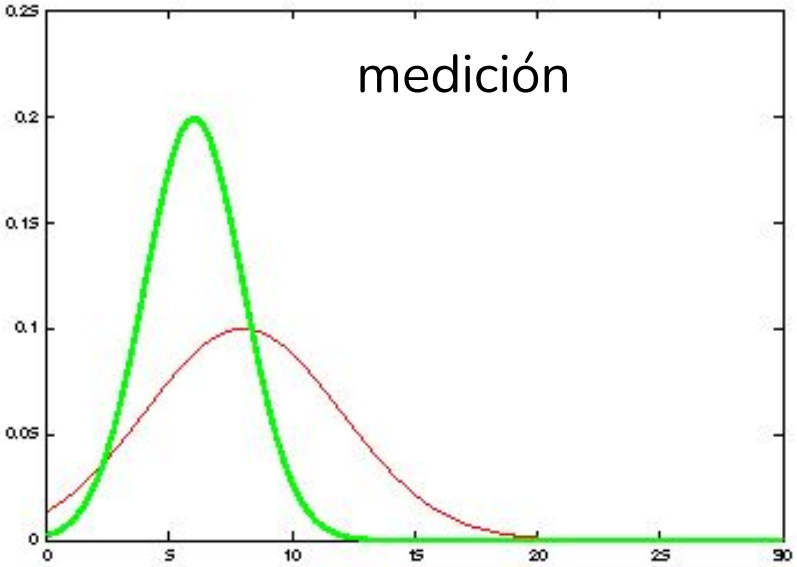

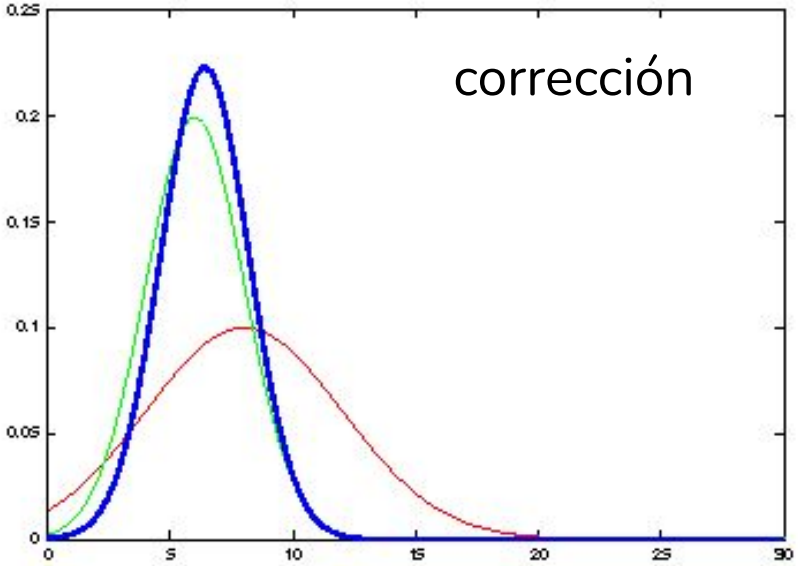

Es un promedio ponderado

Filtro de Kalman en 1D

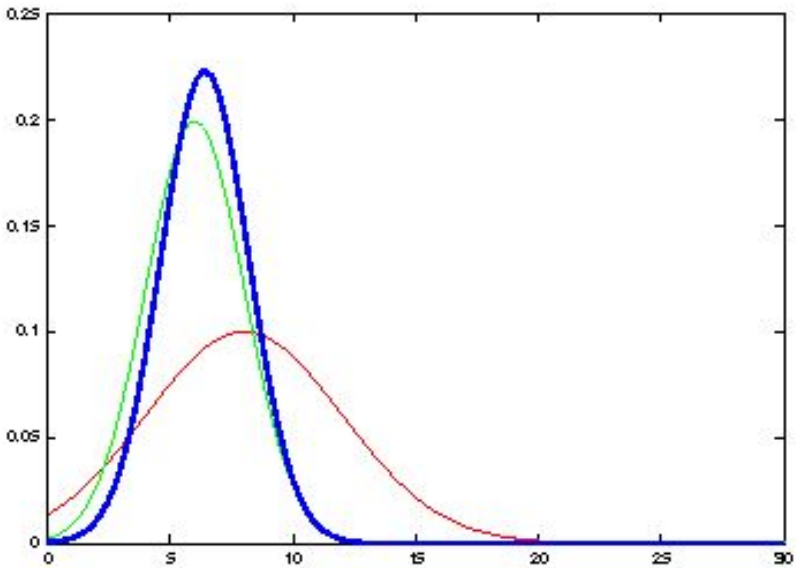

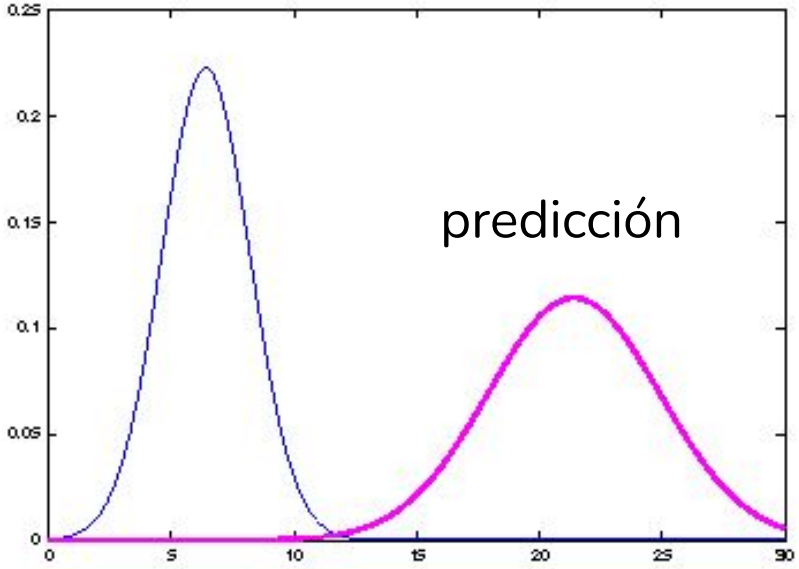

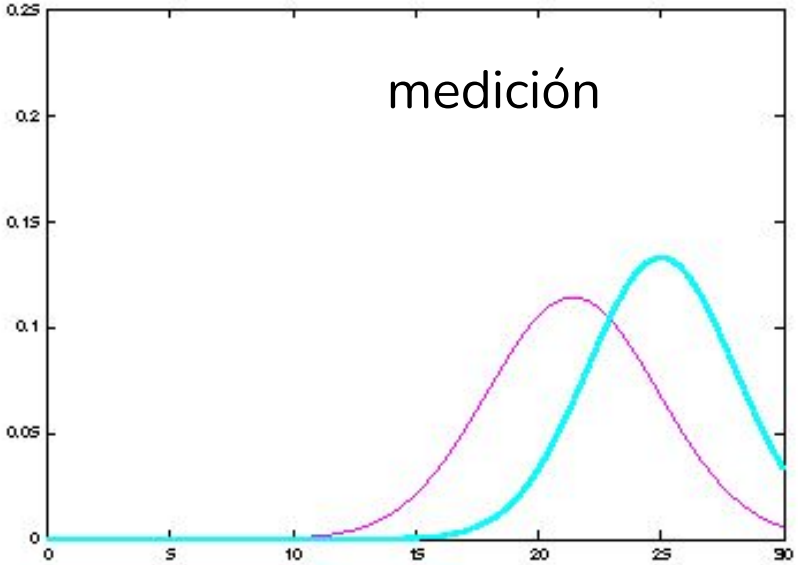

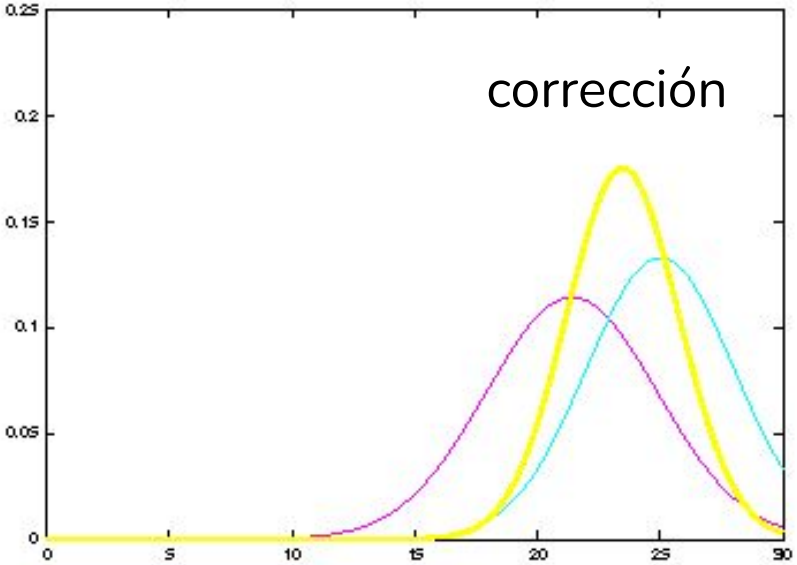

Algoritmo de filtro de Kalman

1. Algoritmo **Kalman_filter**(μ_{t-1}, Σ_{t-1}, u_t, z_t):

2. Predicción:
3. $\bar{\mu}_t = A_t \mu_{t-1} + B_t u_t$
4. $\bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t$

5. Corrección:
6. $K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + R_t)^{-1}$
7. $\mu_t = \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t)$
8. $\Sigma_t = (I - K_t C_t) \bar{\Sigma}_t$
9. Return μ_t, Σ_t

Sistema dinámico No-lineal

- La mayoría de los problemas reales de robótica incluyen funciones no lineales

$$\cancel{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t} \qquad \cancel{z_t = C_t x_t + \delta_t}$$

$$\Downarrow \qquad\qquad \Downarrow$$

$$\boxed{x_t = g(u_t, x_{t-1})} \qquad \boxed{z_t = h(x_t)}$$

Suposición de Linealidad

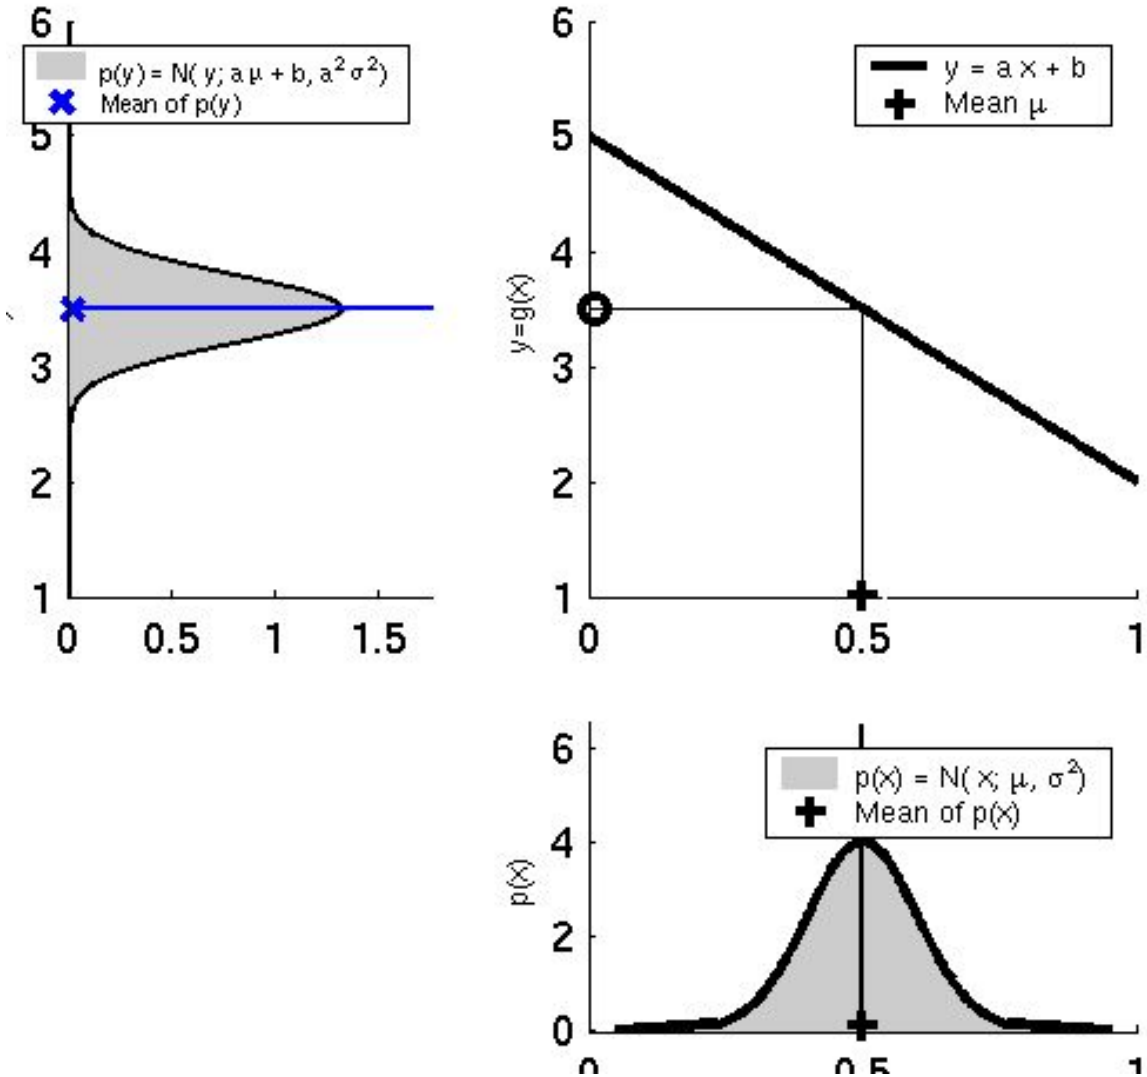

Función No-Lineal

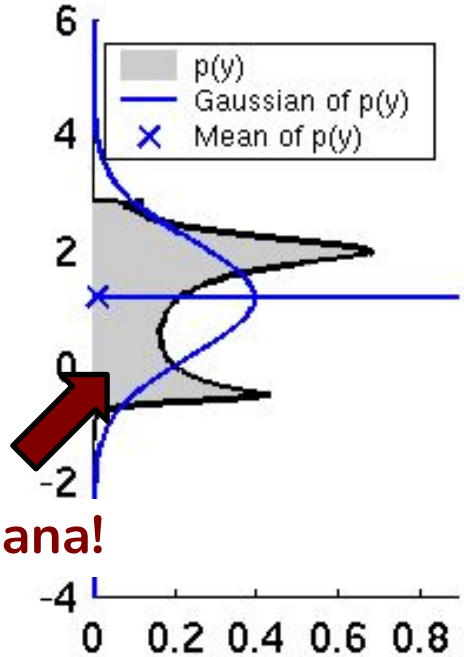

No Gaussiana!

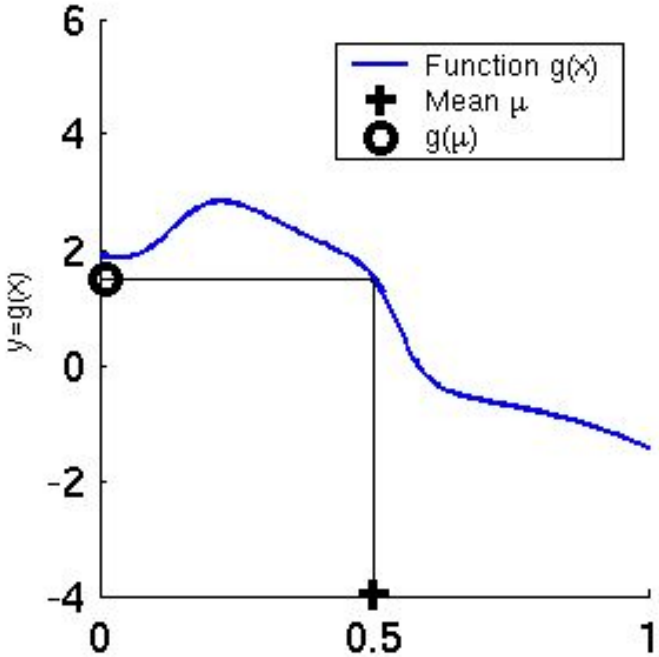

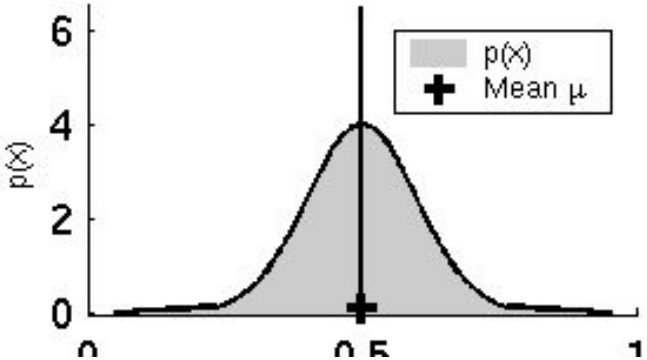

Distribuciones No Gaussianas

- Funciones no lineales llevan a distribuciones no-Gaussianas
- El filtro de Kalman ya no se puede usar!

Cómo se resuelve esto?

Distribuciones No Gaussianas

- Funciones no lineales llevan a distribuciones no-Gaussianas
- El filtro de Kalman ya no se puede usar!

Cómo se resuelve esto?

Linealización local!

Linealización EKF: Expansión de Taylor de primer orden

- Predicción:

$$g(u_t, x_{t-1}) \approx g(u_t, \mu_{t-1}) + \frac{\partial g(u_t, \mu_{t-1})}{\partial x_{t-1}} (x_{t-1} - \mu_{t-1})$$

$$g(u_t, x_{t-1}) \approx g(u_t, \mu_{t-1}) + G_t \, (x_{t-1} - \mu_{t-1})$$

- Corrección:

$$h(x_t) \approx h(\bar{\mu}_t) + \frac{\partial h(\bar{\mu}_t)}{\partial x_t} (x_t - \bar{\mu}_t)$$

$$h(x_t) \approx h(\bar{\mu}_t) + H_t \, (x_t - \bar{\mu}_t)$$

Matrices Jacobianas

Repaso: Matriz Jacobiana

- En general, es una **matriz no cuadrada** de $n \times m$
- Dada una función vectorial

$$f(\mathbf{x}) = \begin{bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ \vdots \\ f_m(\mathbf{x}) \end{bmatrix}$$

- La **matriz Jacobiana** se define como

$$\mathbf{F}_{\mathbf{x}} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \cdots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \frac{\partial f_m}{\partial x_2} & \cdots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}$$

Repaso: Matriz Jacobiana

- Es la orientación del **plano tangente** a una función vectorial en un punto dado

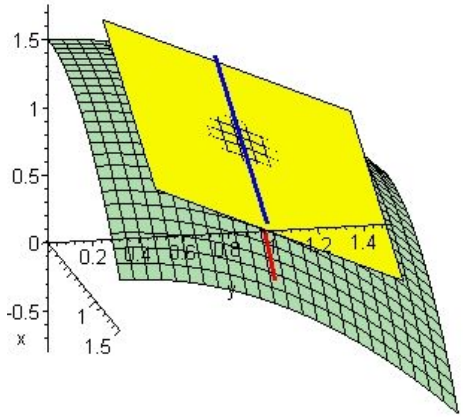

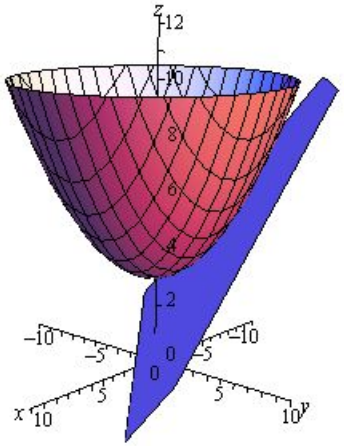

- Es la **generalización del gradiente** de una función escalar

Linealización EKF: Expansión de Taylor de primer orden

- Predicción:

$$g(u_t, x_{t-1}) \approx g(u_t, \mu_{t-1}) + \frac{\partial g(u_t, \mu_{t-1})}{\partial x_{t-1}} (x_{t-1} - \mu_{t-1})$$

$$g(u_t, x_{t-1}) \approx g(u_t, \mu_{t-1}) + G_t \, (x_{t-1} - \mu_{t-1})$$

- Corrección:

$$h(x_t) \approx h(\bar{\mu}_t) + \frac{\partial h(\bar{\mu}_t)}{\partial x_t} (x_t - \bar{\mu}_t)$$

$$h(x_t) \approx h(\bar{\mu}_t) + H_t \, (x_t - \bar{\mu}_t)$$

Función Lineal!

Suposición de Linealidad

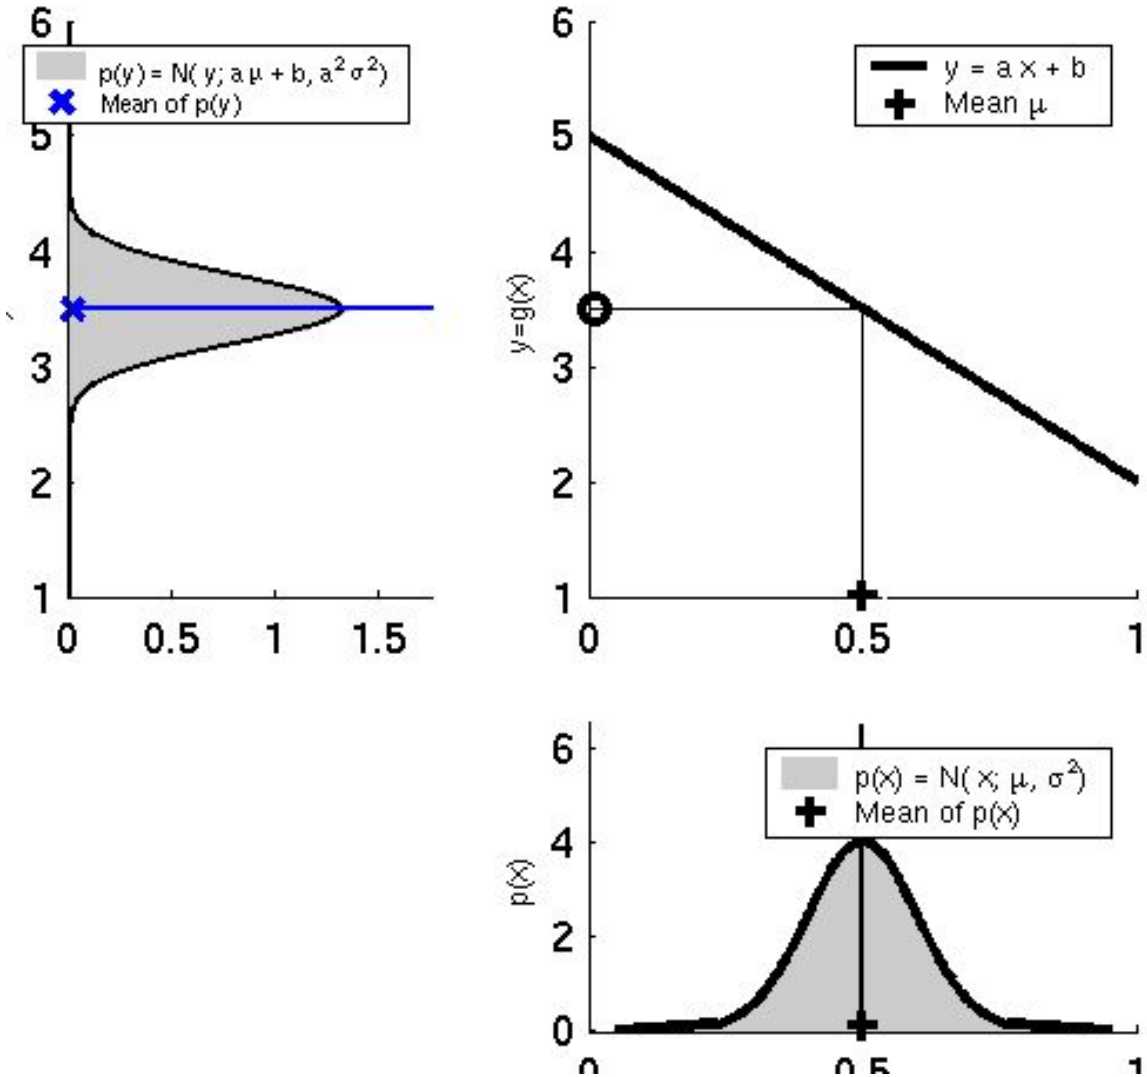

Función No Lineal

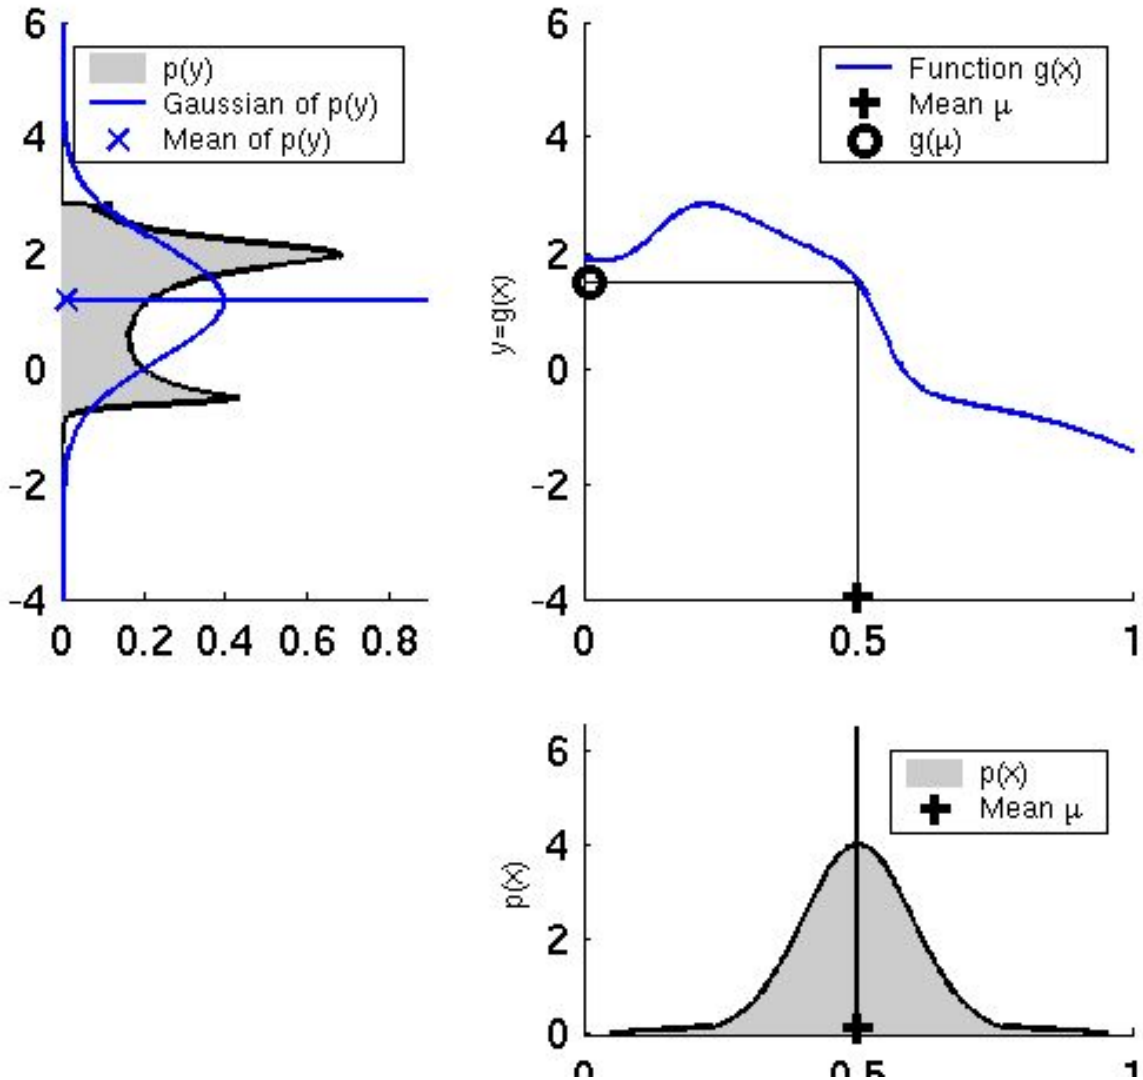

Linealización EKF (1)

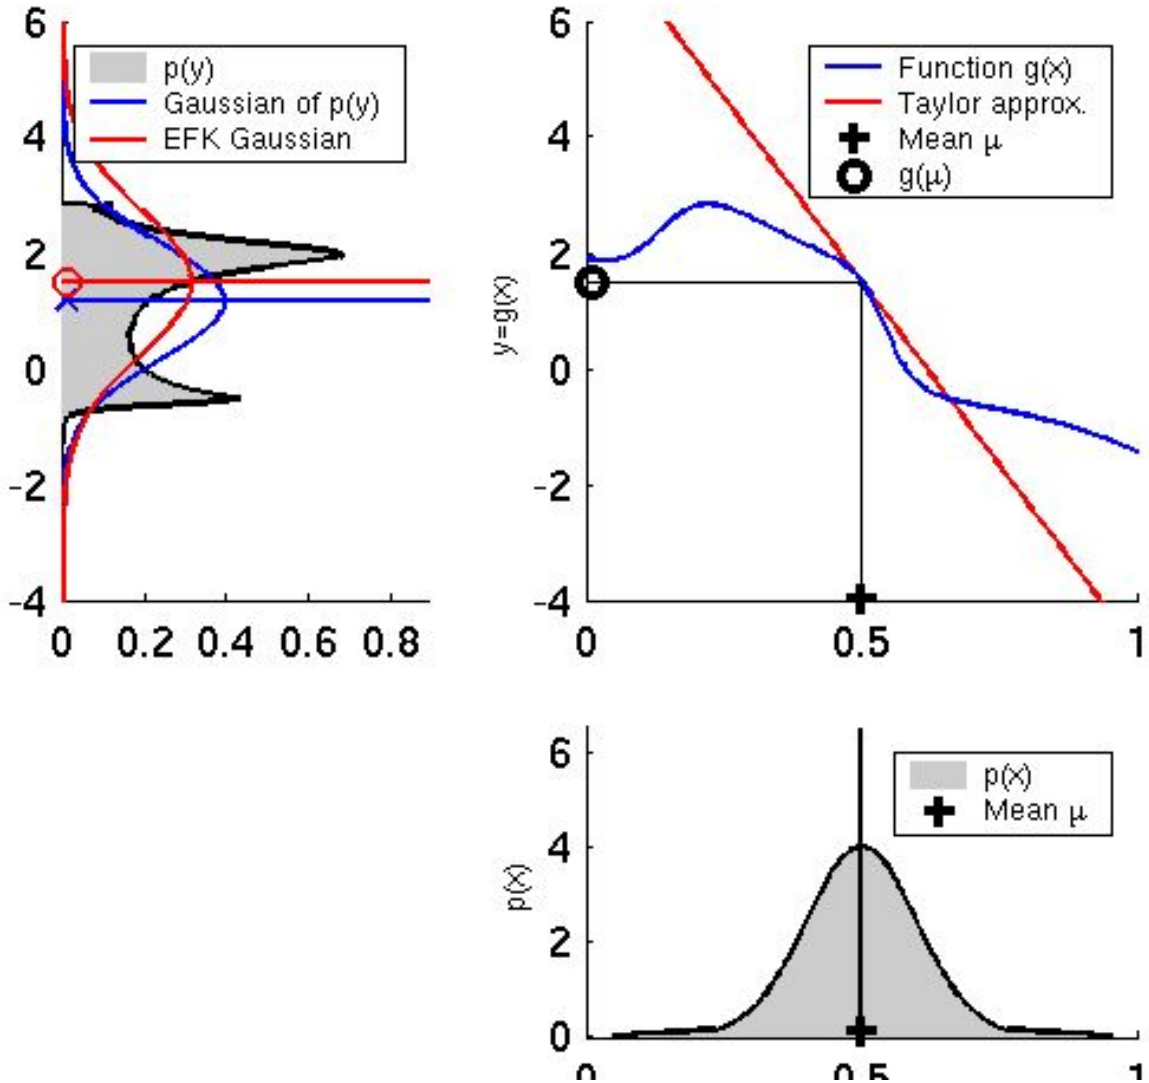

Linealización EKF (2)

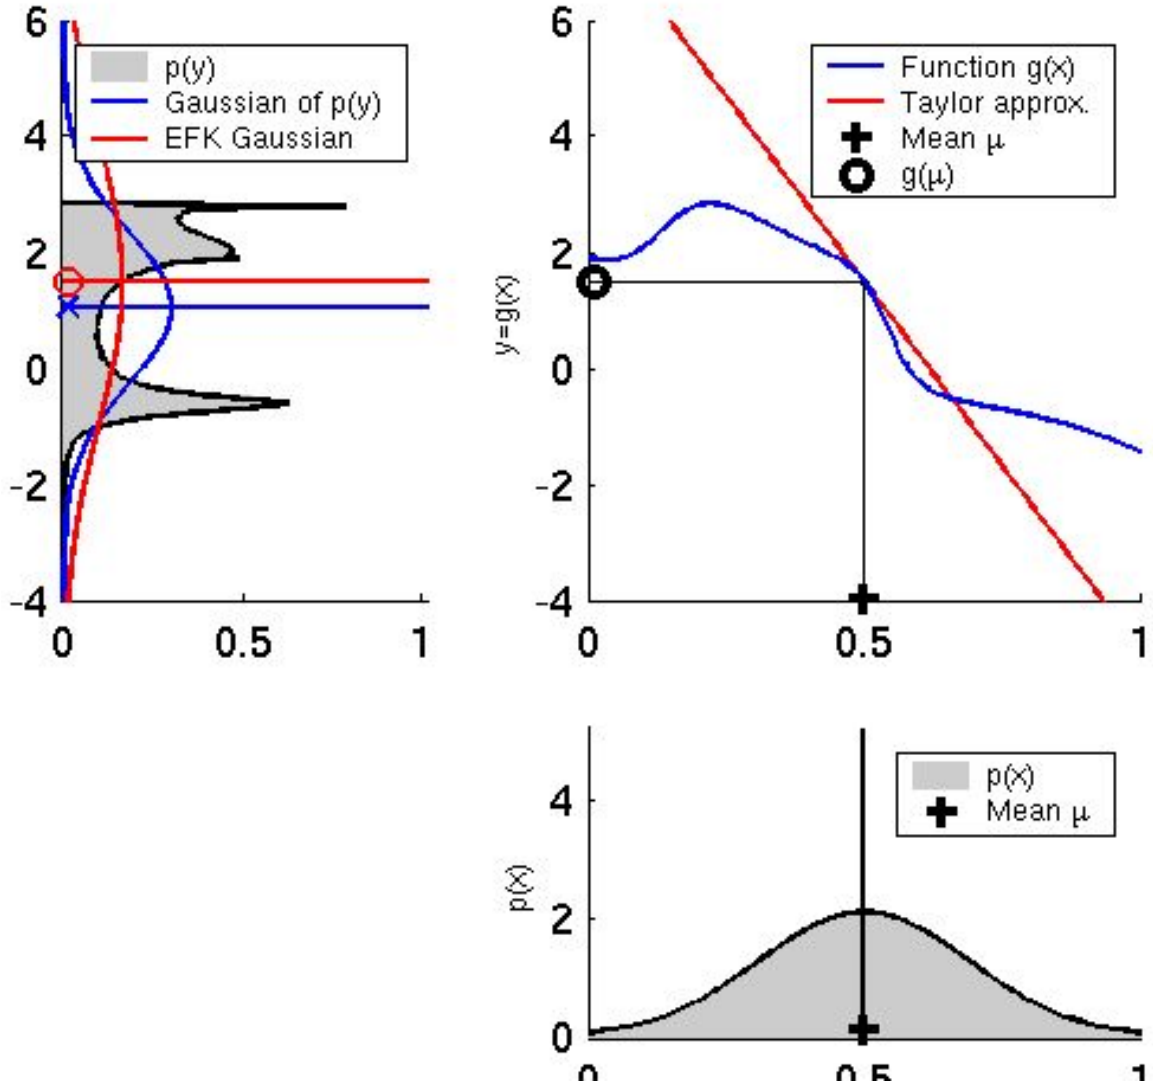

Linealización EKF (3)

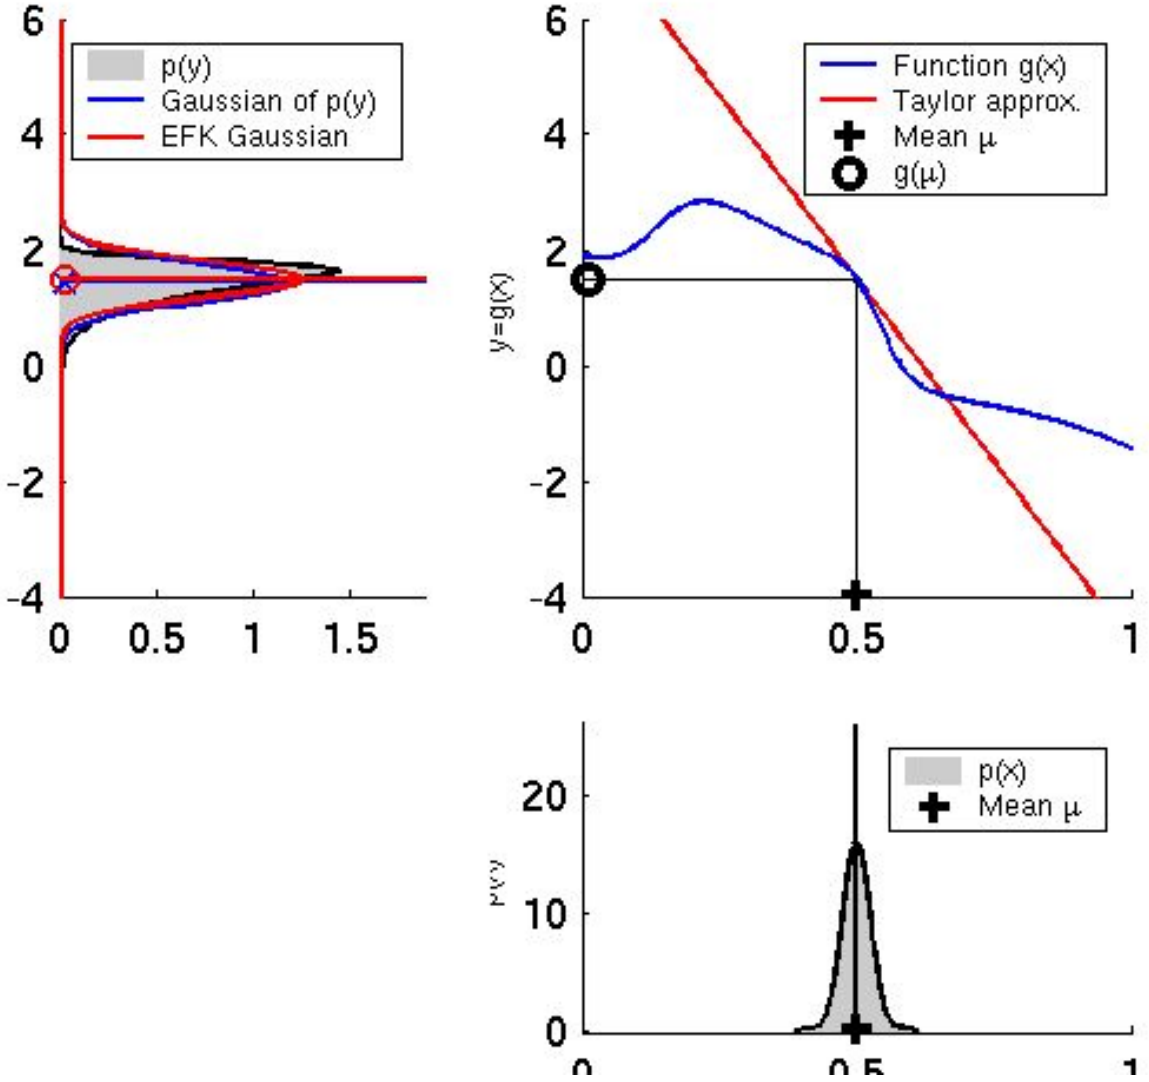

Algoritmo EKF

1. **Extended_Kalman_filter**(μ_{t-1}, Σ_{t-1}, u_t, z_t):

2. Predicción:

3. $\bar{\mu}_t = g(u_t, \mu_{t-1})$ $\longleftarrow$ $\bar{\mu}_t = A_t \mu_{t-1} + B_t u_t$

4. $\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + Q_t$ $\longleftarrow$ $\bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t$

5. Corrección:

6. $K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + R_t)^{-1}$ $\longleftarrow$ $K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + R_t)^{-1}$

7. $\mu_t = \bar{\mu}_t + K_t (z_t - h(\bar{\mu}_t))$ $\longleftarrow$ $\mu_t = \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t)$

8. $\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t$ $\longleftarrow$ $\Sigma_t = (I - K_t C_t) \bar{\Sigma}_t$

9. Return μ_t, Σ_t

$$H_t = \frac{\partial h(\bar{\mu}_t)}{\partial x_t} \qquad G_t = \frac{\partial g(u_t, \mu_{t-1})}{\partial x_{t-1}}$$

Repaso de modelos de movimiento

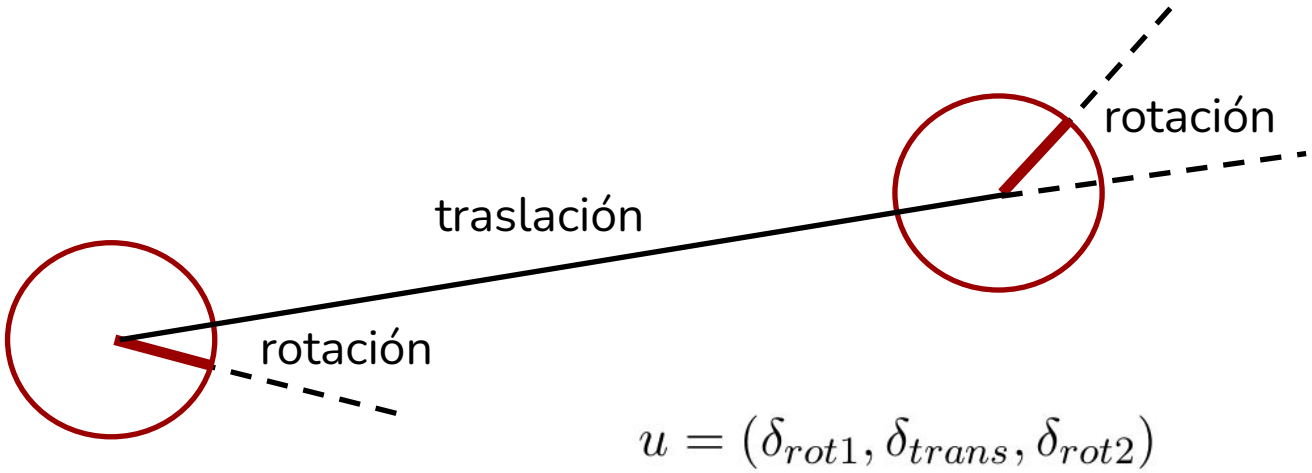

- Descomposición del movimiento en
  - Distancia recorrida
  - Rotación inicial
  - Rotación final

Modelo de odometría

- Modelo no lineal:

$$\begin{bmatrix} x' \\ y' \\ \theta' \end{bmatrix} = \underbrace{\begin{bmatrix} x \\ y \\ \theta \end{bmatrix} + \begin{bmatrix} \delta_{trans} \cos(\theta + \delta_{rot_1}) \\ \delta_{trans} \sin(\theta + \delta_{rot_1}) \\ \delta_{rot_1} + \delta_{rot_2} \end{bmatrix}}_{g(u_t, x_{t-1})} + \mathcal{N}(0, R_t)$$

- Linealización:

$$g(u_t, x_{t-1}) \approx g(u_t, \mu_{t-1}) + G_t(x_{t-1} - \mu_{t-1})$$

Modelo de odometría

$$g\left(u_t, x_{t-1}\right) \approx g\left(u_t, \mu_{t-1}\right) + G_t(x_{t-1} - \mu_{t-1})$$

- Jacobiano con respecto al estado:

$$G_t = \frac{\delta g\left(u_t, \mu_{t-1}\right)}{\delta x_{t-1}} = \begin{bmatrix} \frac{\delta x'}{\delta \mu_{t-1,x}} & \frac{\delta x'}{\delta \mu_{t-1,y}} & \frac{\delta x'}{\delta \mu_{t-1,\theta}} \\ \frac{\delta y'}{\delta \mu_{t-1,x}} & \frac{\delta y'}{\delta \mu_{t-1,y}} & \frac{\delta y'}{\delta \mu_{t-1,\theta}} \\ \frac{\delta \theta'}{\delta \mu_{t-1,x}} & \frac{\delta \theta'}{\delta \mu_{t-1,y}} & \frac{\delta \theta'}{\delta \mu_{t-1,\theta}} \end{bmatrix}$$

$$G_t = \begin{bmatrix} 1 & 0 & -\delta_{trans}\sin(\theta + \delta_{rot_1}) \\ 0 & 1 & \delta_{trans}\cos(\theta + \delta_{rot_1}) \\ 0 & 0 & 1 \end{bmatrix}$$

Modelo de odometría

$$g\left(u_t, x_{t-1}\right) \approx g\left(u_t, \mu_{t-1}\right) + G_t(x_{t-1} - \mu_{t-1})$$

- Jacobiano con respecto al control:

$$Vt = \frac{\delta g\left(u_t, \mu_{t-1}\right)}{\delta u_t} = \begin{bmatrix} \frac{\delta x'}{\delta u_{t,\delta_{rot_1}}} & \frac{\delta x'}{\delta u_{t,\delta_{trans}}} & \frac{\delta x'}{\delta u_{t,\delta_{rot_2}}} \\ \frac{\delta y'}{\delta u_{t,\delta_{rot_1}}} & \frac{\delta y'}{\delta u_{t,\delta_{trans}}} & \frac{\delta y'}{\delta u_{t,\delta_{rot_2}}} \\ \frac{\delta \theta'}{\delta u_{t,\delta_{rot_1}}} & \frac{\delta \theta'}{\delta u_{t,\delta_{trans}}} & \frac{\delta \theta'}{\delta u_{t,\delta_{rot_2}}} \end{bmatrix}$$

$$V_t = \begin{bmatrix} -\delta_{trans}\sin(\theta + \delta_{rot_1}) & \cos(\theta + \delta_{rot_1}) & 0 \\ \delta_{trans}\cos(\theta + \delta_{rot_1}) & \sin(\theta + \delta_{rot_1}) & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

Modelo de sensor (distancia y orientación)

- Localización EKF con landmarks

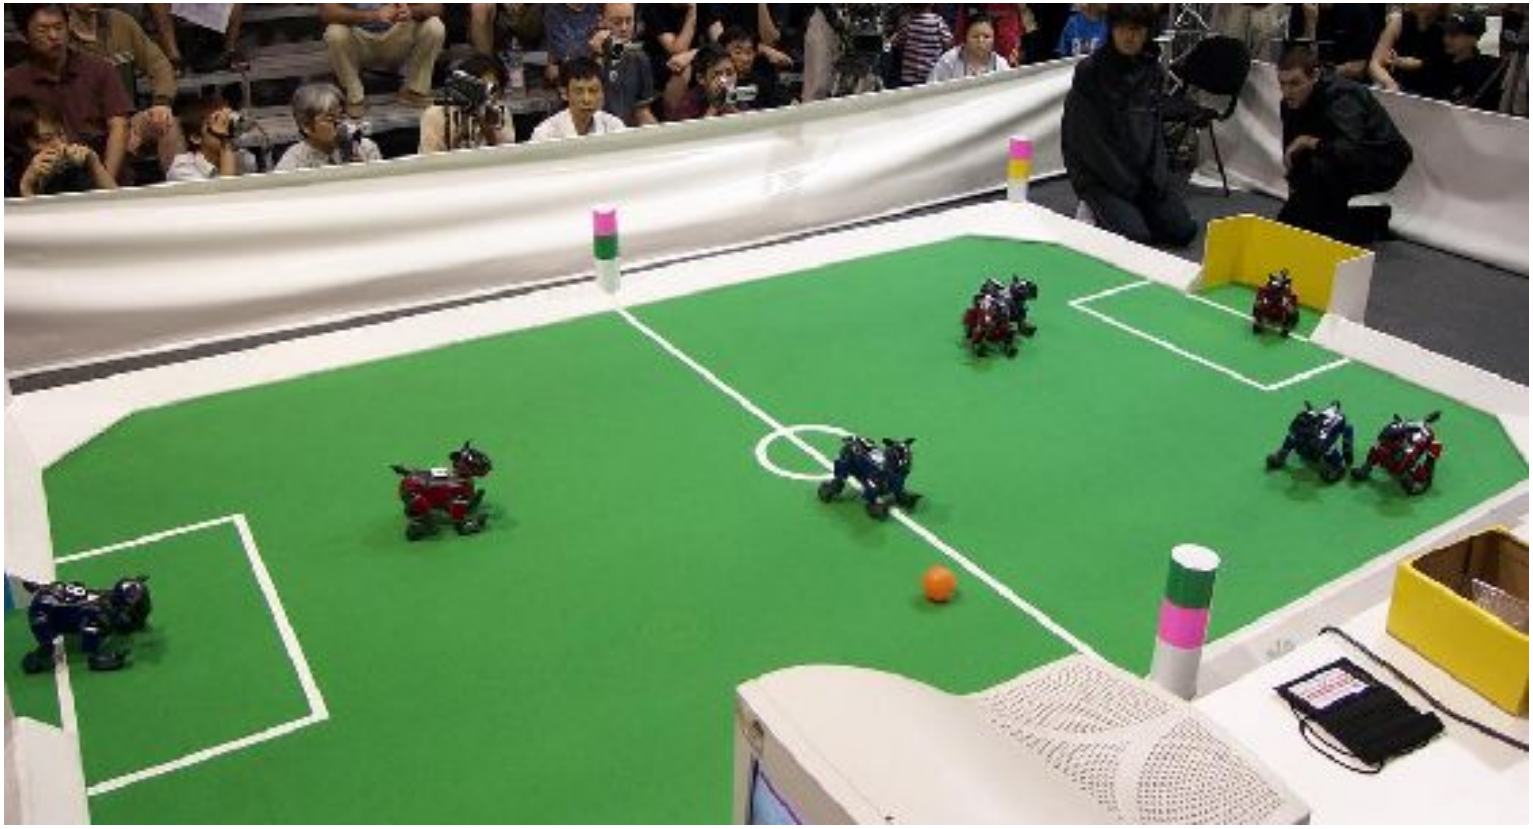

Modelo de distancia y orientación

- Modelo de Medición:

$$z_t^i = \begin{bmatrix} r_t^i \\ \phi_t^i \end{bmatrix} = \begin{bmatrix} \sqrt{(m_{j,x} - x)^2 + (m_{j,y} - y)^2} \\ \operatorname{atan2}(m_{j,y} - y, m_{j,x} - x) - \theta \end{bmatrix} + \mathcal{N}(0, Q_t)$$

- Linealización:

$$h(x_t, m) \approx h(\overline{\mu}_t) + H_t^i (x_t - \overline{\mu}_t)$$

Modelo de distancia y orientación

- Jacobiano con respecto al estado:

$$H_t = \frac{\delta h\left(\overline{\mu}_t, m\right)}{\delta x_t} = \begin{bmatrix} \frac{\delta r_t^i}{\delta \overline{\mu}_{t,x}} & \frac{\delta r_t^i}{\delta \overline{\mu}_{t,y}} & \frac{\delta r_t^i}{\delta \overline{\mu}_{t,\theta}} \\ \frac{\delta \phi_t^i}{\delta \overline{\mu}_{t,x}} & \frac{\delta \phi_t^i}{\delta \overline{\mu}_{t,y}} & \frac{\delta \phi_t^i}{\delta \overline{\mu}_{t,\theta}} \end{bmatrix}$$

$$H_t^i = \begin{bmatrix} -\frac{m_{j,x} - \overline{\mu}_{t,x}}{\sqrt{q}} & -\frac{m_{j,y} - \overline{\mu}_{t,y}}{\sqrt{q}} & 0 \\ \frac{m_{j,y} - \overline{\mu}_{t,y}}{q} & -\frac{m_{j,x} - \overline{\mu}_{t,x}}{q} & -1 \end{bmatrix}$$

donde

$$q = \left(m_{j,x} - \overline{\mu}_{t,x}\right)^2 + \left(m_{j,y} - \overline{\mu}_{t,y}\right)^2$$

Algoritmo EKF (predicción)

1: ExtendedKalmanFilter$(\mu_{t-1}, \Sigma_{t-1}, u_t, z_t, c_t, m)$

2: $\theta = \mu_{t-1,\theta}$

3: $G_t = \begin{bmatrix} 1 & 0 & -\delta_{trans}\sin(\theta + \delta_{rot_1}) \\ 0 & 1 & \delta_{trans}\cos(\theta + \delta_{rot_1}) \\ 0 & 0 & 1 \end{bmatrix}$

4: $V_t = \begin{bmatrix} -\delta_{trans}\sin(\theta + \delta_{rot_1}) & \cos(\theta + \delta_{rot_1}) & 0 \\ \delta_{trans}\cos(\theta + \delta_{rot_1}) & \sin(\theta + \delta_{rot_1}) & 0 \\ 1 & 0 & 1 \end{bmatrix}$

5: $M_t = \begin{bmatrix} \alpha_1\delta_{rot_1}^2 + \alpha_2\delta_{trans}^2 & 0 & 0 \\ 0 & \alpha_3\delta_{trans}^2 + \alpha_4\left(\delta_{rot_1}^2 + \delta_{rot_2}^2\right) & 0 \\ 0 & 0 & \alpha_1\delta_{rot_2}^2 + \alpha_2\delta_{trans}^2 \end{bmatrix}$

6: $\overline{\mu}_t = \mu_{t-1} + \begin{bmatrix} \delta_{trans}\cos(\theta + \delta_{rot_1}) \\ \delta_{trans}\sin(\theta + \delta_{rot_1}) \\ \delta_{rot_1} + \delta_{rot_2} \end{bmatrix}$

7: $\overline{\Sigma}_t = G_t\Sigma_{t-1}G_t^\top + V_tM_tV_t^\top$

M_t es una covarianza que modela el ruido que hay en los comandos de control. $V_tM_tV_t^\top$ hace referencia a la incerteza que es agregada debido al ruido de los comandos de control.

Algoritmo EKF (predicción)

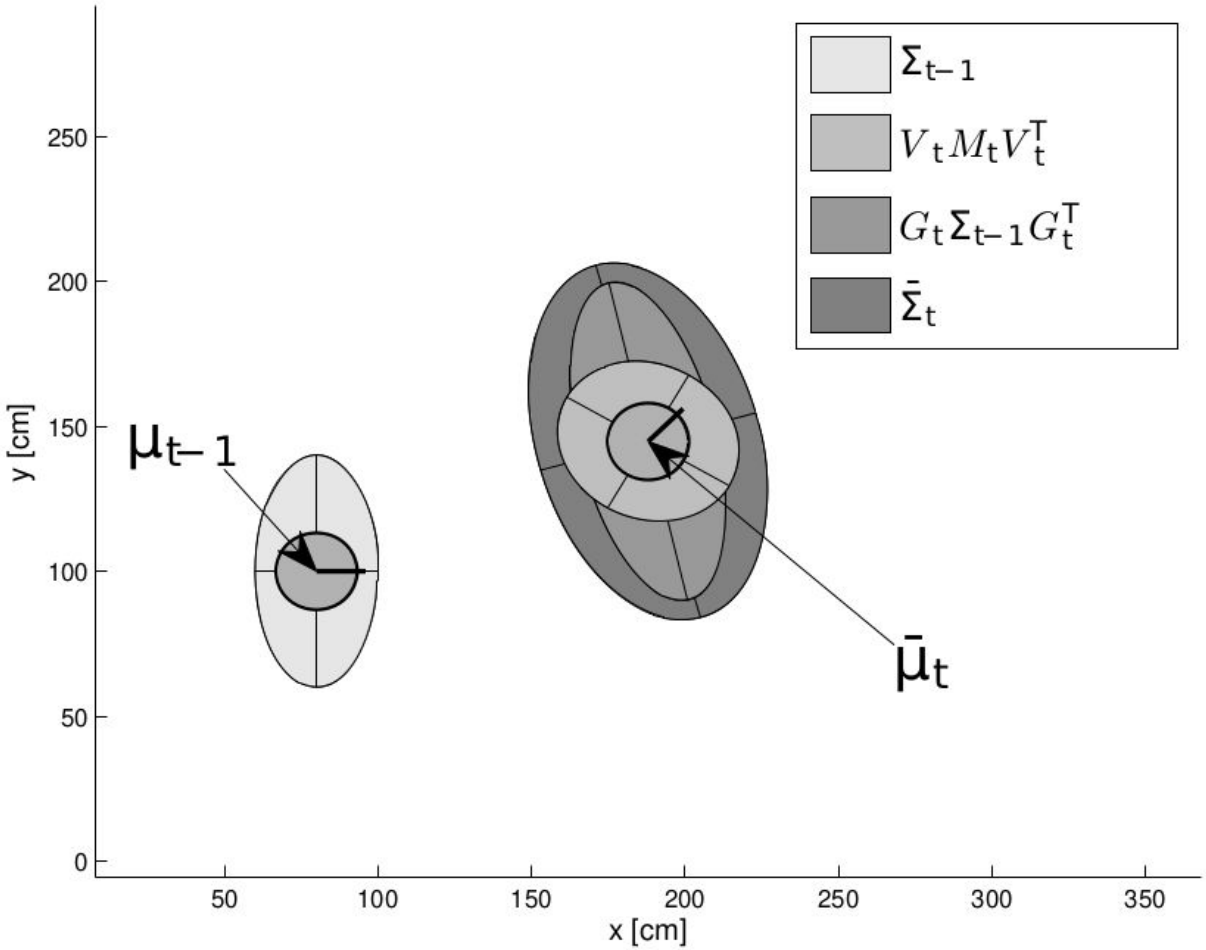

Algoritmo EKF (Corrección)

$Q_t = \begin{bmatrix} \sigma_r^2 & 0 \\ 0 & \sigma_\phi^2 \end{bmatrix}$

for t **do**odos los features observados $z_t^i = (r_t^i, \phi_t^i)^\top$

$\quad j = c_t^i$

$\quad q = (m_{j,x} - \overline{\mu}_{t,x})^2 + (m_{j,y} - \overline{\mu}_{t,y})^2$

$\quad \hat{z}_t^i = \begin{bmatrix} \sqrt{q} \\ \operatorname{atan2}(m_{j,y} - \overline{\mu}_{t,y}, m_{j,x} - \overline{\mu}_{t,x}) - \overline{\mu}_{t,\theta} \end{bmatrix}$

$\quad H_t^i = \begin{bmatrix} -\dfrac{m_{j,x} - \overline{\mu}_{t,x}}{\sqrt{q}} & -\dfrac{m_{j,y} - \overline{\mu}_{t,y}}{\sqrt{q}} & 0 \\ \dfrac{m_{j,y} - \overline{\mu}_{t,y}}{q} & -\dfrac{m_{j,x} - \overline{\mu}_{t,x}}{q} & -1 \end{bmatrix}$

$\quad S_t^i = H_t^i \overline{\Sigma}_t {H_t^i}^\top + Q_t$

$\quad K_t^i = \overline{\Sigma}_t {H_t^i}^\top {S_t^i}^{-1}$

$\quad \overline{\mu}_t = \overline{\mu}_t + K_t^i (z_t - \hat{z}_t^i)$

$\quad \overline{\Sigma}_t = (I - K_t^i H_t^i) \overline{\Sigma}_t$

end for

$\mu_t = \overline{\mu}_t$

$\Sigma_t = \overline{\Sigma}_t$

return μ_t, Σ_t

Algoritmo EKF (Predicción)

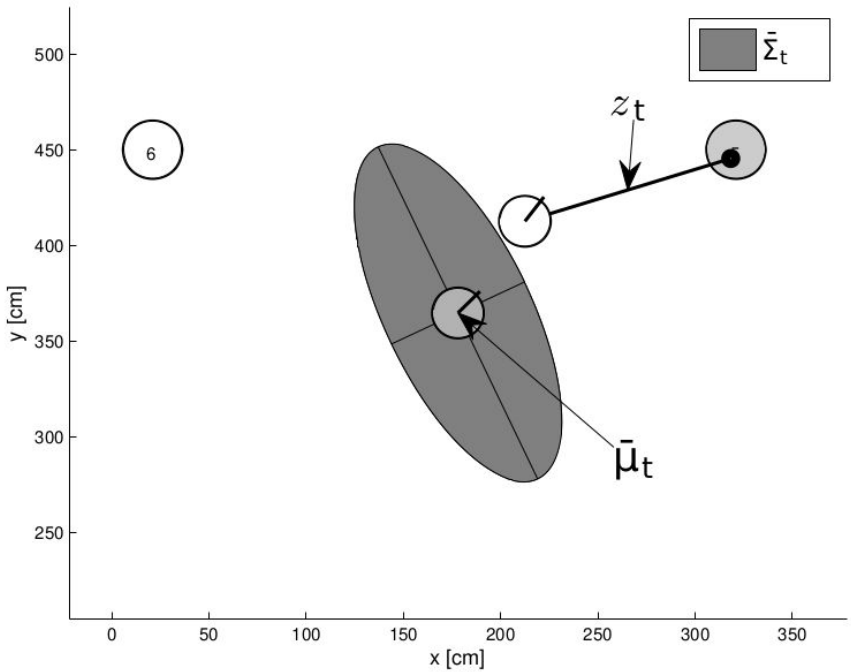

Predicción de Pose

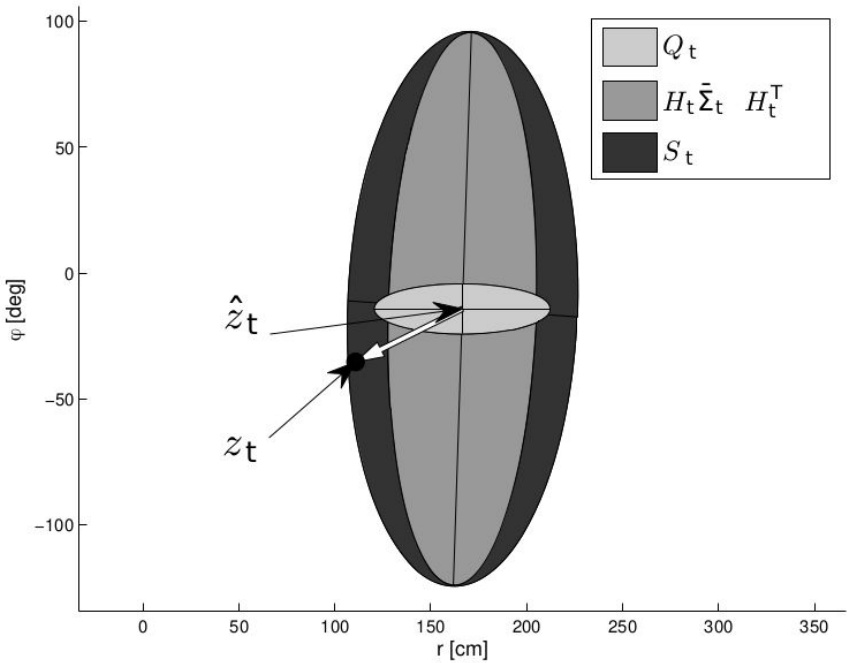

Predicción de Medición

- La pose esperada del robot y la medición están indicados por el círculo blanco y la línea en negrita, respectivamente.
- La flecha blanca indica la innovación, diferencia entre la observación y predicción de la medición.

Algoritmo EKF (Corrección)

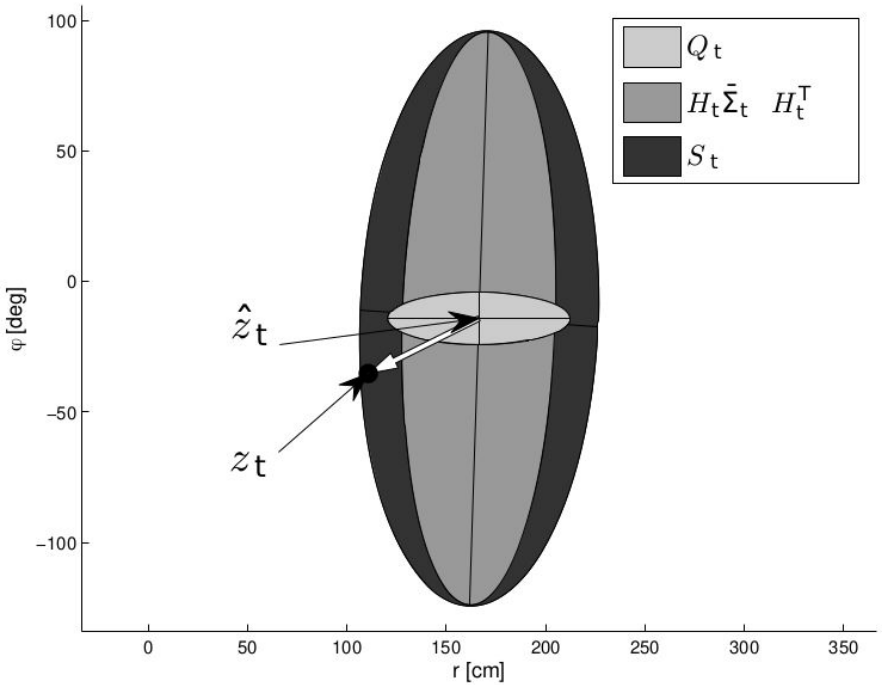

Predicción de Medición

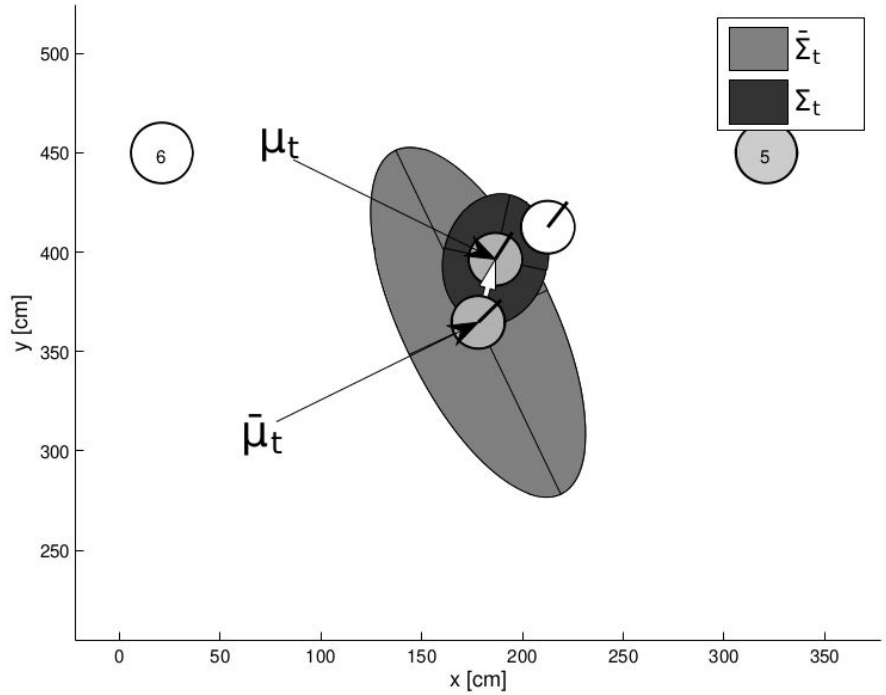

Corrección de Medición

Algoritmo EKF

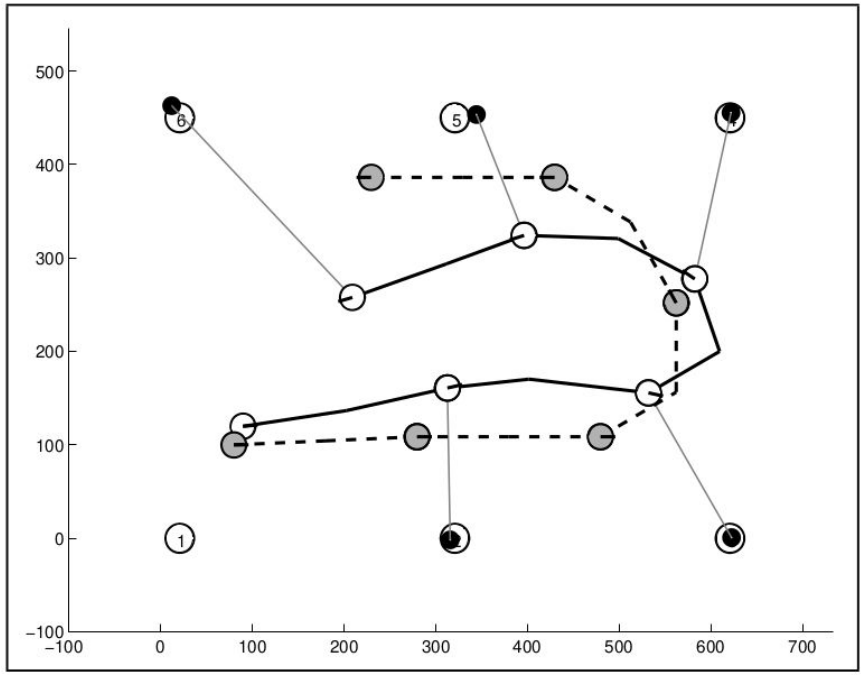

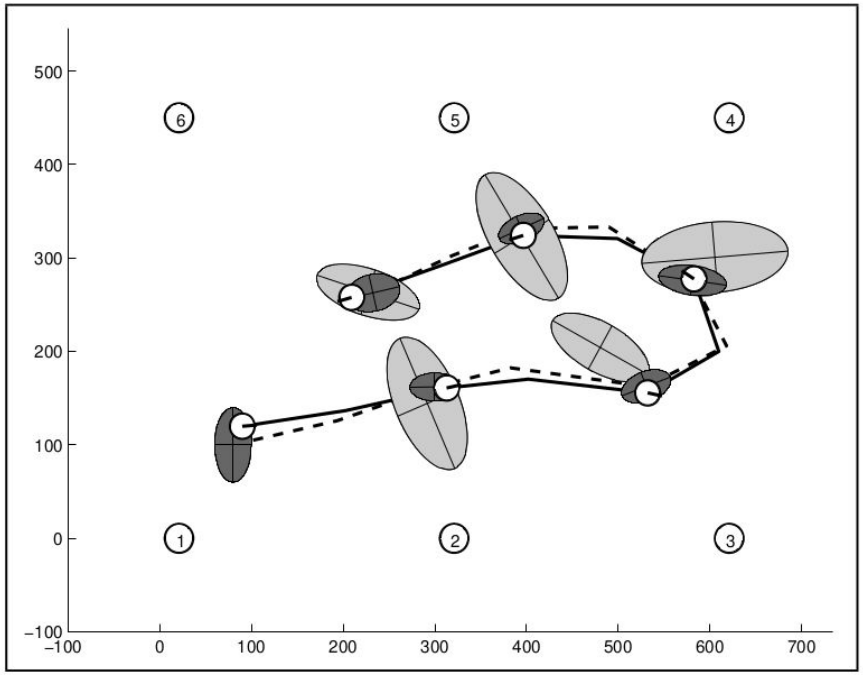

- La línea sólida es el Ground-truth. En el primer gráfico la línea punteada es la odometría y en el segundo gráfico es la estimación dada por el EKF.

Resumen de filtro de Kalman Extendido

- Solución ad-hoc para tratar las **no-linealidades**
- Linealiza localmente en cada paso
- En la práctica, funciona bien para no-linealidades **moderadas**
- Ejemplo: localización de landmarks
- Hay otras maneras de tratar las no-linealidades (unscented Kalman Filter)