Principios de la Robótica Autónoma

Mapas de grilla y mapeo con poses conocidas

Ignacio Mas

Motivación: ¿Por qué mapas?

- **Aprender mapas** es uno de los problemas fundamentales de la robótica móvil

- Los mapas permiten localización, hacer tareas de manera eficiente, etc.

- Los sistemas **robóticos complejos** se basan en mapas para estas tareas.

El problema general del mapeo

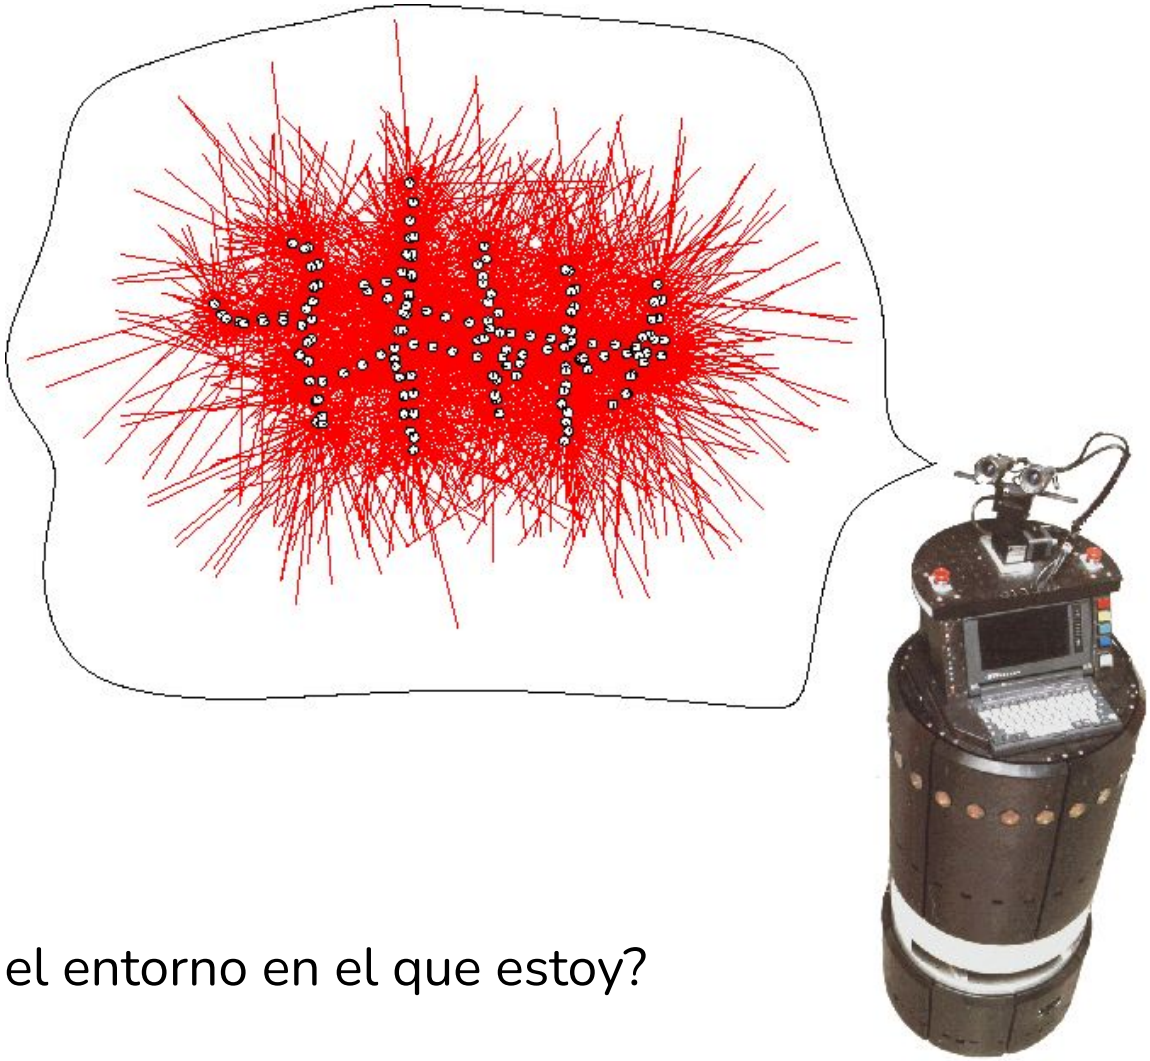

¿Cómo es el entorno en el que estoy?

El problema general del mapeo

- Formalmente, el mapa implica que, dados los **datos**

$$d = \{u_1, z_1, u_2, z_2, \ldots, u_t, z_t\}$$

- Se desea calcular el mapa más probable

$$m^\star = \mathrm{argmax}_m P(m \mid d)$$

El problema general del mapeo

- Formalmente, el mapa implica que, dados los **datos**

$$d = \{u_1, z_1, u_2, z_2, \ldots, u_t, z_t\}$$

- Se desea calcular el mapa más probable

$$m^\star = \mathrm{argmax}_m P(m \mid d)$$

- Describiremos primero cómo **calcular un mapa dadas las poses del robot**

El problema general del mapeo con poses conocidas

- Formalmente, implica que dadas las **mediciones y las poses**

$$d = \{x_1, z_1, x_2, z_2, \ldots, x_t, z_t\}$$

- Se desea calcular el mapa más probable

$$m^\star = \mathrm{argmax}_m P(m \mid d)$$

Features vs. Mapas Volumétricos

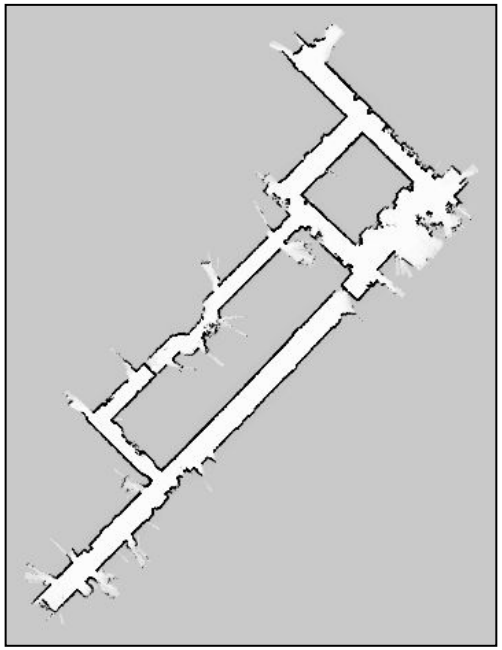

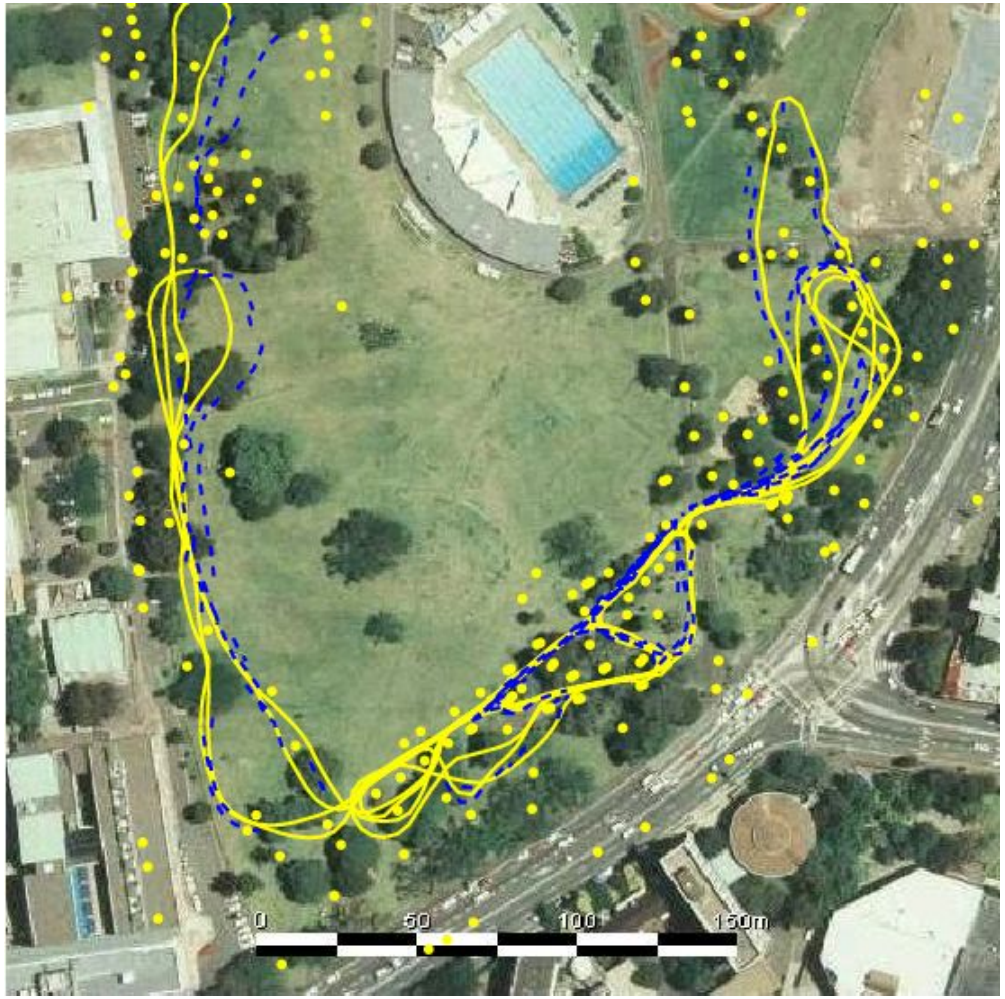

Cortesía de Eduardo Nebot

Mapa de grilla

- Discretizamos el mundo en **celdas**
- La **estructura** de grilla es rígida
- Cada celda puede estar **ocupada o libre**
- Es un modelo no-paramétrico
- Requiere considerable memoria de almacenamiento

Ejemplo

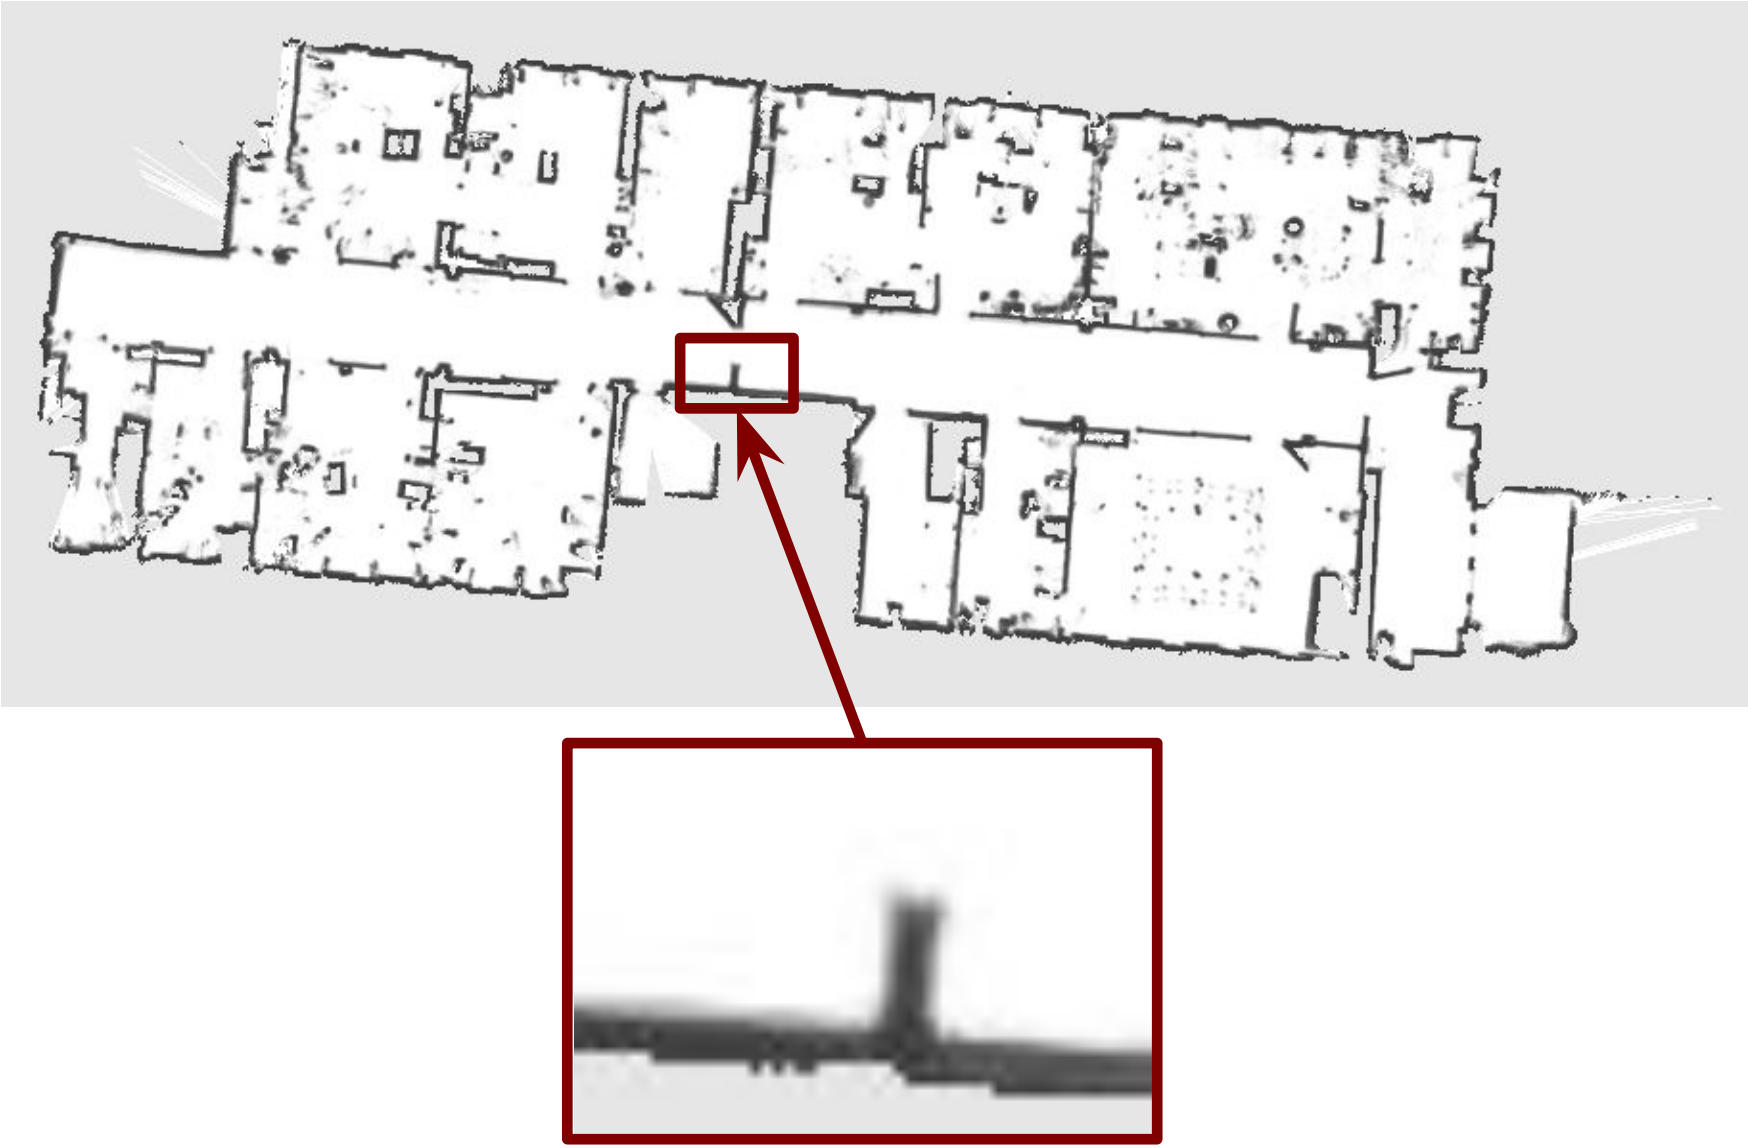

Representación del mapa

- Suposiciones para simplificar el problema

Suposición 1

- El área que corresponde a una celda está o completamente libre u ocupada

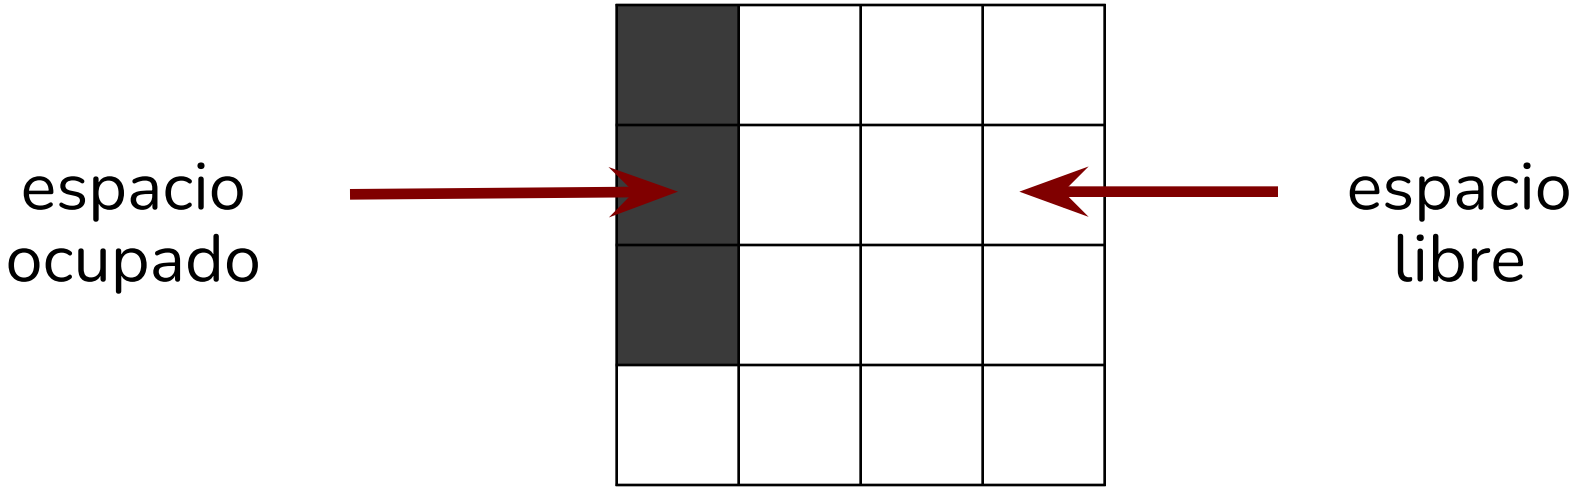

Representación

- Cada celda es una **variable aleatoria binaria** que modela la ocupación

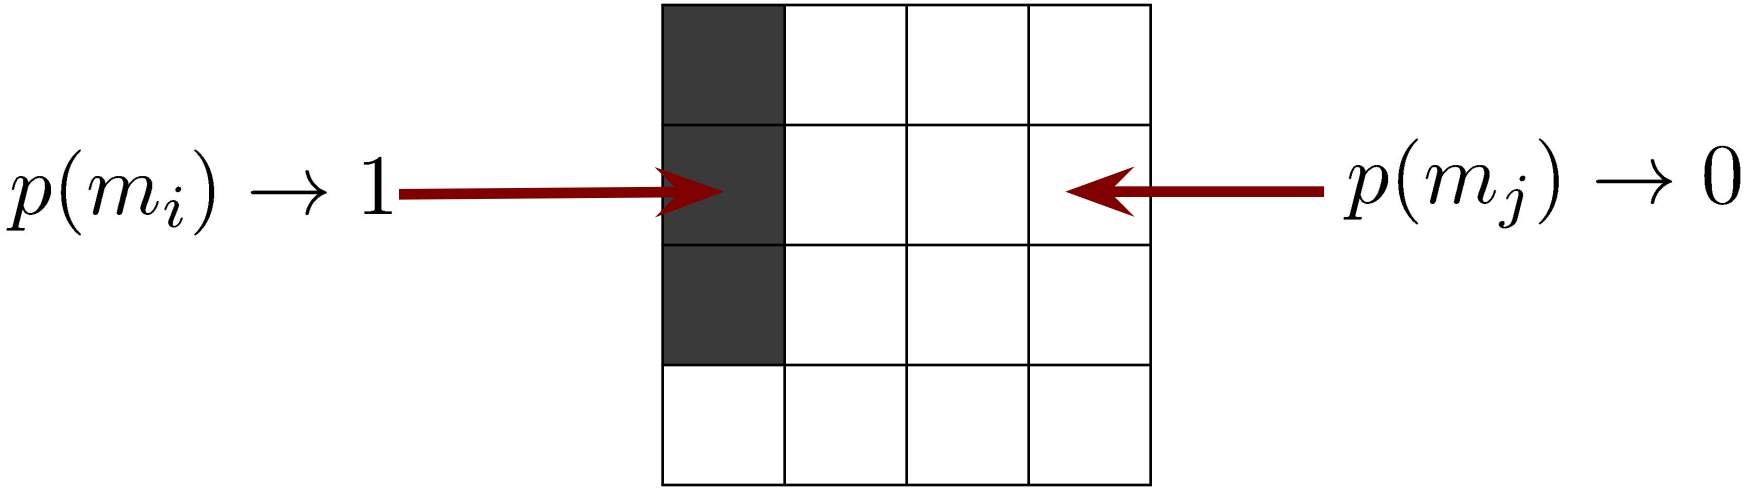

Probabilidad de ocupación

- Cada celda es una **variable aleatoria binaria** que modela la ocupación

- Celda ocupada $p(m_i) = 1$

- Celda no ocupada $p(m_i) = 0$

- Sin información $p(m_i) = 0.5$

- El entorno se asume **estático**

Suposición 2

- Las celdas (las variables aleatorias) son **independientes** unas de otras

No hay dependencia entre celdas

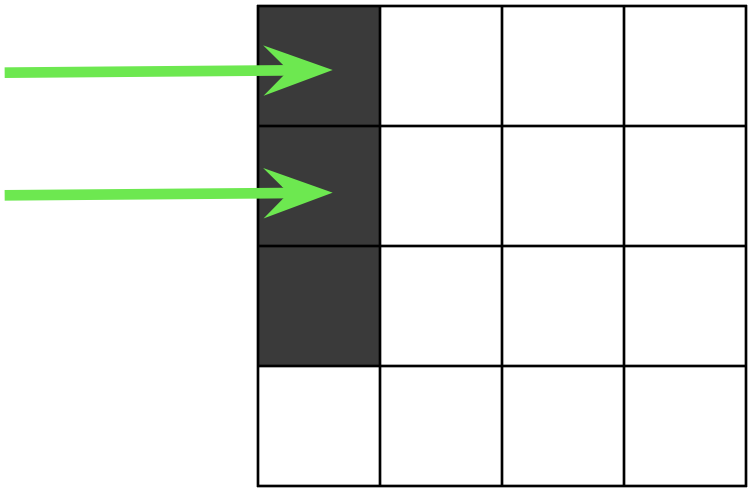

Representación

- La distribución de probabilidad del mapa está dada por el **producto de las distribuciones** de probabilidad de las celdas individuales

$$p(m) = \prod_i p(m_i)$$

mapa

celda

Representación

- La distribución de probabilidad del mapa está dada por el **producto de las distribuciones** de probabilidad de las celdas individuales

$$p(m) = \prod_i p(m_i)$$

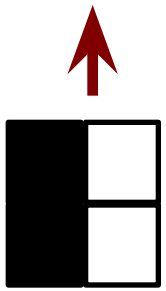

vector de 2x2

4 celdas independientes

Estimación de un mapa a partir de datos

- Dados los datos de un sensor $z_{1:t}$ y las poses del sensor $x_{1:t}$ estimar el mapa

$$p(m \mid z_{1:t}, x_{1:t}) \quad = \quad \prod_i p(m_i \mid z_{1:t}, x_{1:t})$$

Variable aleatoria binaria

Filtro de Bayes Binario
(para un estado estático)

Estimación de un mapa a partir de datos

$$p(m \mid z_{1:t}, x_{1:t}) \quad = \quad \prod_i p(m_i \mid z_{1:t}, x_{1:t})$$

Debo resolver esto

$$p(m_i \mid z_{1:t}, x_{1:t})$$

Filtro de Bayes Binario de estado estático

$$p(m_i \mid z_{1:t}, x_{1:t}) \overset{\text{Bayes rule}}{=} \frac{p(z_t \mid m_i, z_{1:t-1}, x_{1:t})\, p(m_i \mid z_{1:t-1}, x_{1:t})}{p(z_t \mid z_{1:t-1}, x_{1:t})}$$

Filtro de Bayes Binario de estado estático

$$p(m_i \mid z_{1:t}, x_{1:t}) \overset{\text{Bayes rule}}{=} \frac{p(z_t \mid m_i, z_{1:t-1}, x_{1:t})\, p(m_i \mid z_{1:t-1}, x_{1:t})}{p(z_t \mid z_{1:t-1}, x_{1:t})}$$

$$\overset{\text{Markov}}{=} \frac{p(z_t \mid m_i, x_t)\, p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(z_t \mid z_{1:t-1}, x_{1:t})}$$

Filtro de Bayes Binario de estado estático

$$p(m_i \mid z_{1:t}, x_{1:t}) \overset{\text{Bayes rule}}{=} \frac{p(z_t \mid m_i, z_{1:t-1}, x_{1:t})\, p(m_i \mid z_{1:t-1}, x_{1:t})}{p(z_t \mid z_{1:t-1}, x_{1:t})}$$

$$\overset{\text{Markov}}{=} \frac{p(z_t \mid m_i, x_t)\, p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(z_t \mid z_{1:t-1}, x_{1:t})}$$

$$p(z_t \mid m_i, x_t) \overset{\text{Bayes rule}}{=} \frac{p(m_i \mid z_t, x_t)\, p(z_t \mid x_t)}{p(m_i \mid x_t)}$$

Filtro de Bayes Binario de estado estático

$$
\begin{aligned}
p(m_i \mid z_{1:t}, x_{1:t}) &\overset{\text{Bayes rule}}{=} \frac{p(z_t \mid m_i, z_{1:t-1}, x_{1:t})\, p(m_i \mid z_{1:t-1}, x_{1:t})}{p(z_t \mid z_{1:t-1}, x_{1:t})} \\
&\overset{\text{Markov}}{=} \frac{p(z_t \mid m_i, x_t)\, p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(z_t \mid z_{1:t-1}, x_{1:t})} \\
&\overset{\text{Bayes rule}}{=} \frac{p(m_i \mid z_t, x_t)\, p(z_t \mid x_t)\, p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(m_i \mid x_t)\, p(z_t \mid z_{1:t-1}, x_{1:t})}
\end{aligned}
$$

Filtro de Bayes Binario de estado estático

$$
\begin{aligned}
p(m_i \mid z_{1:t}, x_{1:t}) &\overset{\text{Bayes rule}}{=} \frac{p(z_t \mid m_i, z_{1:t-1}, x_{1:t})\, p(m_i \mid z_{1:t-1}, x_{1:t})}{p(z_t \mid z_{1:t-1}, x_{1:t})} \\
&\overset{\text{Markov}}{=} \frac{p(z_t \mid m_i, x_t)\, p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(z_t \mid z_{1:t-1}, x_{1:t})} \\
&\overset{\text{Bayes rule}}{=} \frac{p(m_i \mid z_t, x_t)\, p(z_t \mid x_t)\, p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(m_i \mid x_t)\, p(z_t \mid z_{1:t-1}, x_{1:t})} \\
&\overset{\text{Markov}}{=} \frac{p(m_i \mid z_t, x_t)\, p(z_t \mid x_t)\, p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(m_i)\, p(z_t \mid z_{1:t-1}, x_{1:t})}
\end{aligned}
$$

Filtro de Bayes Binario de estado estático

$$
\begin{aligned}
p(m_i \mid z_{1:t}, x_{1:t}) &\overset{\text{Bayes rule}}{=} \frac{p(z_t \mid m_i, z_{1:t-1}, x_{1:t})\, p(m_i \mid z_{1:t-1}, x_{1:t})}{p(z_t \mid z_{1:t-1}, x_{1:t})} \\
&\overset{\text{Markov}}{=} \frac{p(z_t \mid m_i, x_t)\, p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(z_t \mid z_{1:t-1}, x_{1:t})} \\
&\overset{\text{Bayes rule}}{=} \frac{p(m_i \mid z_t, x_t)\, p(z_t \mid x_t)\, p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(m_i \mid x_t)\, p(z_t \mid z_{1:t-1}, x_{1:t})} \\
&\overset{\text{Markov}}{=} \frac{p(m_i \mid z_t, x_t)\, p(z_t \mid x_t)\, p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(m_i)\, p(z_t \mid z_{1:t-1}, x_{1:t})}
\end{aligned}
$$

Luego lo mismo para el evento opuesto:

$$
p(\neg m_i \mid z_{1:t}, x_{1:t}) \overset{\text{the same}}{=} \frac{p(\neg m_i \mid z_t, x_t)\, p(z_t \mid x_t)\, p(\neg m_i \mid z_{1:t-1}, x_{1:t-1})}{p(\neg m_i)\, p(z_t \mid z_{1:t-1}, x_{1:t})}
$$

Filtro de Bayes Binario de estado estático

- Del cociente de ambas probabilidades, obtenemos:

$$\frac{p(m_i \mid z_{1:t}, x_{1:t})}{p(\neg m_i \mid z_{1:t}, x_{1:t})} = \frac{\dfrac{p(m_i|z_t,x_t)\,\cancel{p(z_t|x_t)}\,p(m_i|z_{1:t-1},x_{1:t-1})}{p(m_i)\,\cancel{p(z_t|z_{1:t-1},x_{1:t})}}}{\dfrac{p(\neg m_i|z_t,x_t)\,\cancel{p(z_t|x_t)}\,p(\neg m_i|z_{1:t-1},x_{1:t-1})}{p(\neg m_i)\,\cancel{p(z_t|z_{1:t-1},x_{1:t})}}}$$

$$\frac{p(m_i \mid z_{1:t}, x_{1:t})}{p(\neg m_i \mid z_{1:t}, x_{1:t})} = \frac{p(m_i \mid z_t, x_t)\, p(m_i \mid z_{1:t-1}, x_{1:t-1})\, p(\neg m_i)}{p(\neg m_i \mid z_t, x_t)\, p(\neg m_i \mid z_{1:t-1}, x_{1:t-1})\, p(m_i)}$$

Filtro de Bayes Binario de estado estático

- Del cociente de ambas probabilidades, obtenemos:

$$
\begin{aligned}
&\frac{p(m_i \mid z_{1:t}, x_{1:t})}{p(\neg m_i \mid z_{1:t}, x_{1:t})} \\
&= \frac{p(m_i \mid z_t, x_t)\, p(m_i \mid z_{1:t-1}, x_{1:t-1})\, p(\neg m_i)}{p(\neg m_i \mid z_t, x_t)\, p(\neg m_i \mid z_{1:t-1}, x_{1:t-1})\, p(m_i)} \\
&= \frac{p(m_i \mid z_t, x_t)}{1 - p(m_i \mid z_t, x_t)} \frac{p(m_i \mid z_{1:t-1}, x_{1:t-1})}{1 - p(m_i \mid z_{1:t-1}, x_{1:t-1})} \frac{1 - p(m_i)}{p(m_i)}
\end{aligned}
$$

Filtro de Bayes Binario de estado estático

- Del cociente de ambas probabilidades, obtenemos:

$$
\begin{aligned}
&\frac{p(m_i \mid z_{1:t}, x_{1:t})}{1 - p(m_i \mid z_{1:t}, x_{1:t})} \\
&= \frac{p(m_i \mid z_t, x_t)\, p(m_i \mid z_{1:t-1}, x_{1:t-1})\, p(\neg m_i)}{p(\neg m_i \mid z_t, x_t)\, p(\neg m_i \mid z_{1:t-1}, x_{1:t-1})\, p(m_i)} \\
&= \underbrace{\frac{p(m_i \mid z_t, x_t)}{1 - p(m_i \mid z_t, x_t)}}_{\text{uses } z_t}\ \underbrace{\frac{p(m_i \mid z_{1:t-1}, x_{1:t-1})}{1 - p(m_i \mid z_{1:t-1}, x_{1:t-1})}}_{\text{recursive term}}\ \underbrace{\frac{1 - p(m_i)}{p(m_i)}}_{\text{prior}}
\end{aligned}
$$

Regla de actualización de ocupación

- Regla recursiva

$$\frac{p(m_i \mid z_{1:t}, x_{1:t})}{1 - p(m_i \mid z_{1:t}, x_{1:t})} = \underbrace{\frac{p(m_i \mid z_t, x_t)}{1 - p(m_i \mid z_t, x_t)}}_{\text{uses } z_t} \underbrace{\frac{p(m_i \mid z_{1:t-1}, x_{1:t-1})}{1 - p(m_i \mid z_{1:t-1}, x_{1:t-1})}}_{\text{recursive term}} \underbrace{\frac{1 - p(m_i)}{p(m_i)}}_{\text{prior}}$$

Notación Log Odds

- El cociente Log Odds se define como

$$l(x) = \log \frac{p(x)}{1 - p(x)}$$

- Pudiéndose recuperar $p(x)$

$$p(x) = 1 - \frac{1}{1 + \exp l(x)}$$

Regla de actualización de ocupación

- Regla recursiva

$$\frac{p(m_i \mid z_{1:t}, x_{1:t})}{1 - p(m_i \mid z_{1:t}, x_{1:t})} = \underbrace{\frac{p(m_i \mid z_t, x_t)}{1 - p(m_i \mid z_t, x_t)}}_{\text{uses } z_t} \underbrace{\frac{p(m_i \mid z_{1:t-1}, x_{1:t-1})}{1 - p(m_i \mid z_{1:t-1}, x_{1:t-1})}}_{\text{recursive term}} \underbrace{\frac{1 - p(m_i)}{p(m_i)}}_{\text{prior}}$$

- Log Odds:

$$l(m_i \mid z_{1:t}, x_{1:t}) = \underbrace{l(m_i \mid z_t, x_t)}_{\text{inverse sensor model}} + \underbrace{l(m_i \mid z_{1:t-1}, x_{1:t-1})}_{\text{recursive term}} - \underbrace{l(m_i)}_{\text{prior}}$$

Mapas de ocupación en términos Log Odds

- El producto se hace suma

$$
\begin{aligned}
& l(m_i \mid z_{1:t}, x_{1:t}) \\
= \quad & \underbrace{l(m_i \mid z_t, x_t)}_{\text{inverse sensor model}} + \underbrace{l(m_i \mid z_{1:t-1}, x_{1:t-1})}_{\text{recursive term}} - \underbrace{l(m_i)}_{\text{prior}}
\end{aligned}
$$

- Que puede escribirse como

$$
l_{t,i} \quad = \quad \text{inv_sensor_model}(m_i, x_t, z_t) + l_{t-1,i} - l_0
$$

Algoritmo de mapa de Ocupación

occupancy_grid_mapping$(\{l_{t-1,i}\}, x_t, z_t)$**:**

for all cells m_i *do*
  if m_i *in perceptual field of* z_t *then*
    $l_{t,i} = l_{t-1,i} + \text{inv_sensor_model}(m_i, x_t, z_t) - l_0$
  else
    $l_{t,i} = l_{t-1,i}$
  endif
endfor
return $\{l_{t,i}\}$

Muy eficiente, solo requiere calcular sumas

Mapas de grillas de ocupación

- Desarrollado a mediados de los 80's por Moravec y Elfes
- Originalmente hecho para ultrasonidos muy ruidosos
- También llamado "mapeo con poses conocidas"

Modelo inverso de sensor para Sonar (distancia)

$$l(m_i \mid z_t, x_t) \quad = \quad \text{inv_sensor_model}(m_i, x_t, z_t)$$

Modelo inverso de sensor para Sonar (distancia)

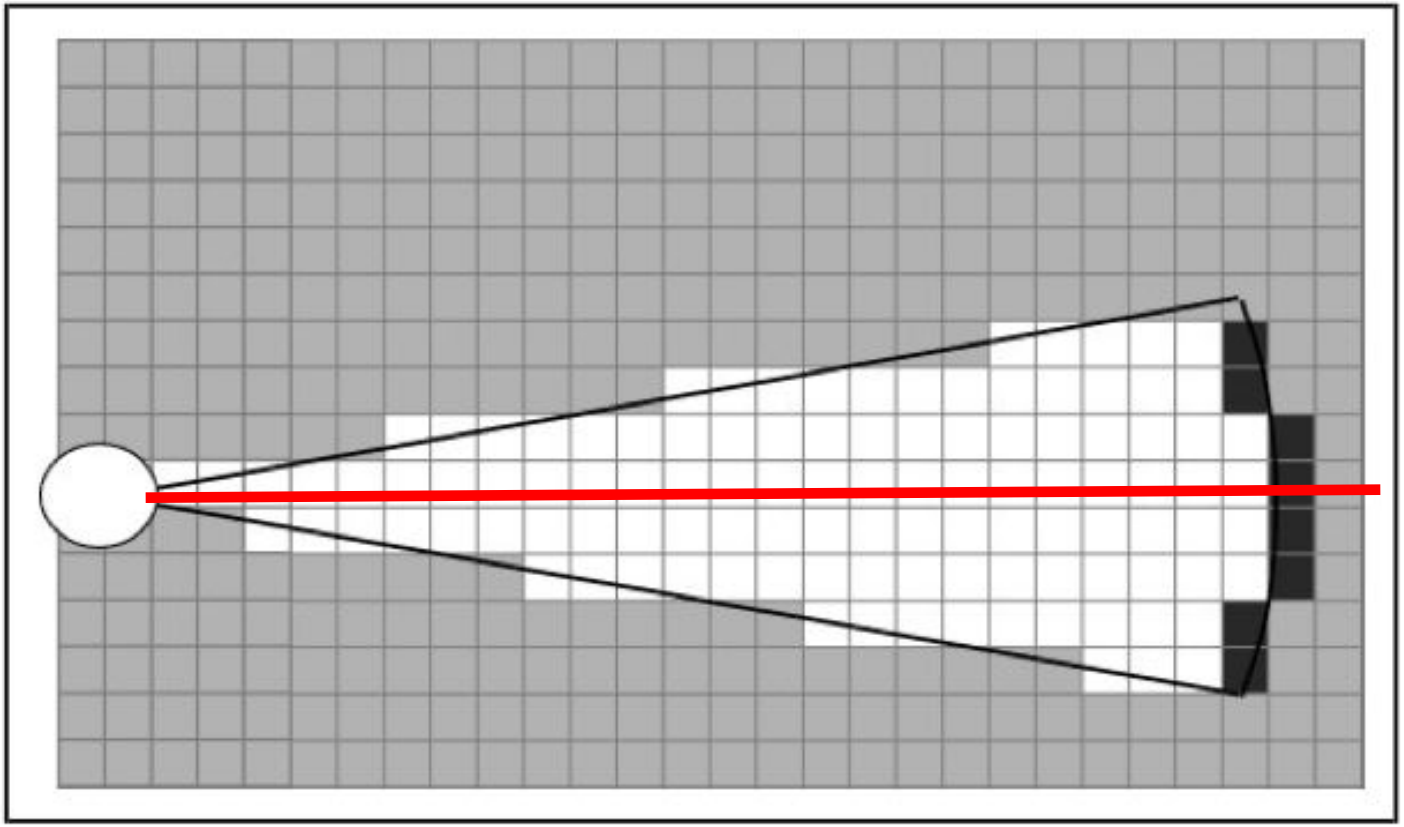

Consideramos las celdas sobre el eje óptico (línea roja)

Valor de ocupación según la distancia medida

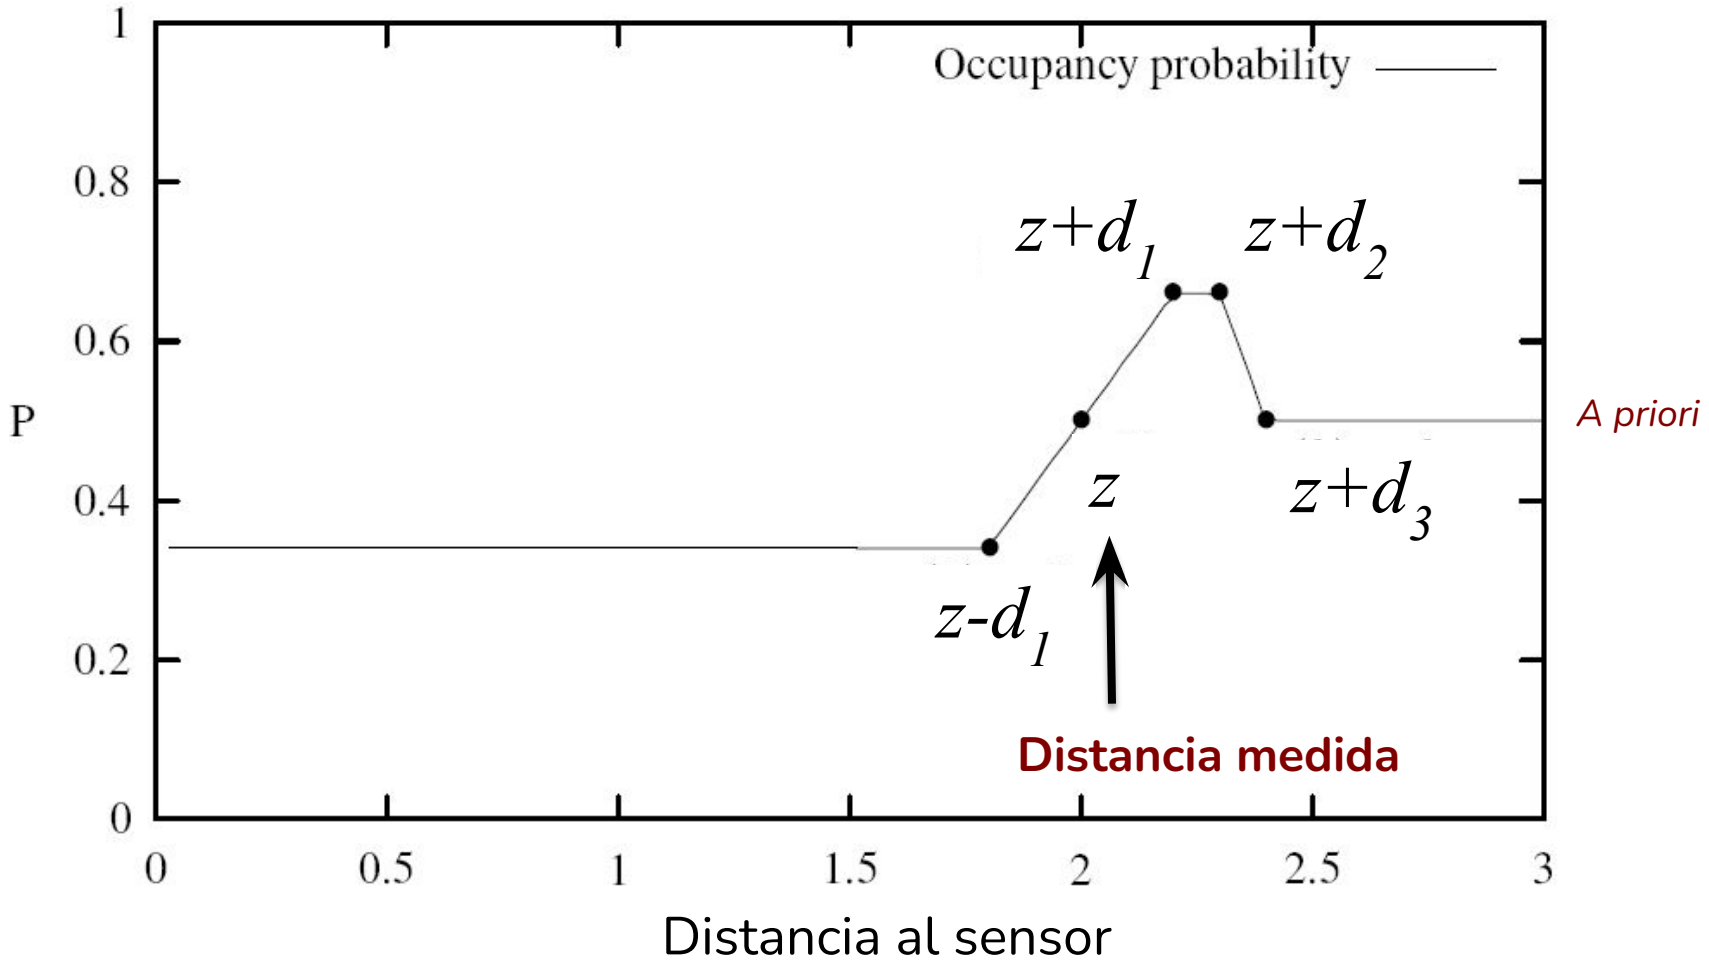

Valor de ocupación según la distancia medida

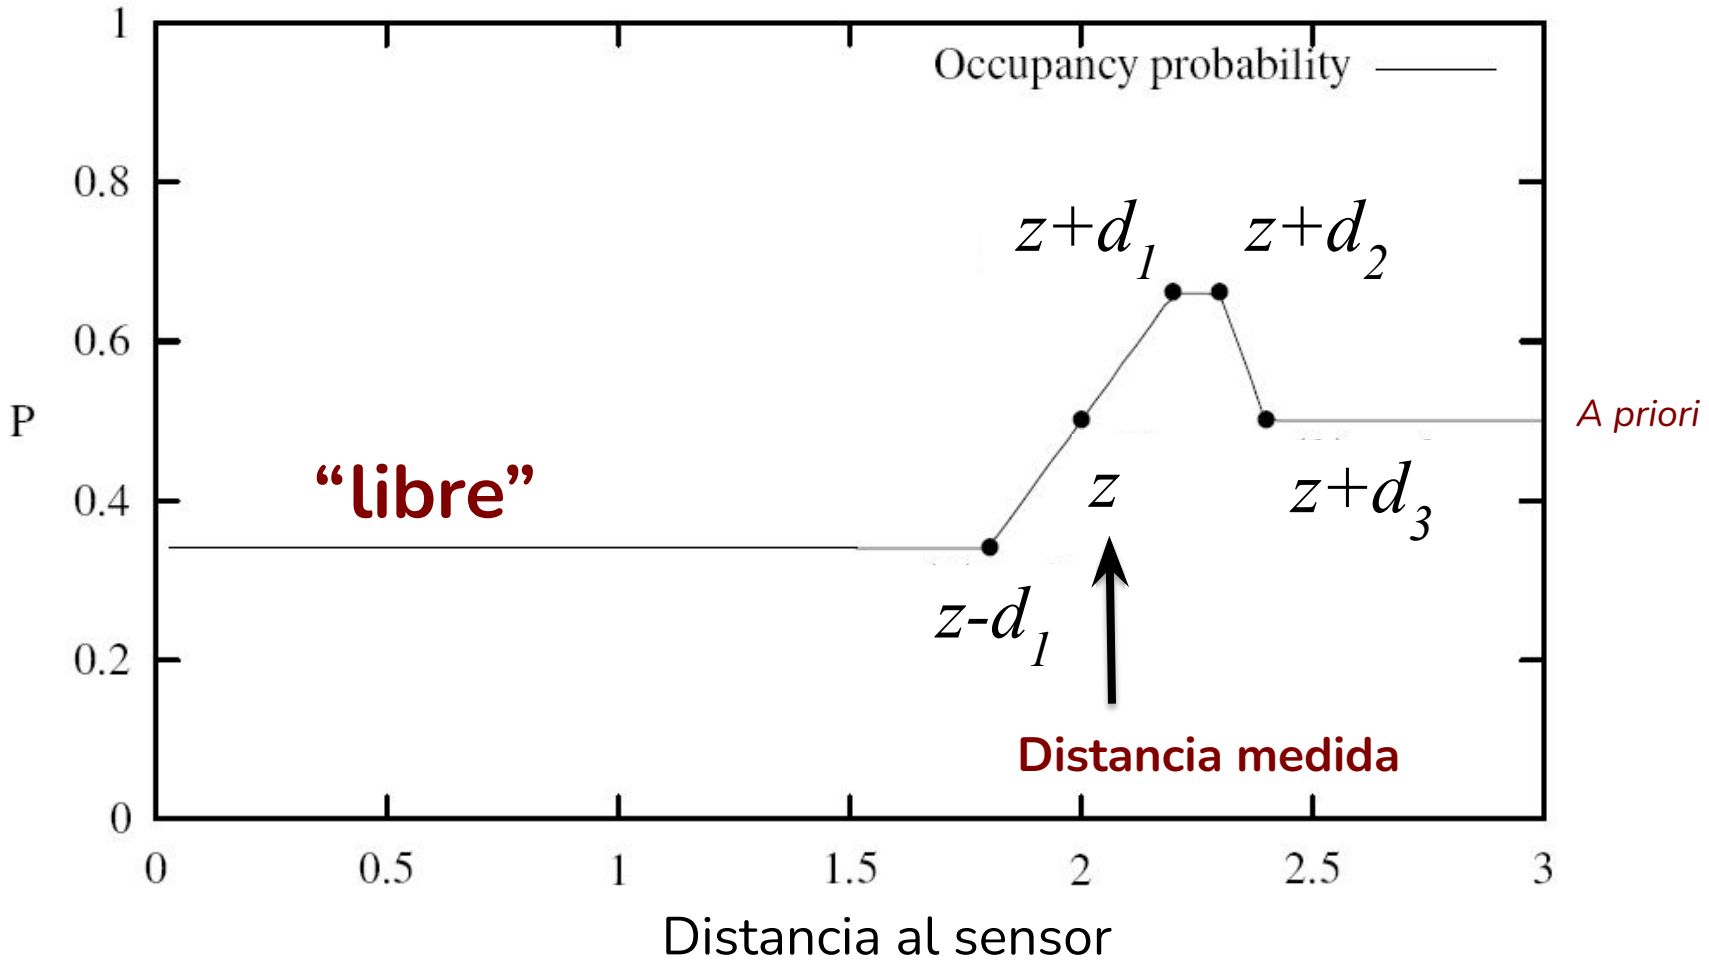

Valor de ocupación según la distancia medida

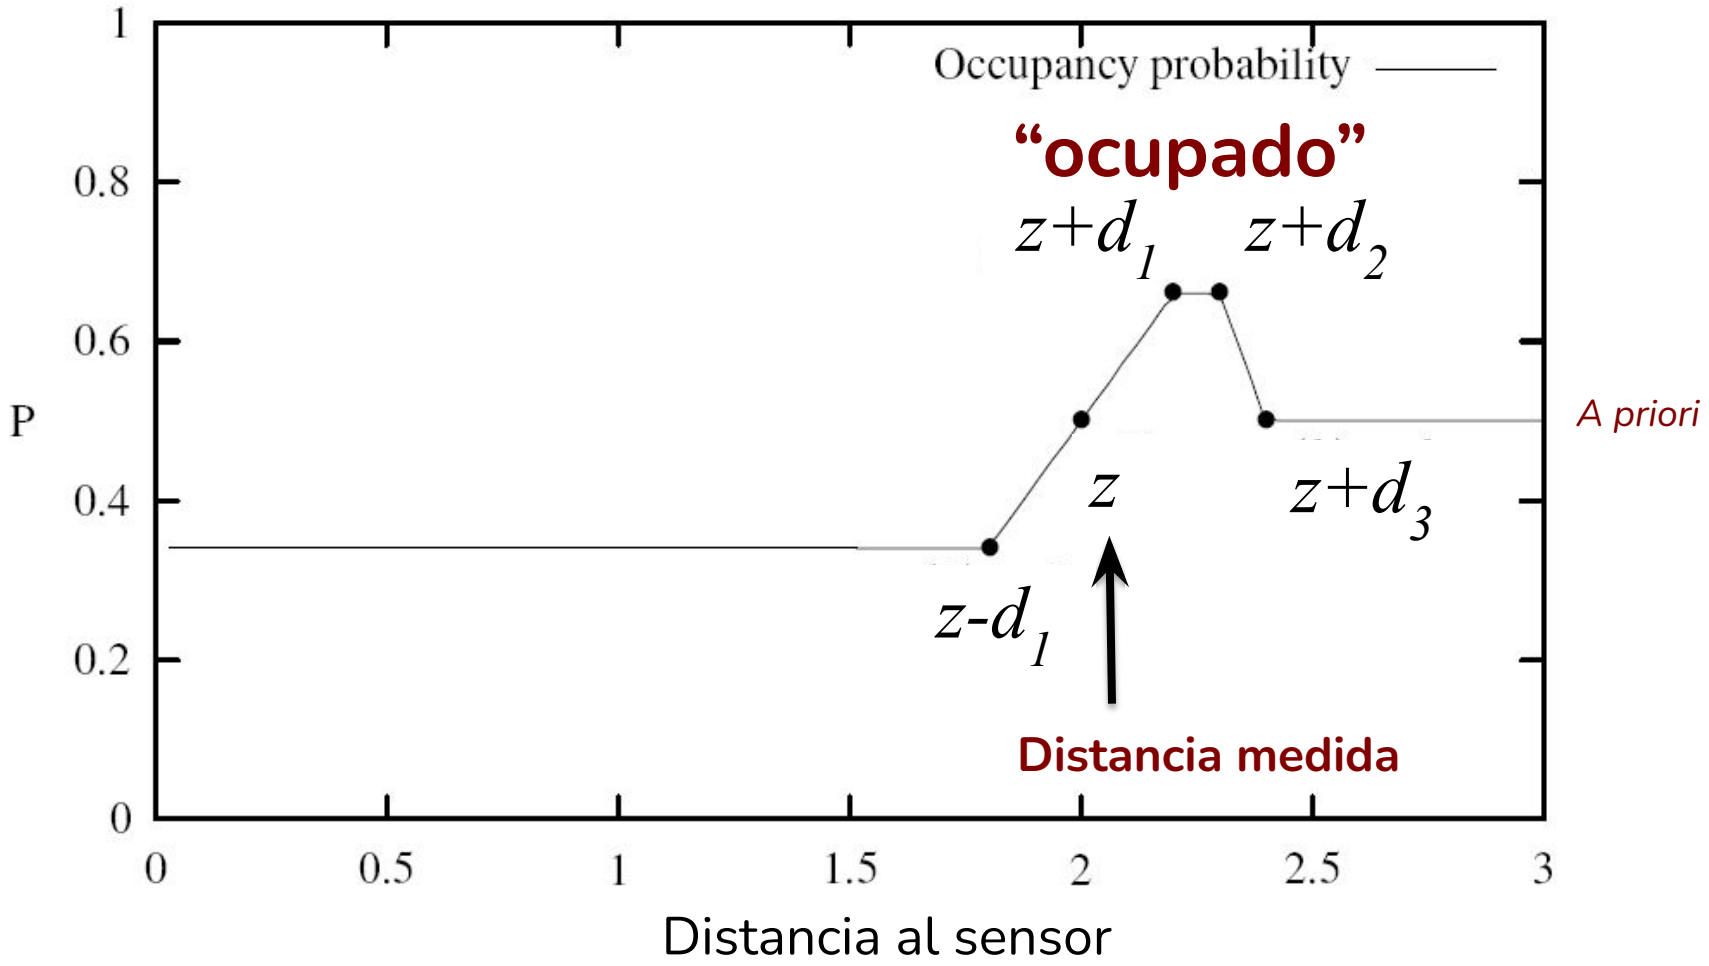

Valor de ocupación según la distancia medida

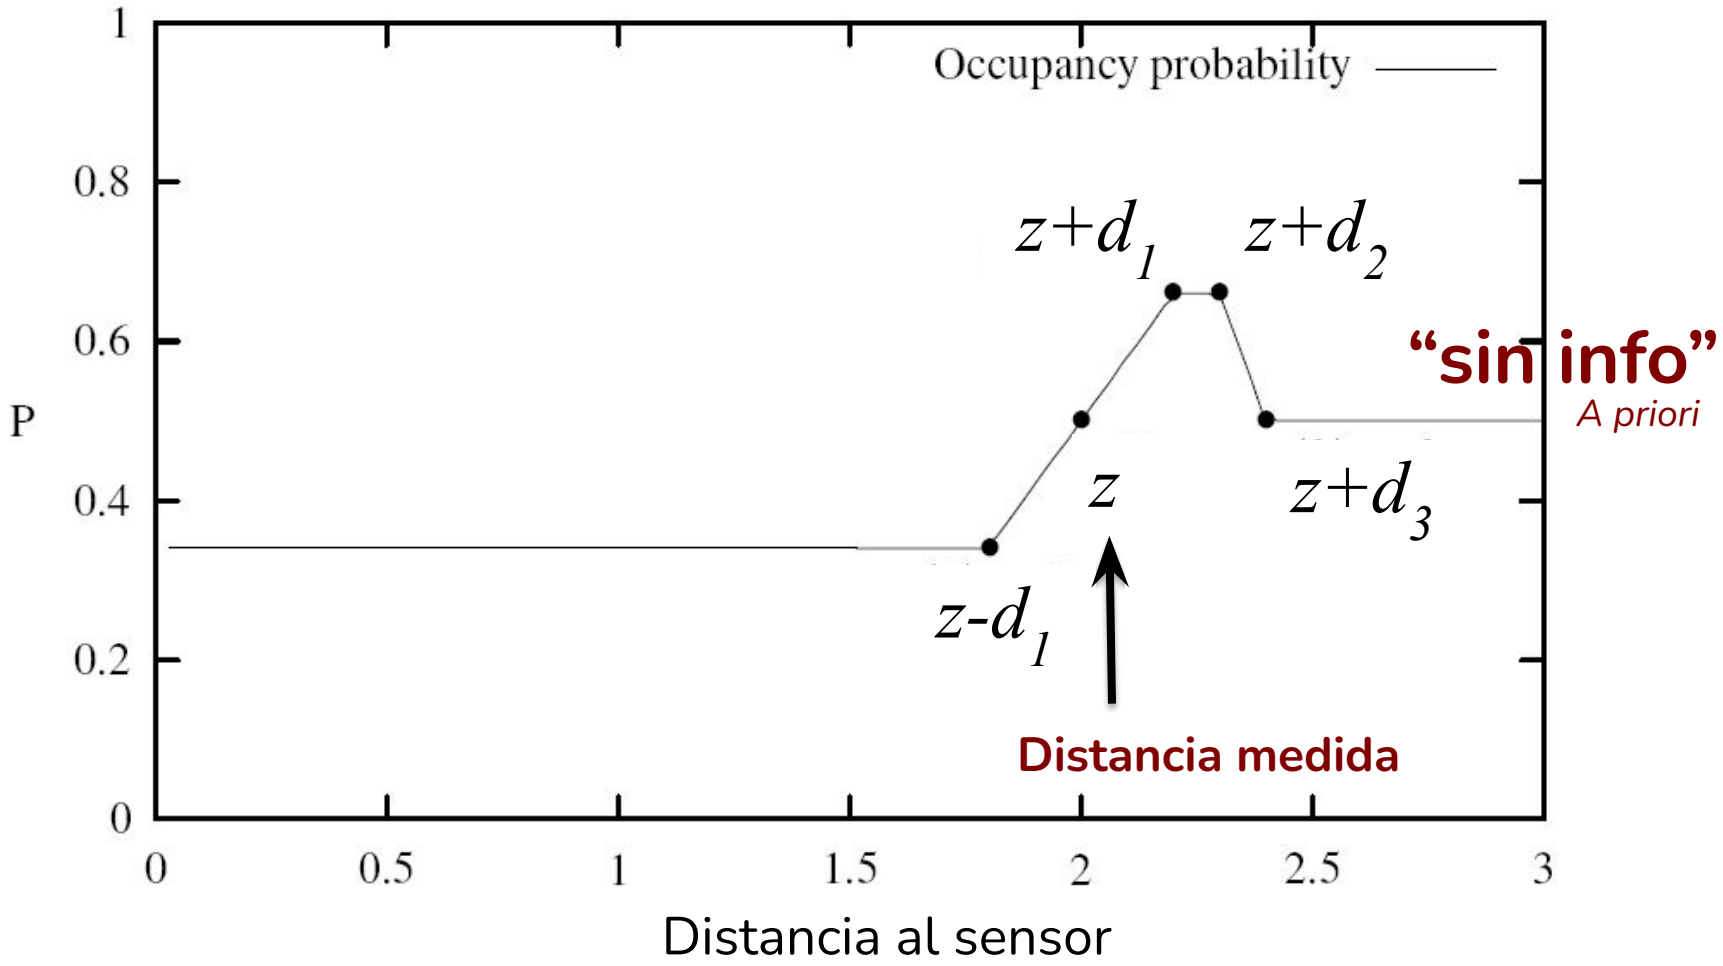

Dependencia con el ángulo de desvío del eje óptico y la distancia

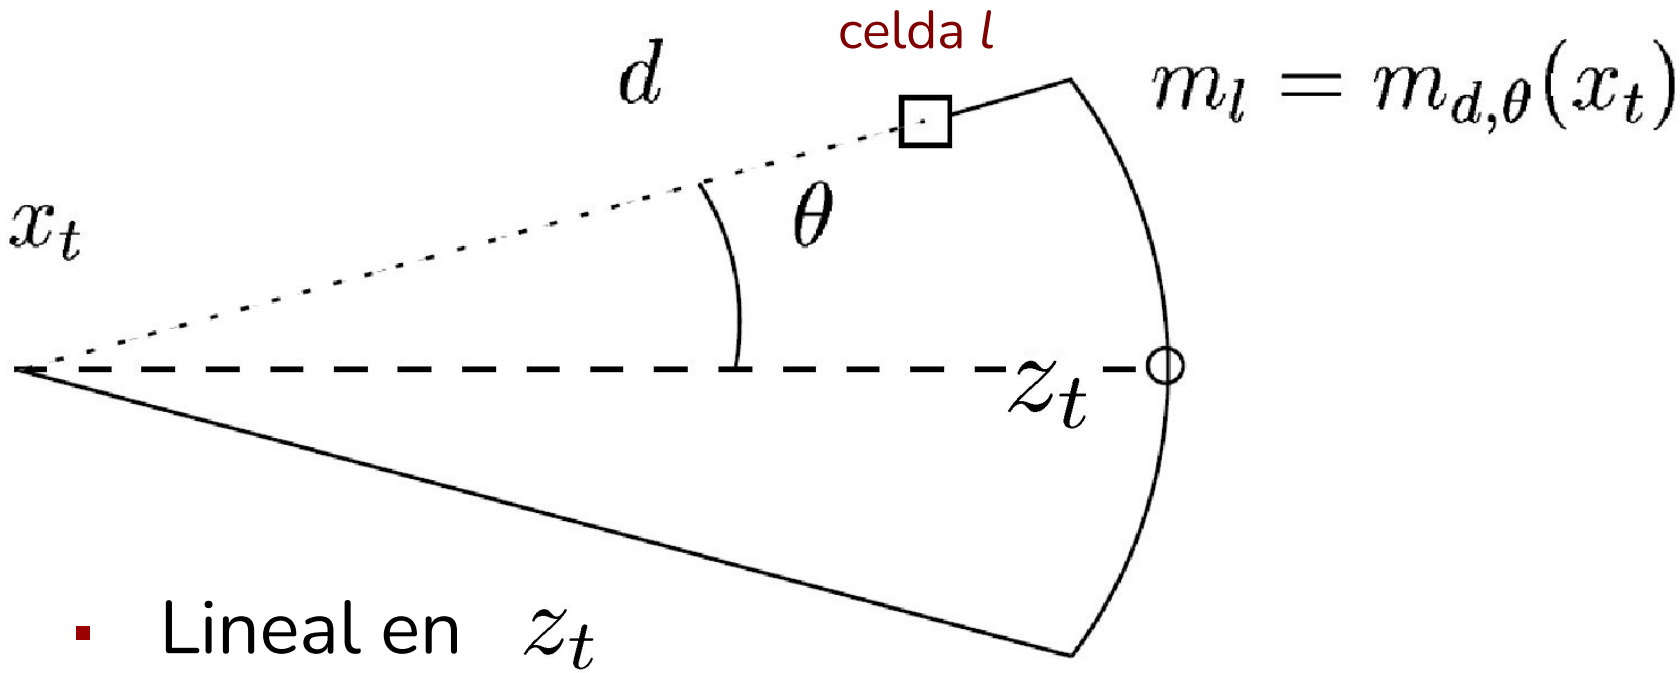

- Lineal en z_t
- Gaussiana en θ

Intensidad de lectura

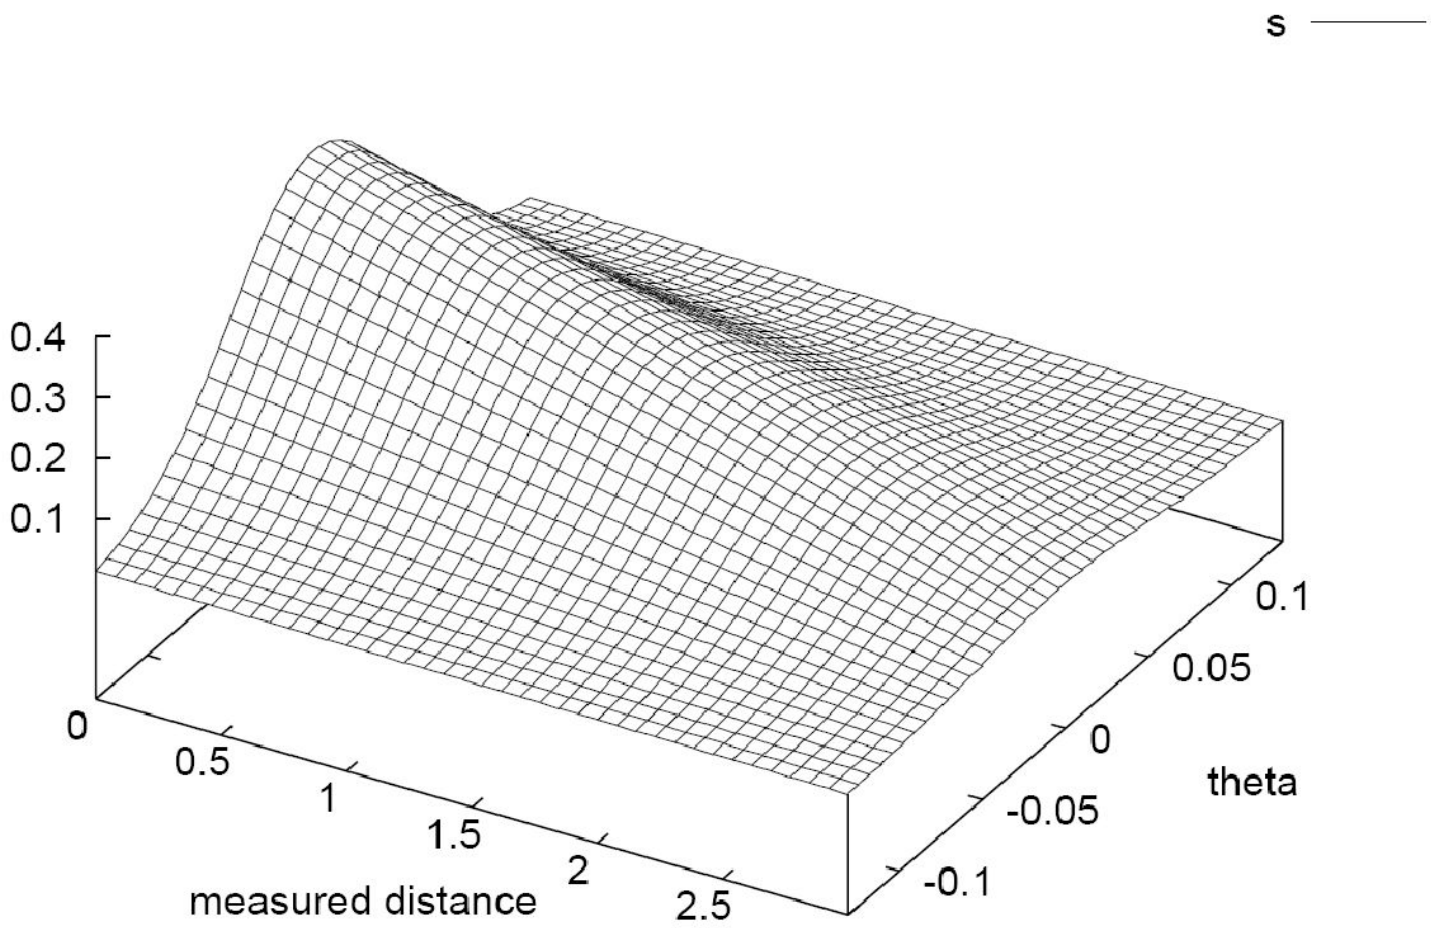

Modelo resultante $p(m_i \mid z_t, x_t)$

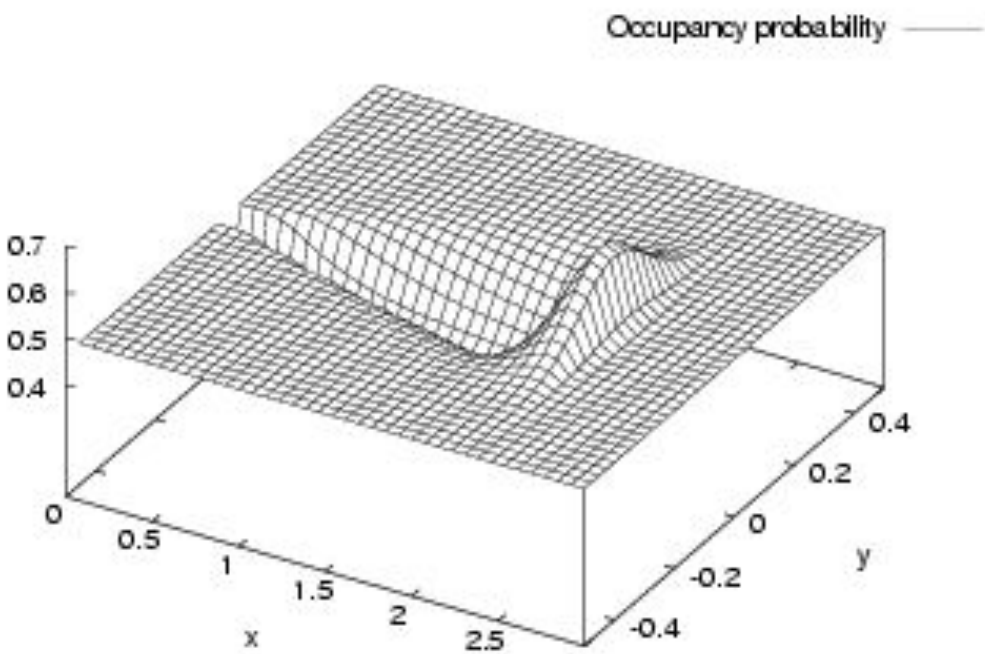

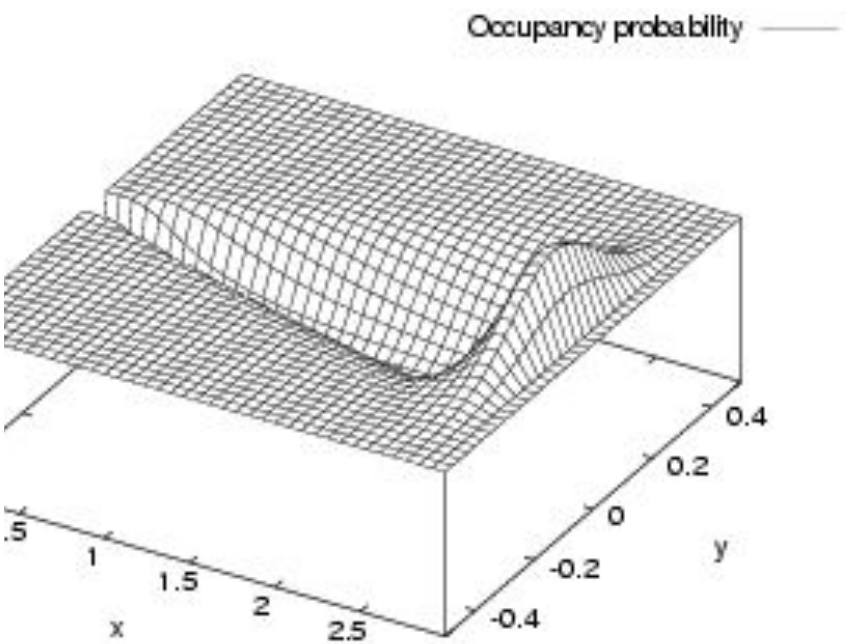

Ejemplo: Actualización incremental de grillas de ocupación

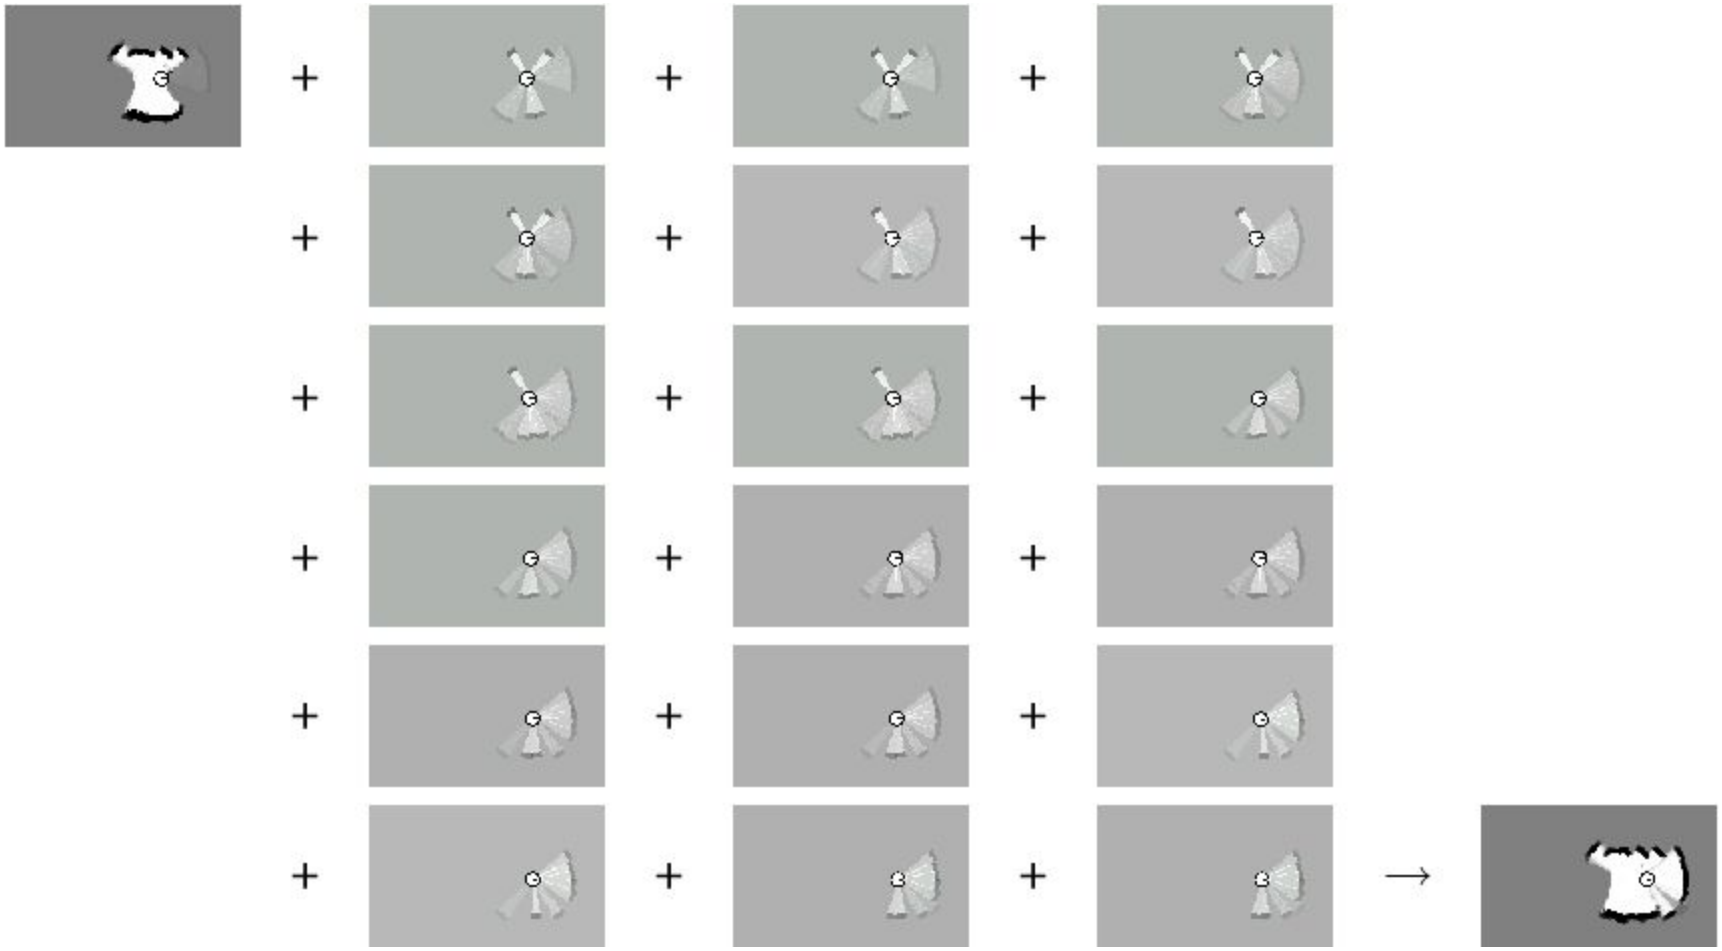

Mapa resultante con sensores de ultrasonido

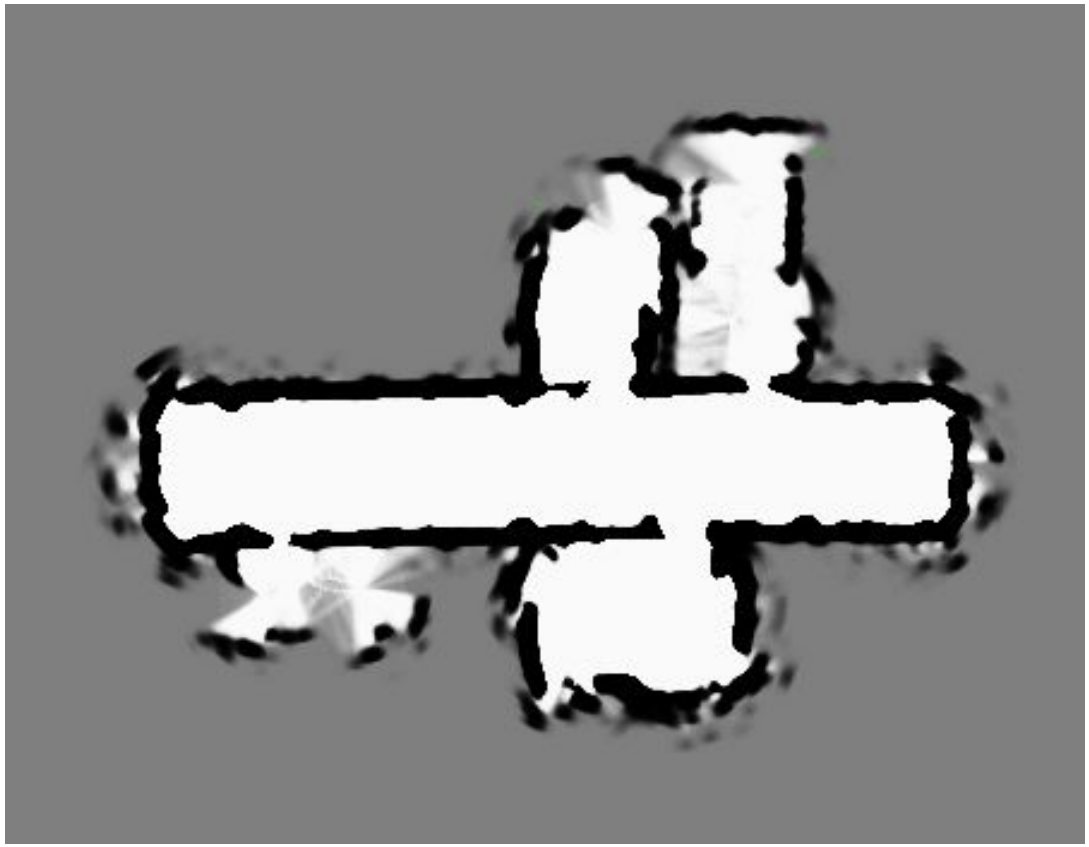

Ocupación y mapa de Maximum Likelihood

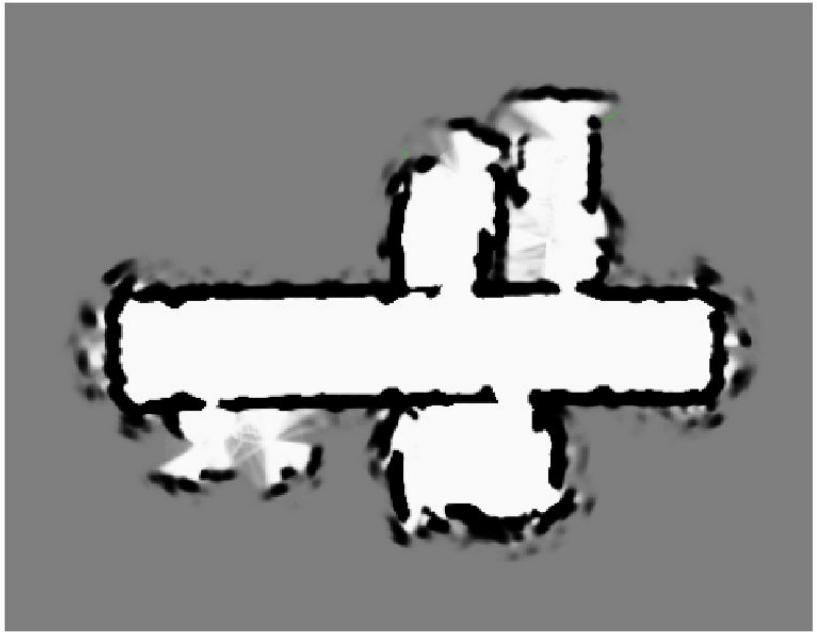

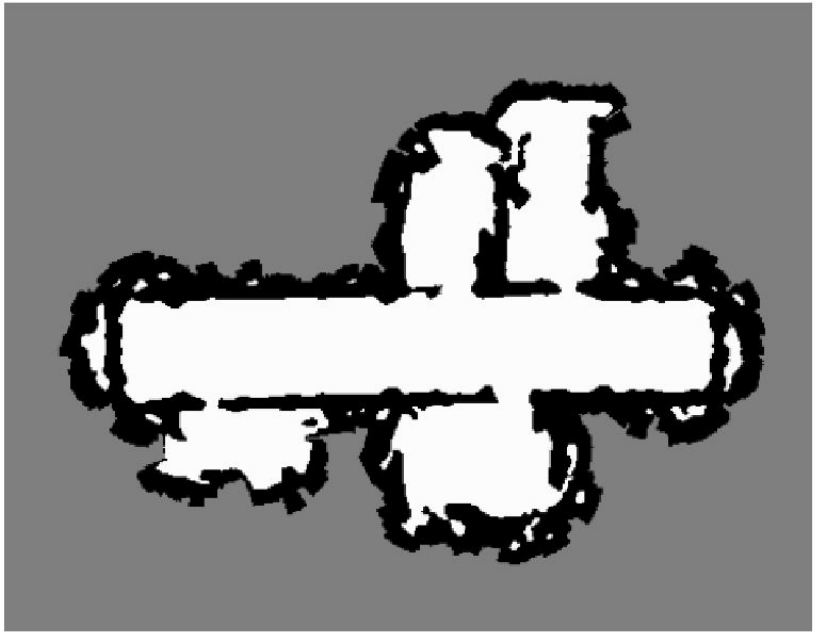

El mapa de maximum likelihood se obtiene redondeando las probabilidades de cada celda a 0 o 1.

Modelo inverso de sensor para Laser Range Finders (LIDAR)

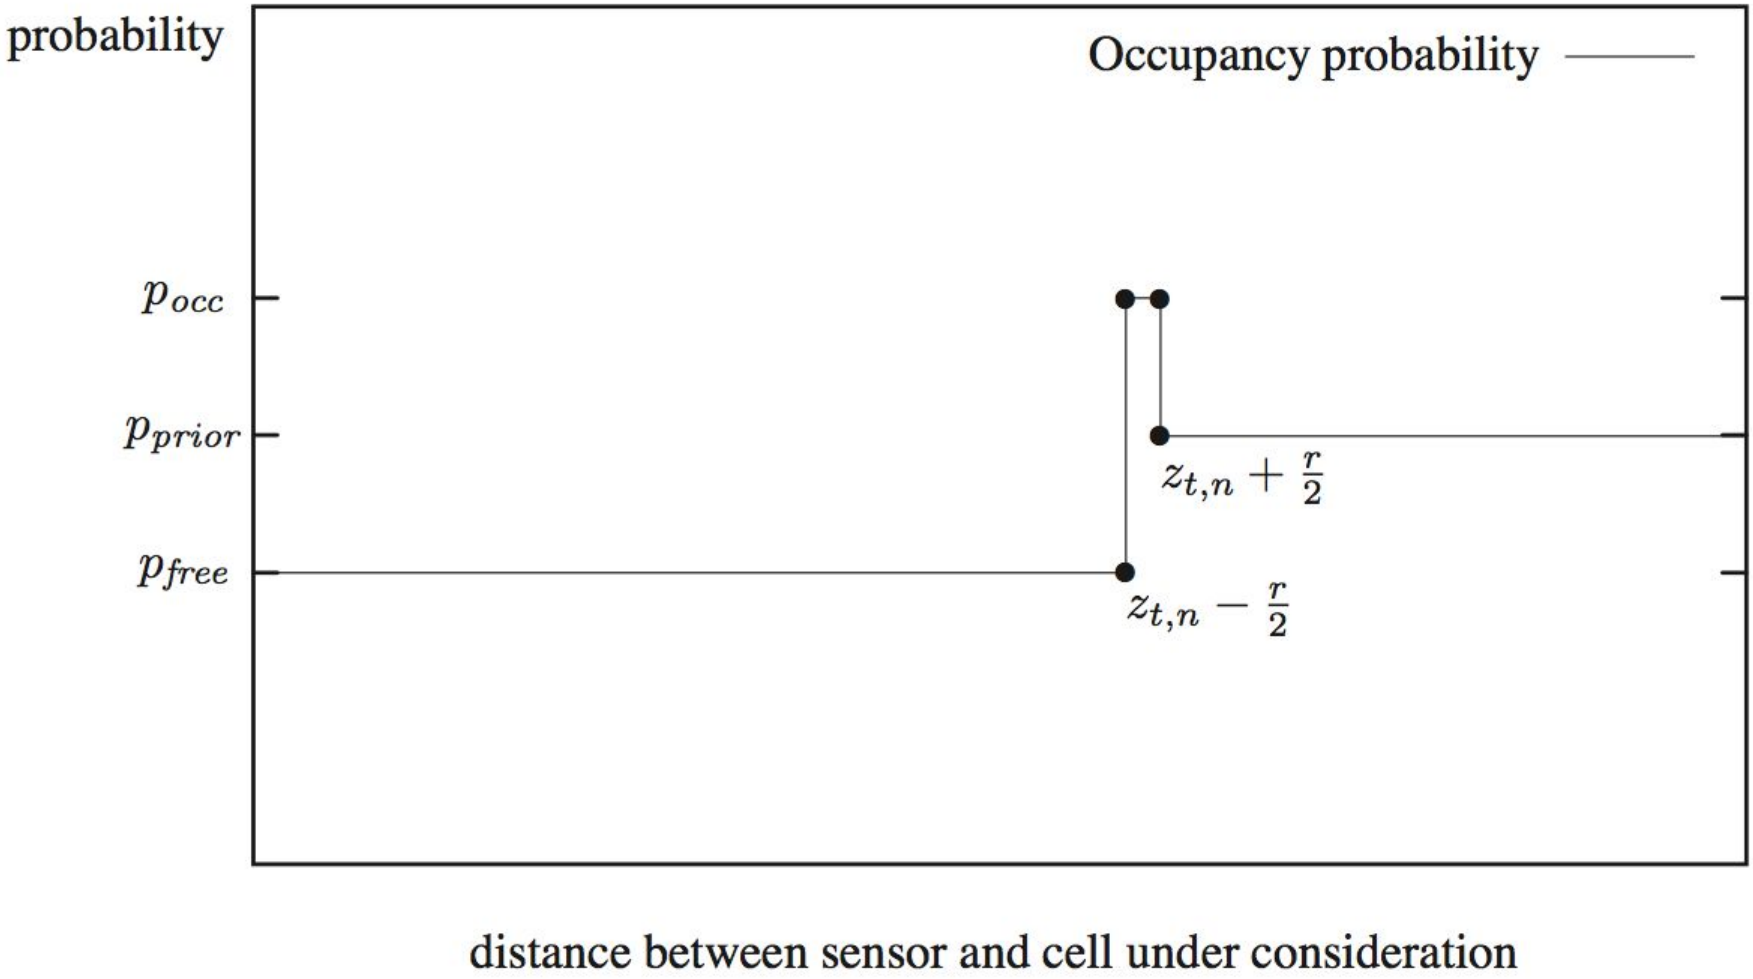

Grilla de ocupación y mapa para LIDARs

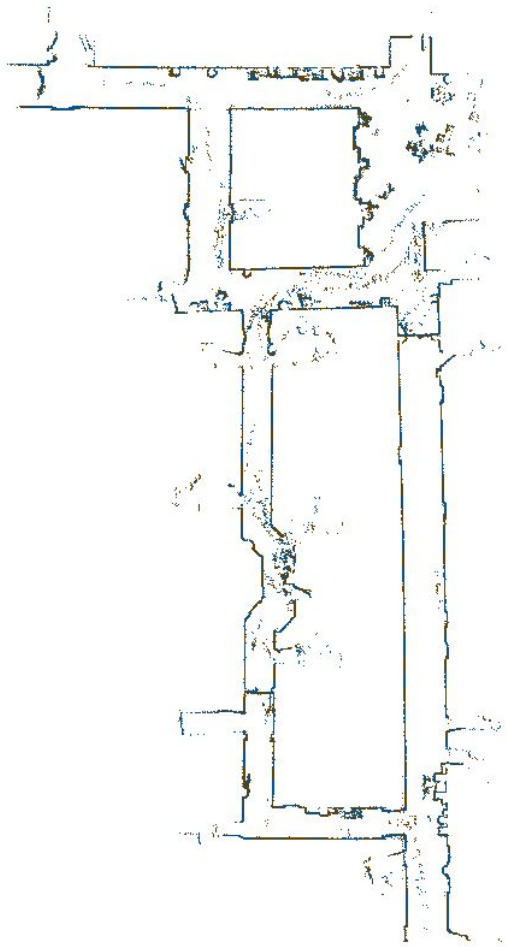

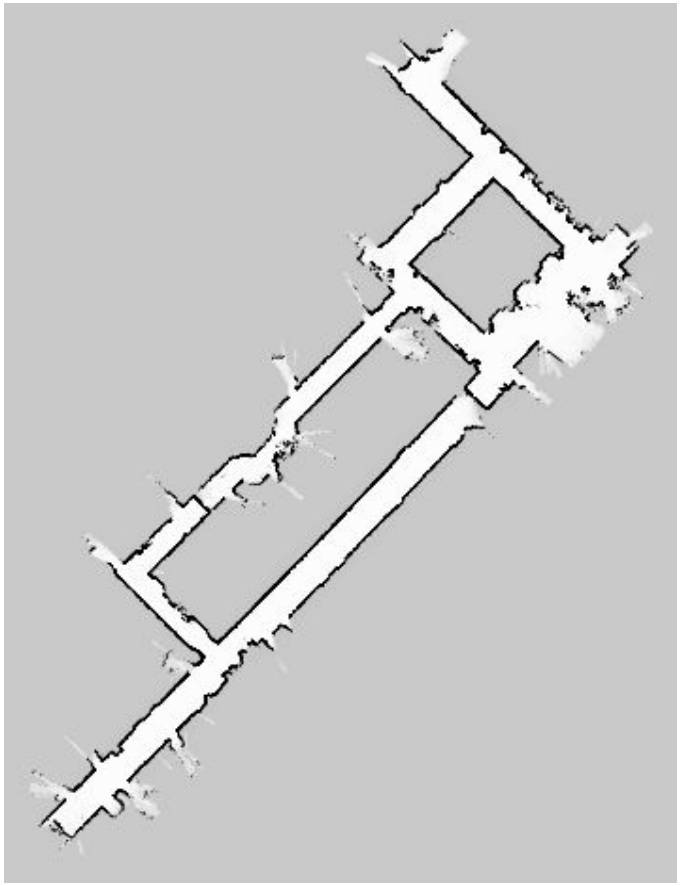

Ejemplo: MIT CSAIL, 3er Piso

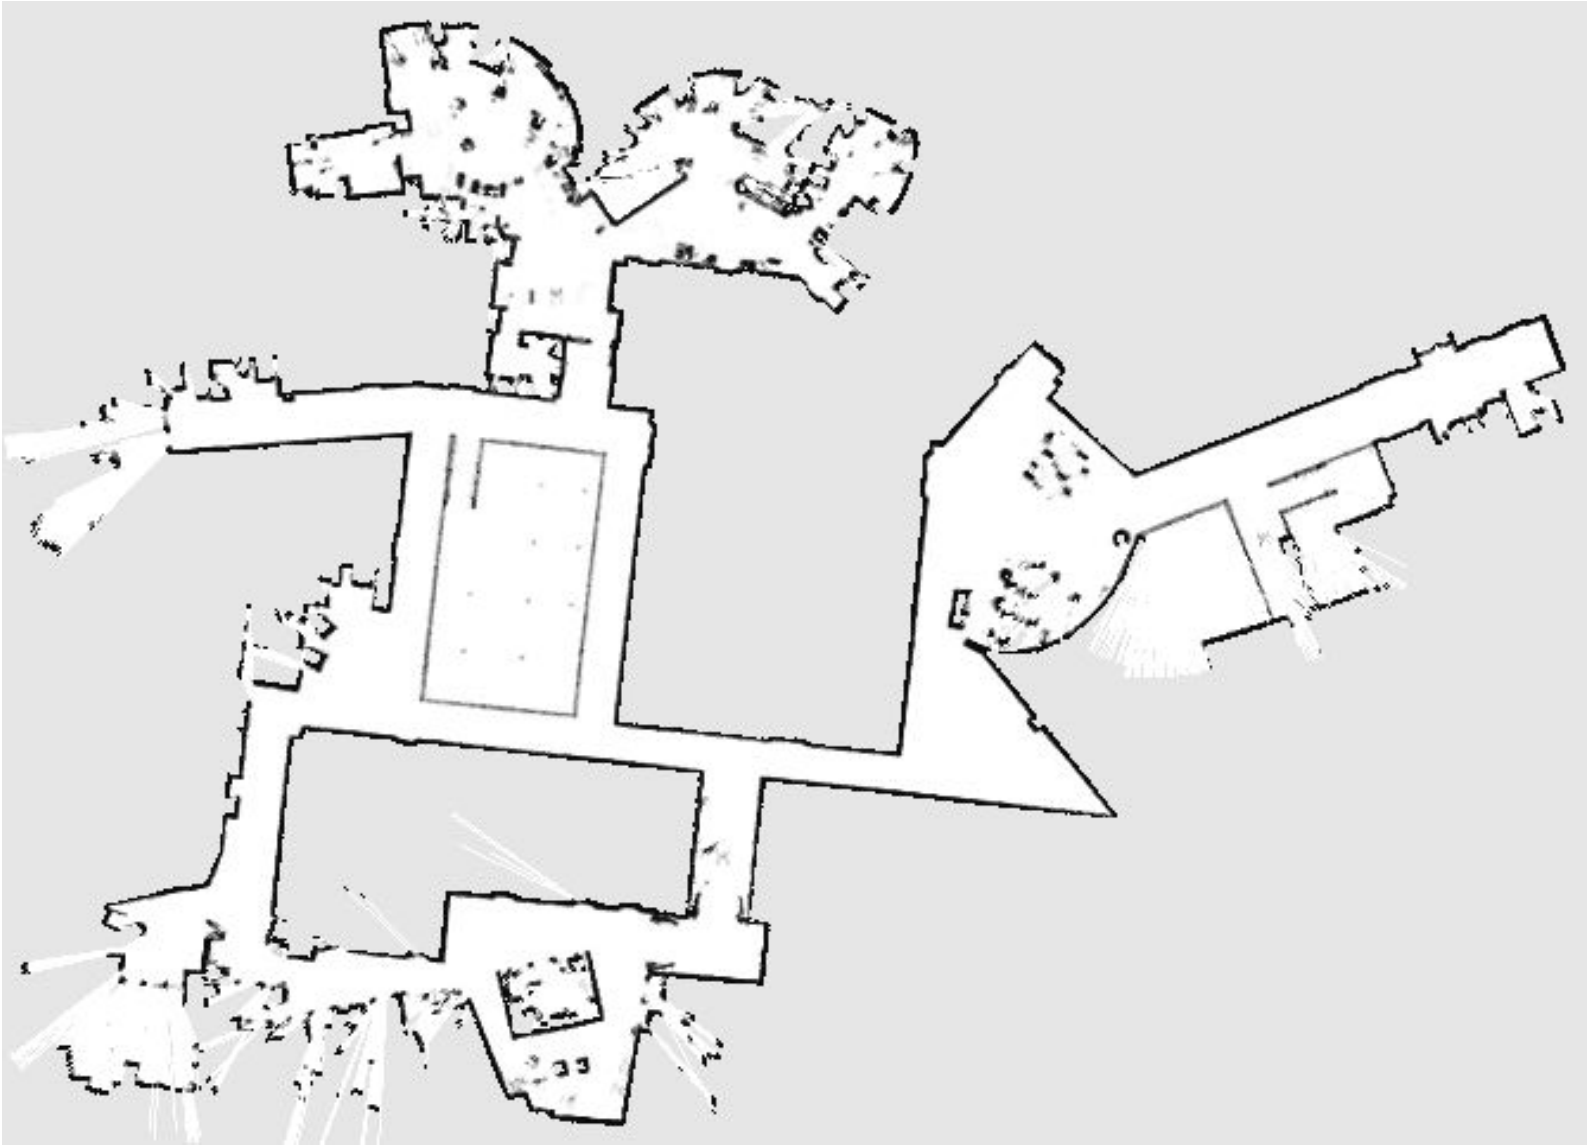

Univ. de Freiburg, Alemania

Resumen

- Los mapas de grillas son un modelo muy usado para representar el entorno
- Las grillas de ocupación **discretizan** el espacio en celdas independientes
- Cada celda es una variable aleatoria **binaria** que estima si la celda está ocupada.
- Estimamos el estado de cada celda usando un filtro de **Bayes binario**.
- Esto permite un **algoritmo eficiente** para el mapeo con poses conocidas
- El modelo “log odds” es rápido de calcular