I402: Principios de la Robótica Autónoma

Clases Prácticas
Tutorial 8

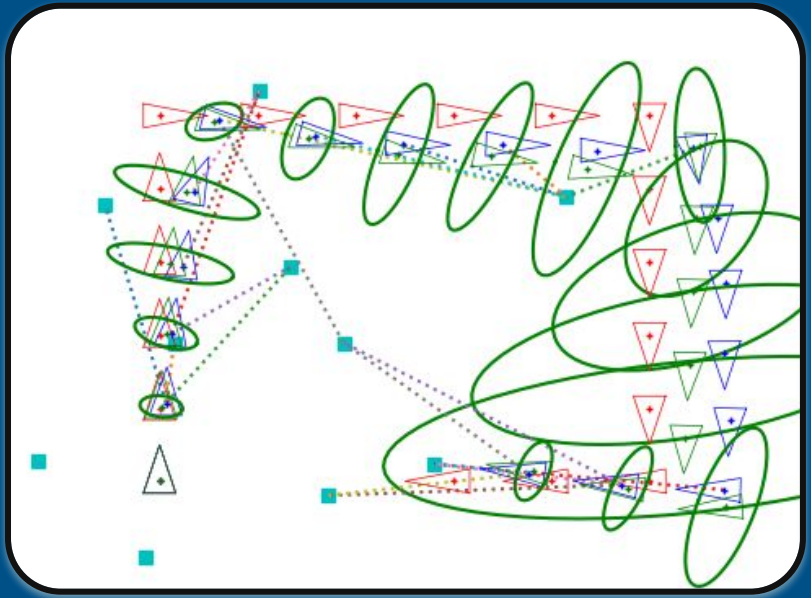

Universidad de SanAndrés

TP3

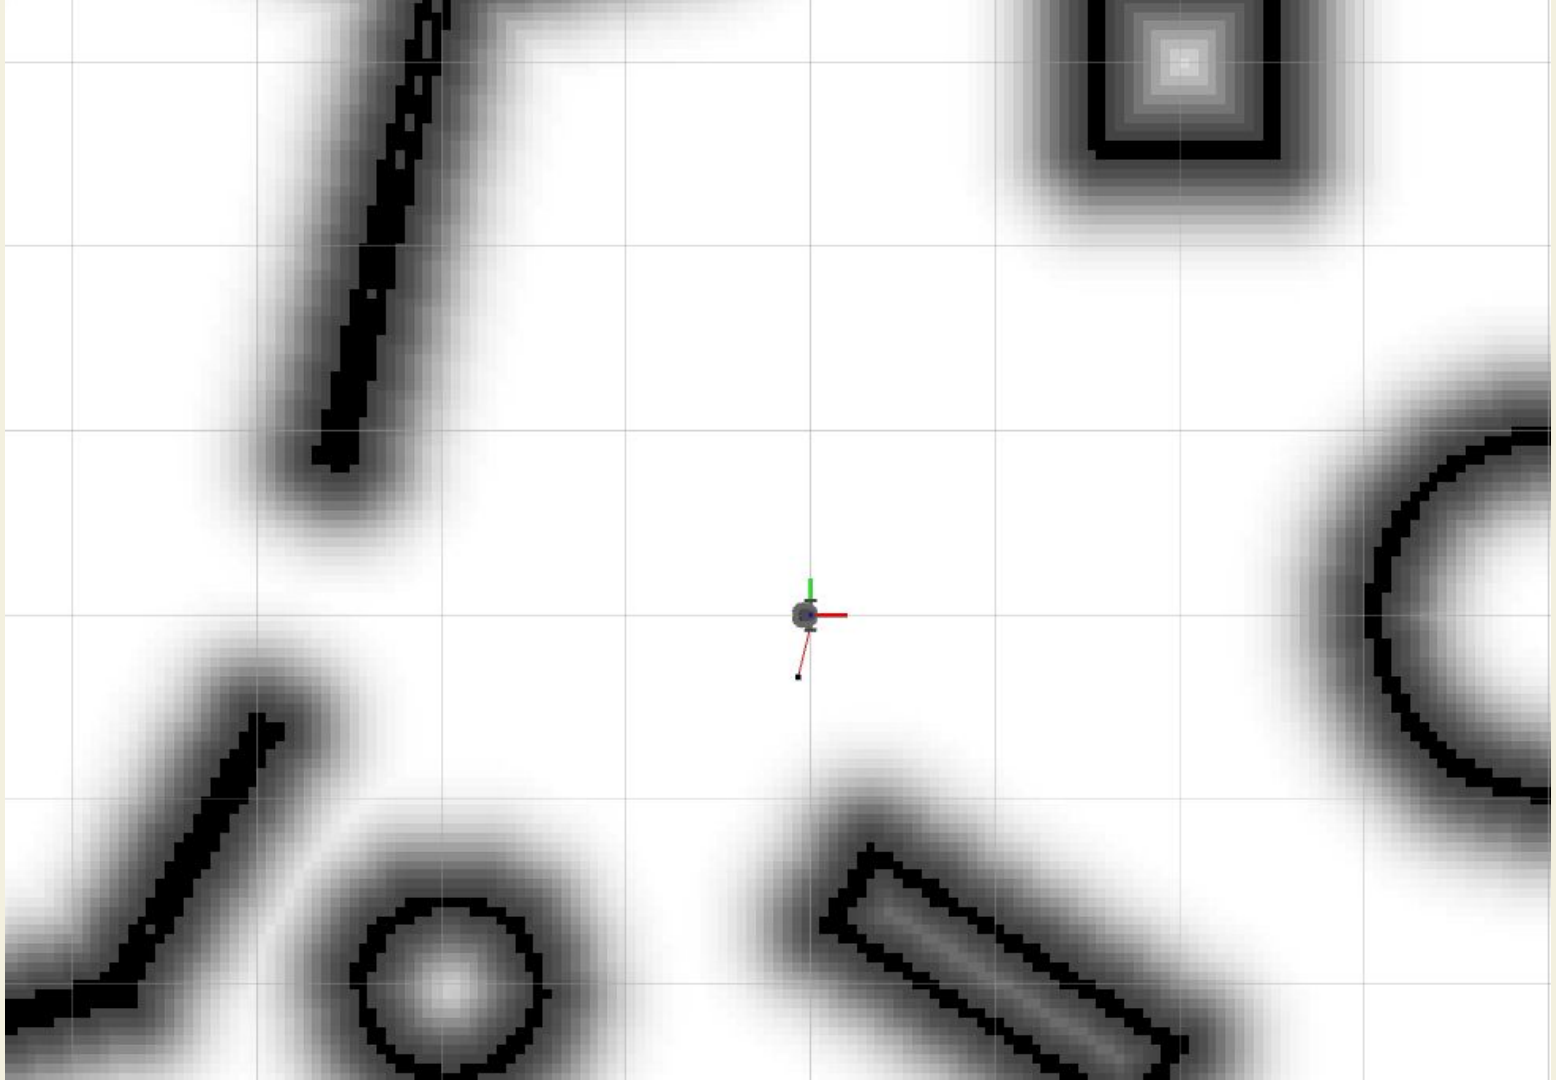

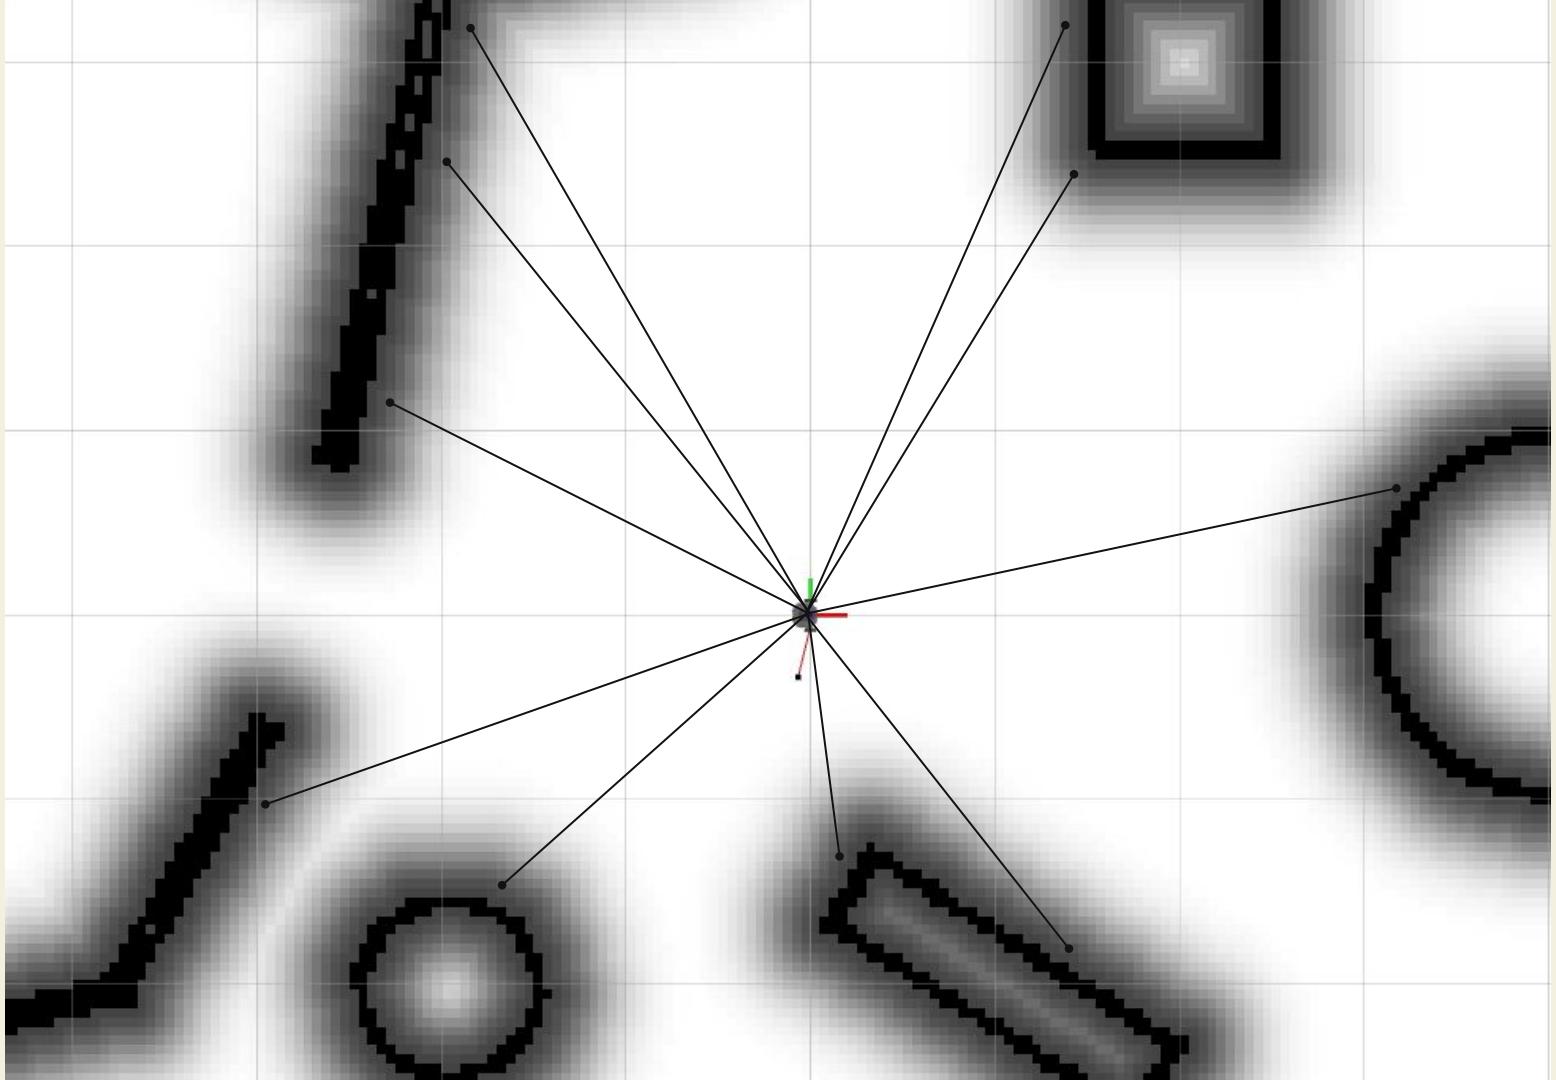

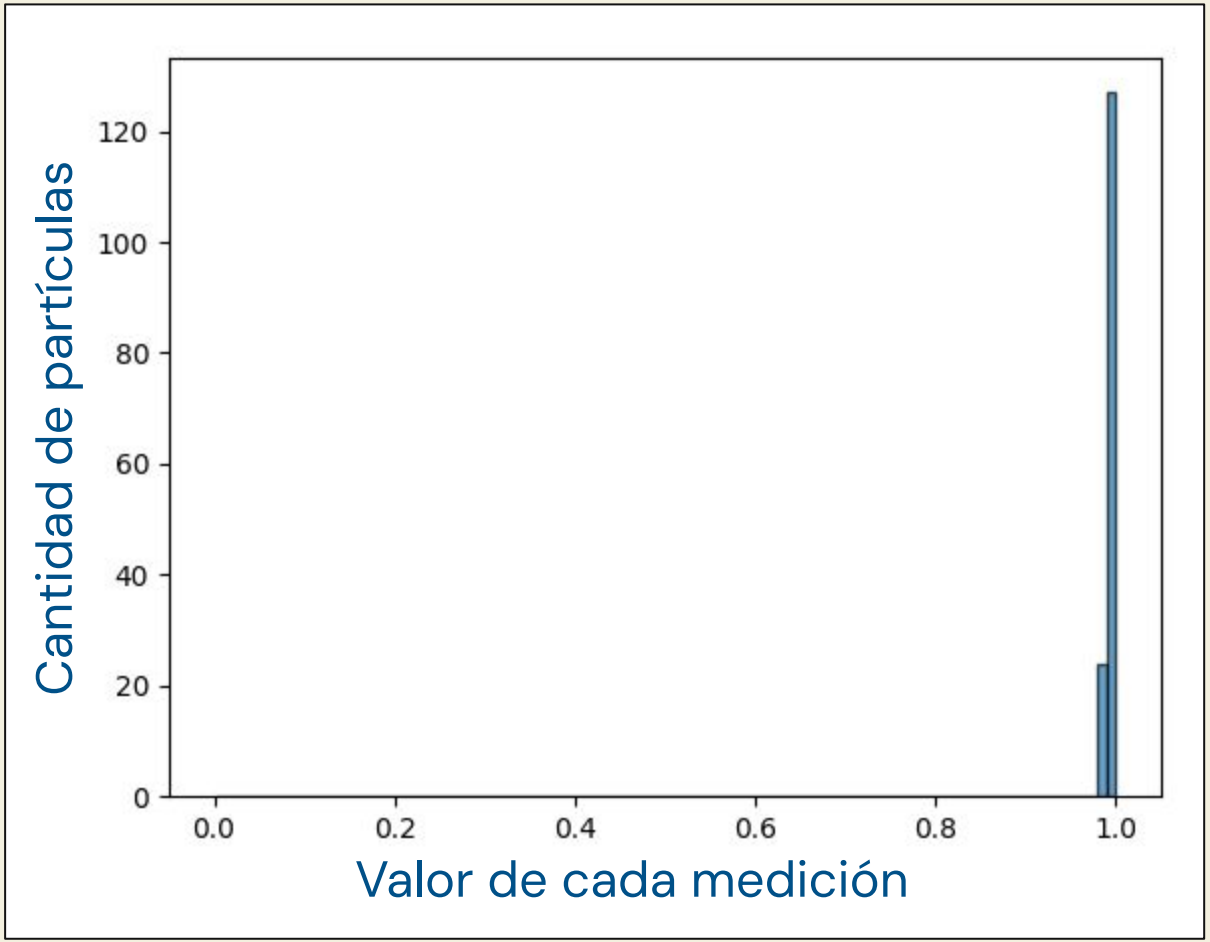
Cantidad de partículas
120
100
80
60
40
20
0
0.0
0.2
0.4
0.6
0.8
1.0
Valor de cada medición

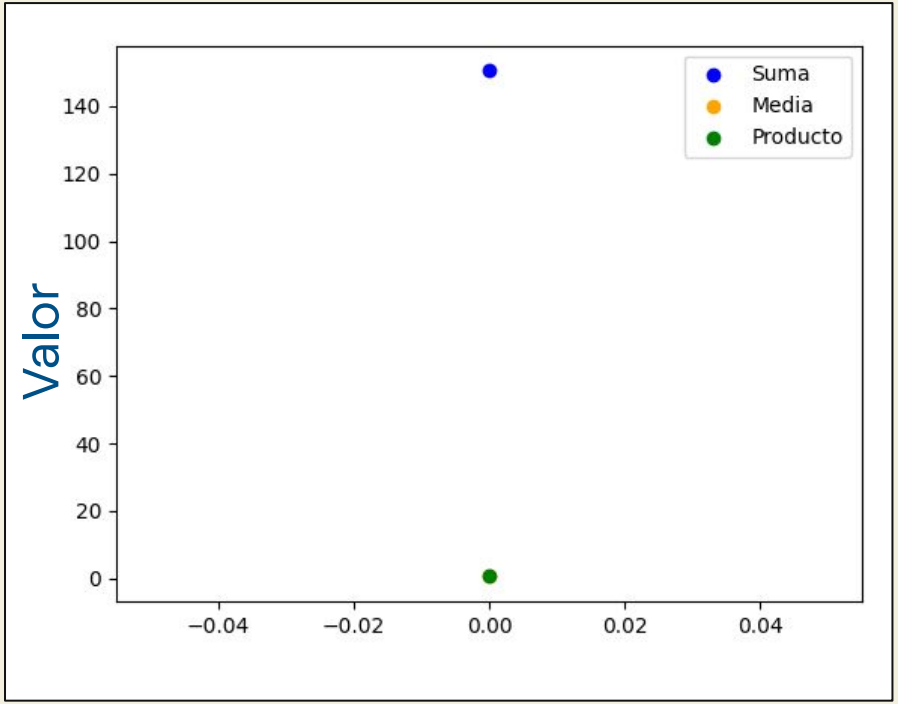
Valor
140
120
100
80
60
40
20
0
−0.04
−0.02
0.00
0.02
0.04
Suma
Media
Producto

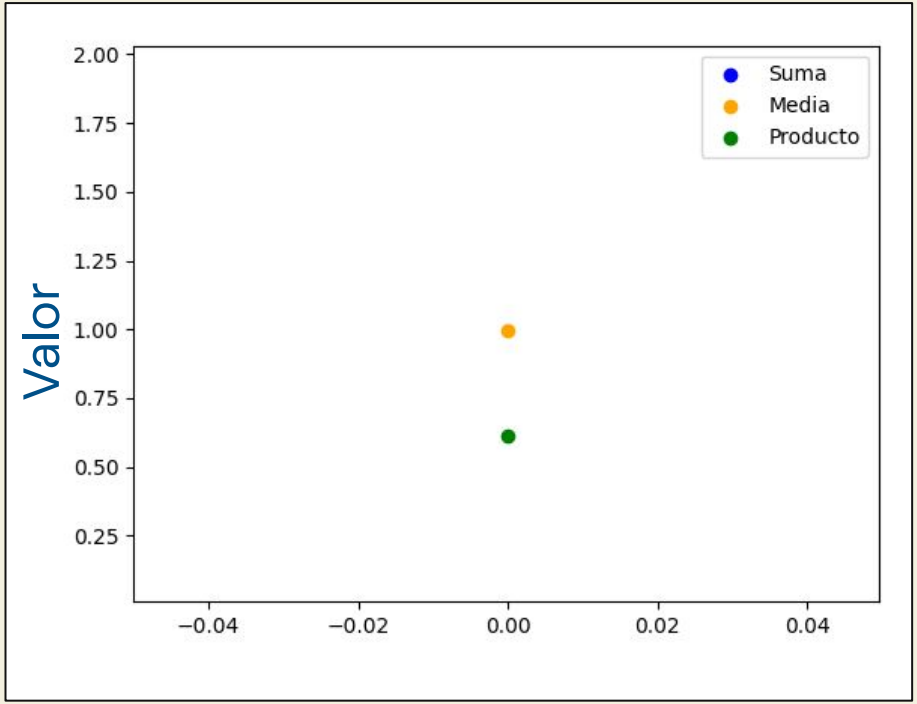
Valor
2.00
1.75
1.50
1.25
1.00
0.75
0.50
0.25
−0.04
−0.02
0.00
0.02
0.04
Suma
Media
Producto

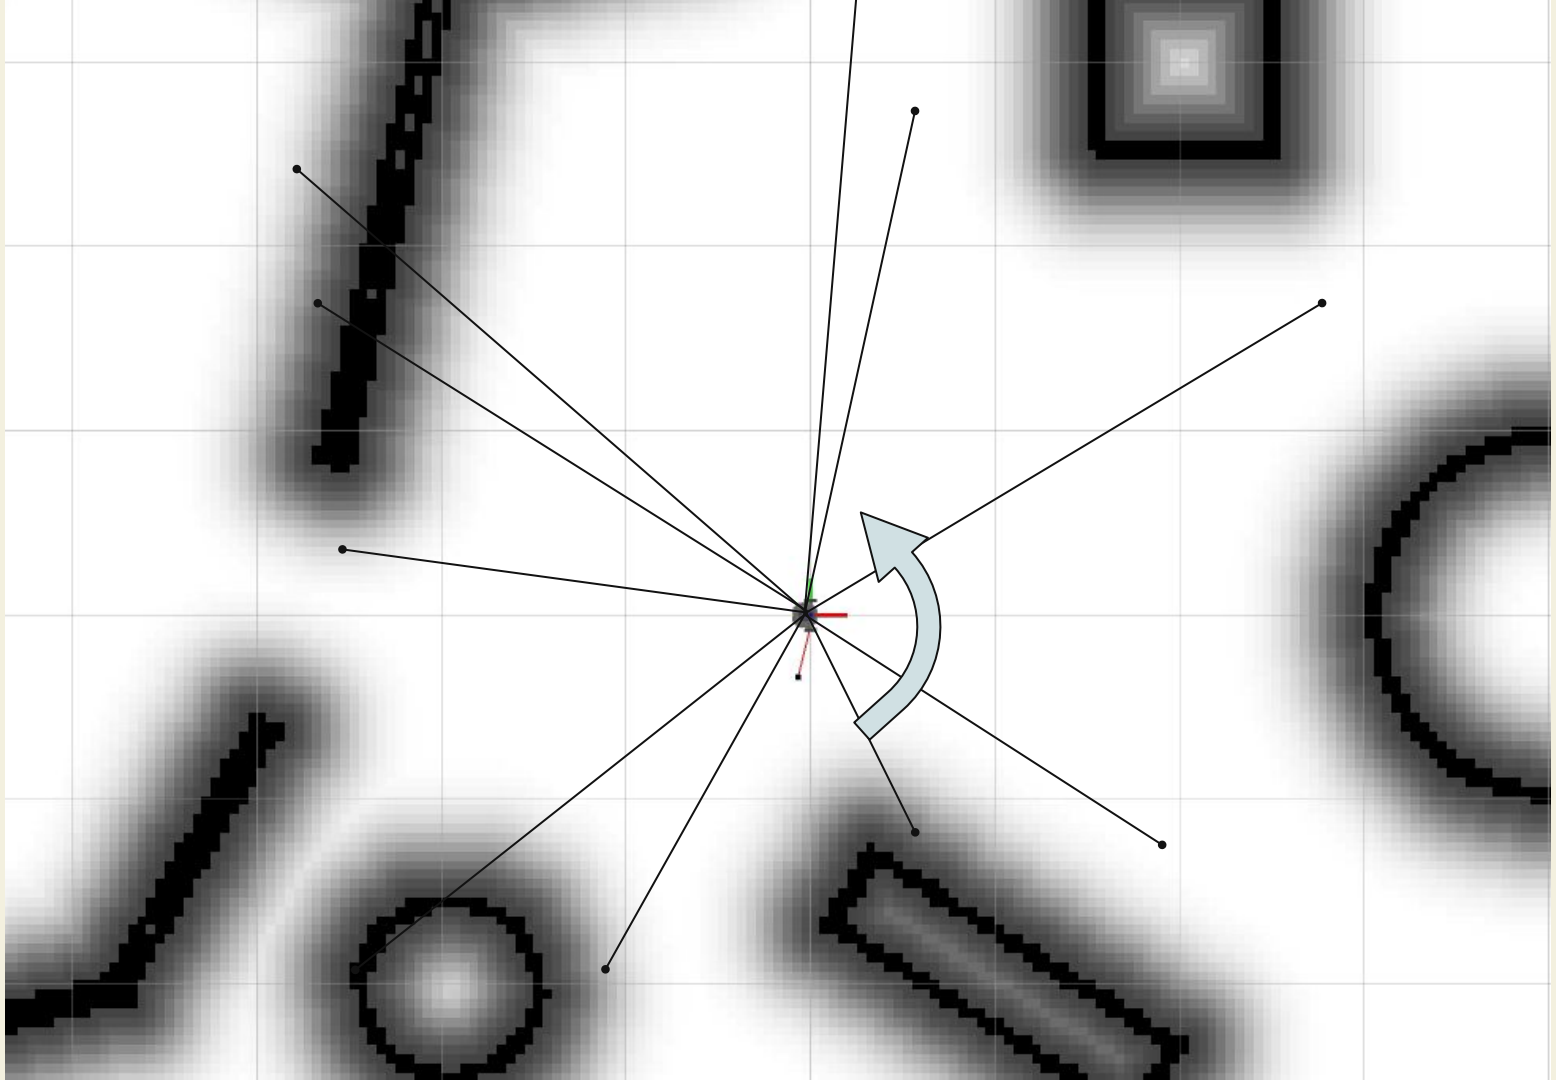

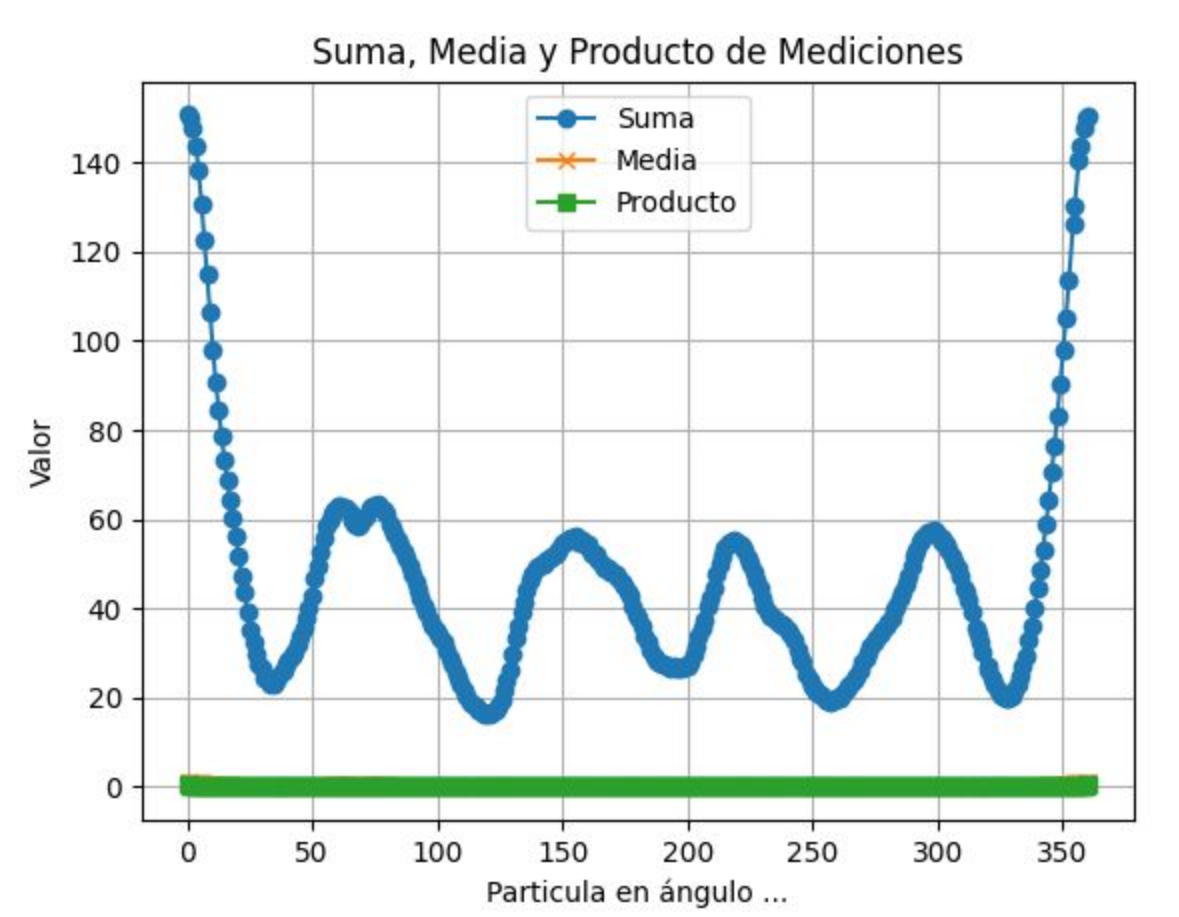
Suma, Media y Producto de Mediciones
Suma
Media
Producto
Valor
0
20
40
60
80
100
120
140
0
50
100
150
200
250
300
350
Particula en ángulo ...

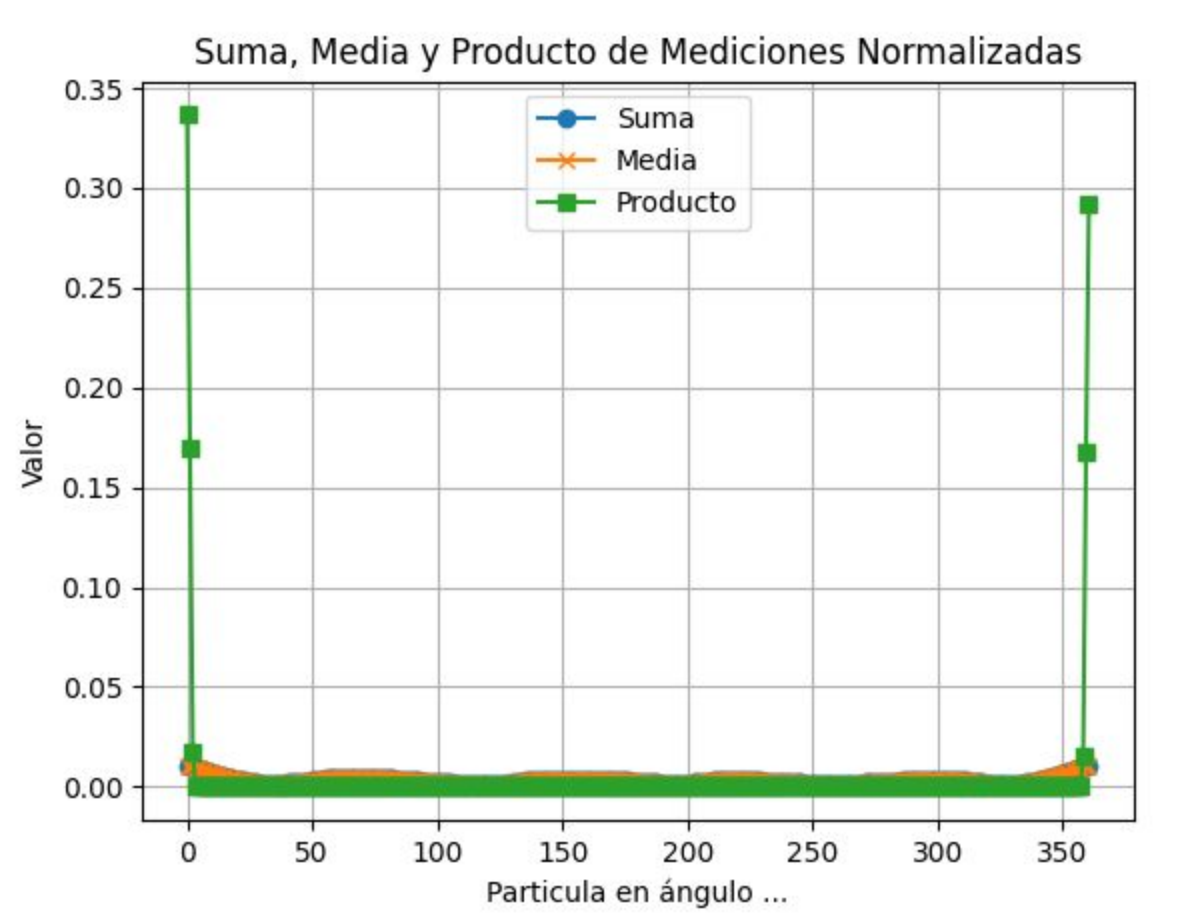
Suma, Media y Producto de Mediciones Normalizadas
Suma
Media
Producto
Valor
0.35
0.30
0.25
0.20
0.15
0.10
0.05
0.00
0
50
100
150
200
250
300
350
Particula en ángulo ...

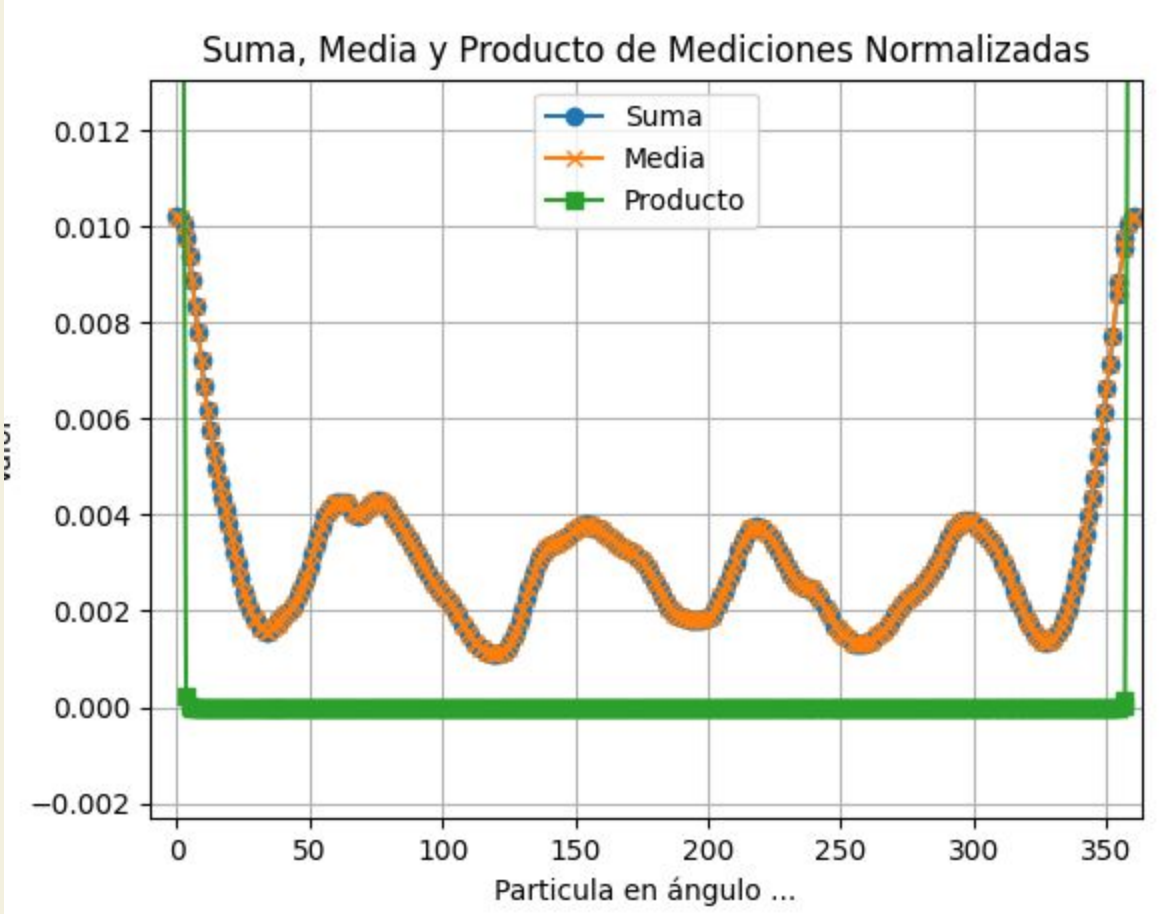
Suma, Media y Producto de Mediciones Normalizadas
Suma
Media
Producto
0.012
0.010
0.008
0.006
0.004
0.002
0.000
−0.002
0
50
100
150
200
250
300
350
Particula en ángulo ...

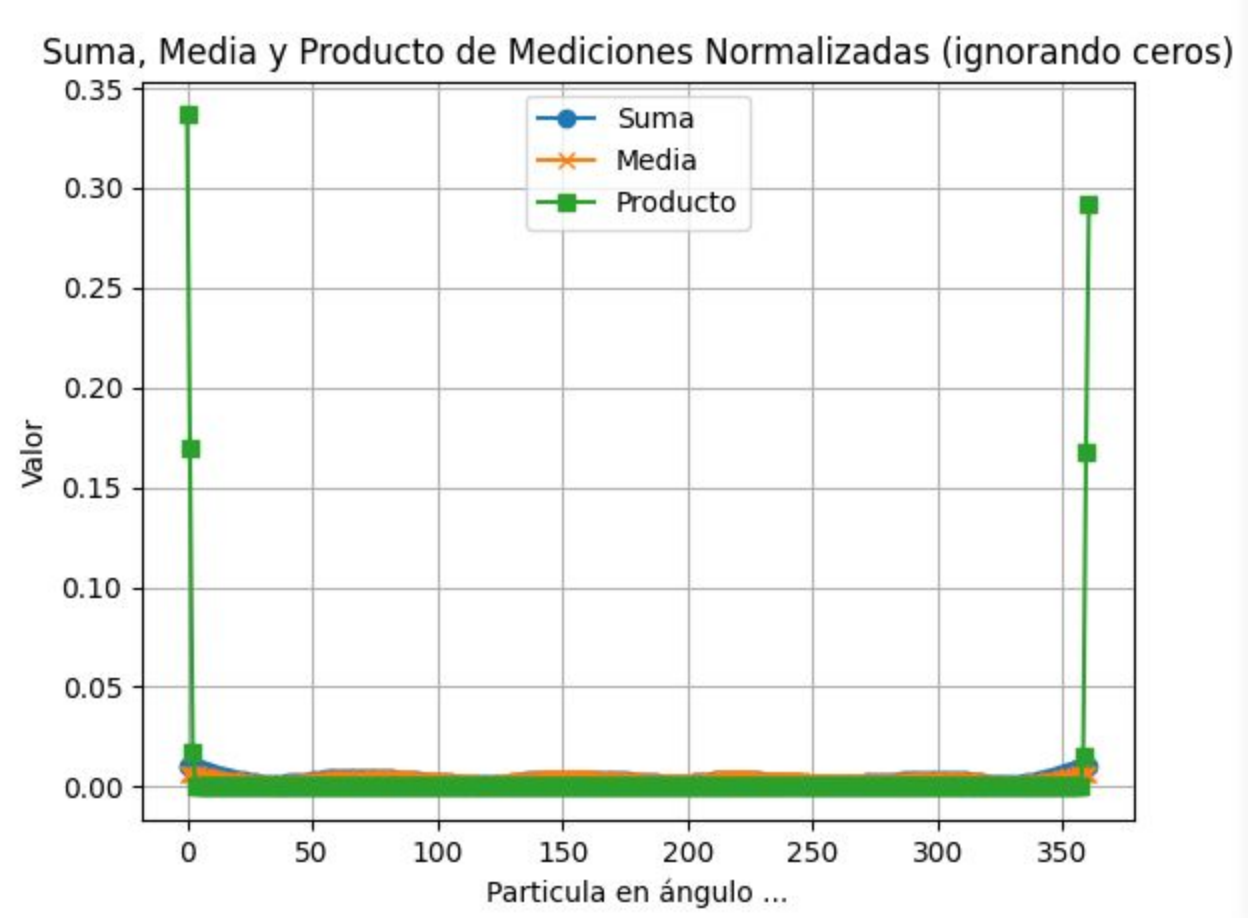
Suma, Media y Producto de Mediciones Normalizadas (ignorando ceros)
Suma
Media
Producto
Valor
0.35
0.30
0.25
0.20
0.15
0.10
0.05
0.00
0
50
100
150
200
250
300
350
Particula en ángulo ...

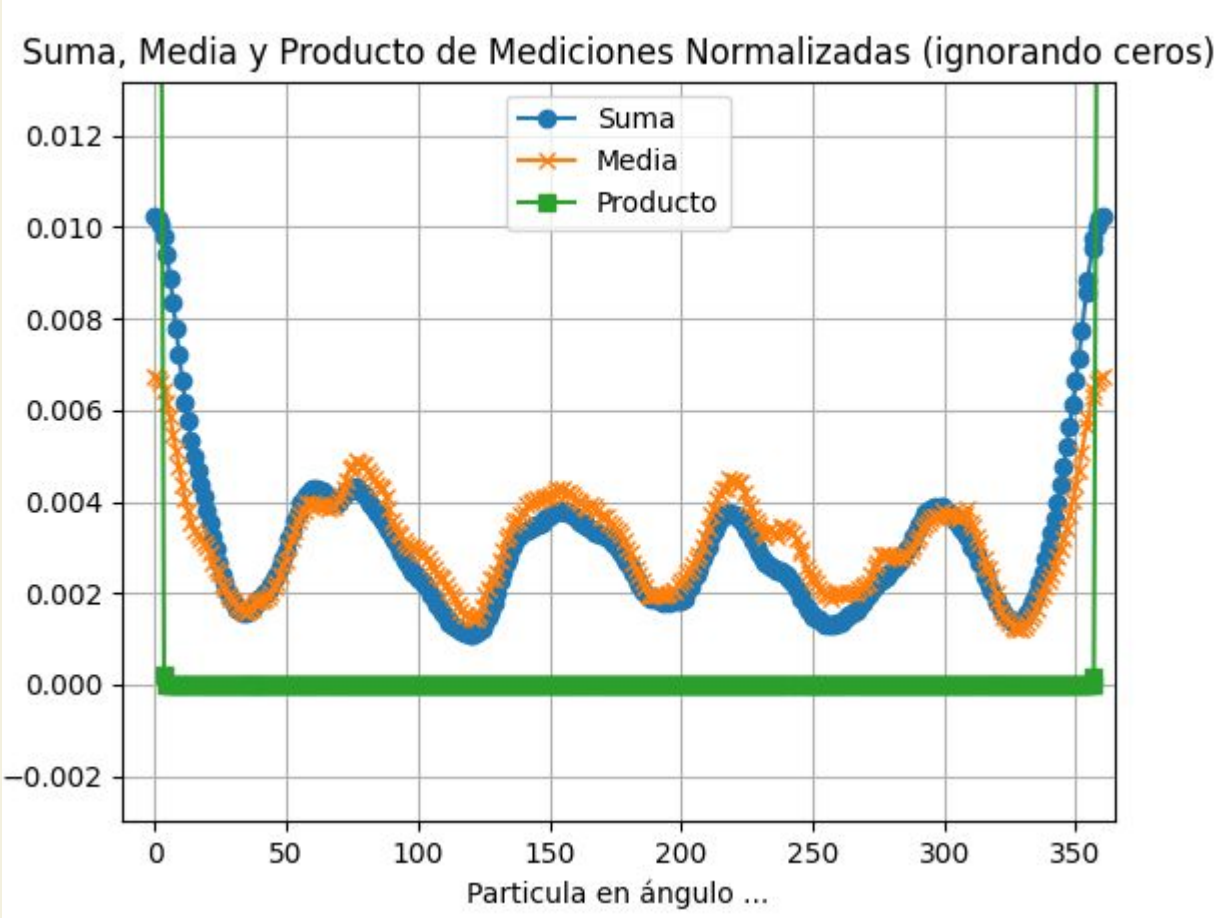
Suma, Media y Producto de Mediciones Normalizadas (ignorando ceros)
Suma
Media
Producto
0.012
0.010
0.008
0.006
0.004
0.002
0.000
−0.002
0
50
100
150
200
250
300
350
Particula en ángulo ...

$$\log w^{[i]} = \sum_j \log p(z_j \mid x^{[i]})$$

$$\log w^{[i]} = \sum_{j=1}^{N} \log \left(p(z_j \mid x^{[i]}) + \varepsilon \right)$$

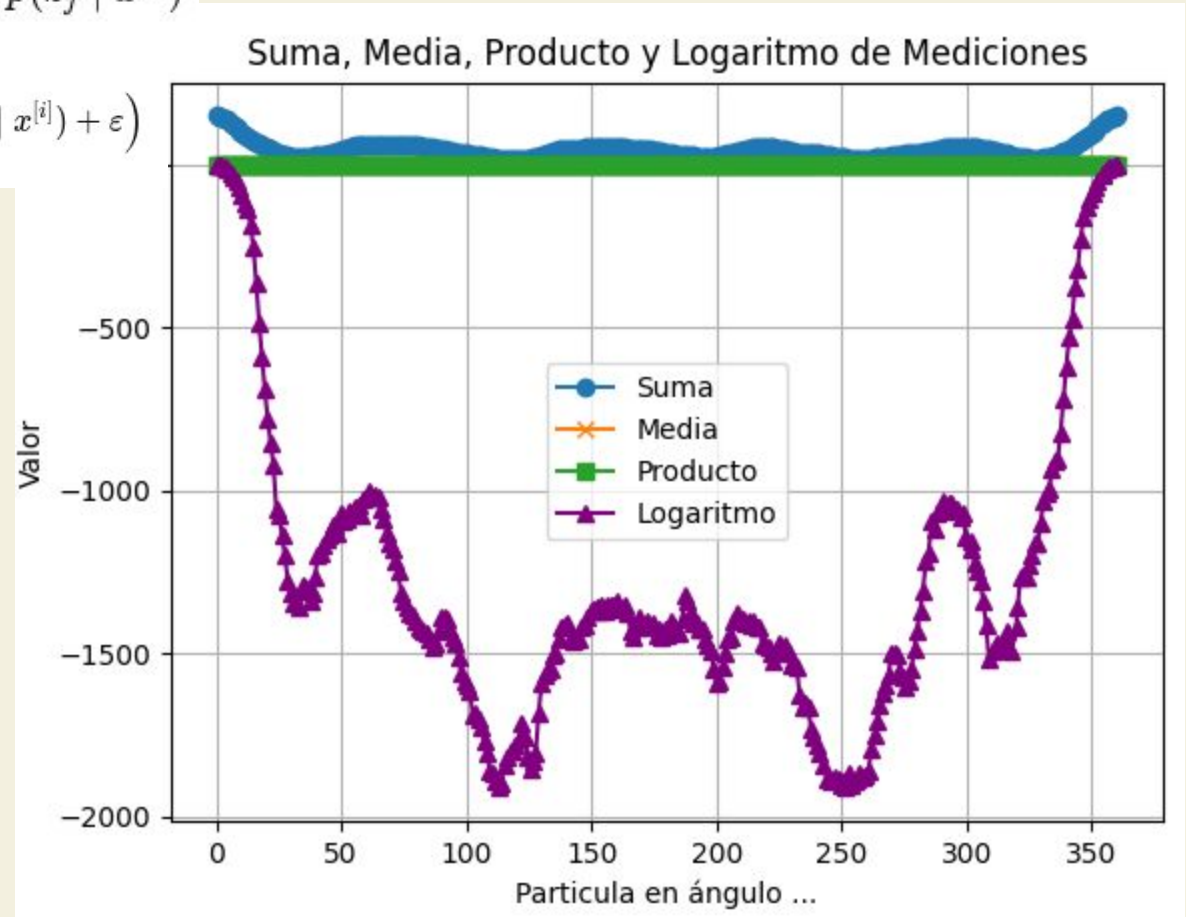

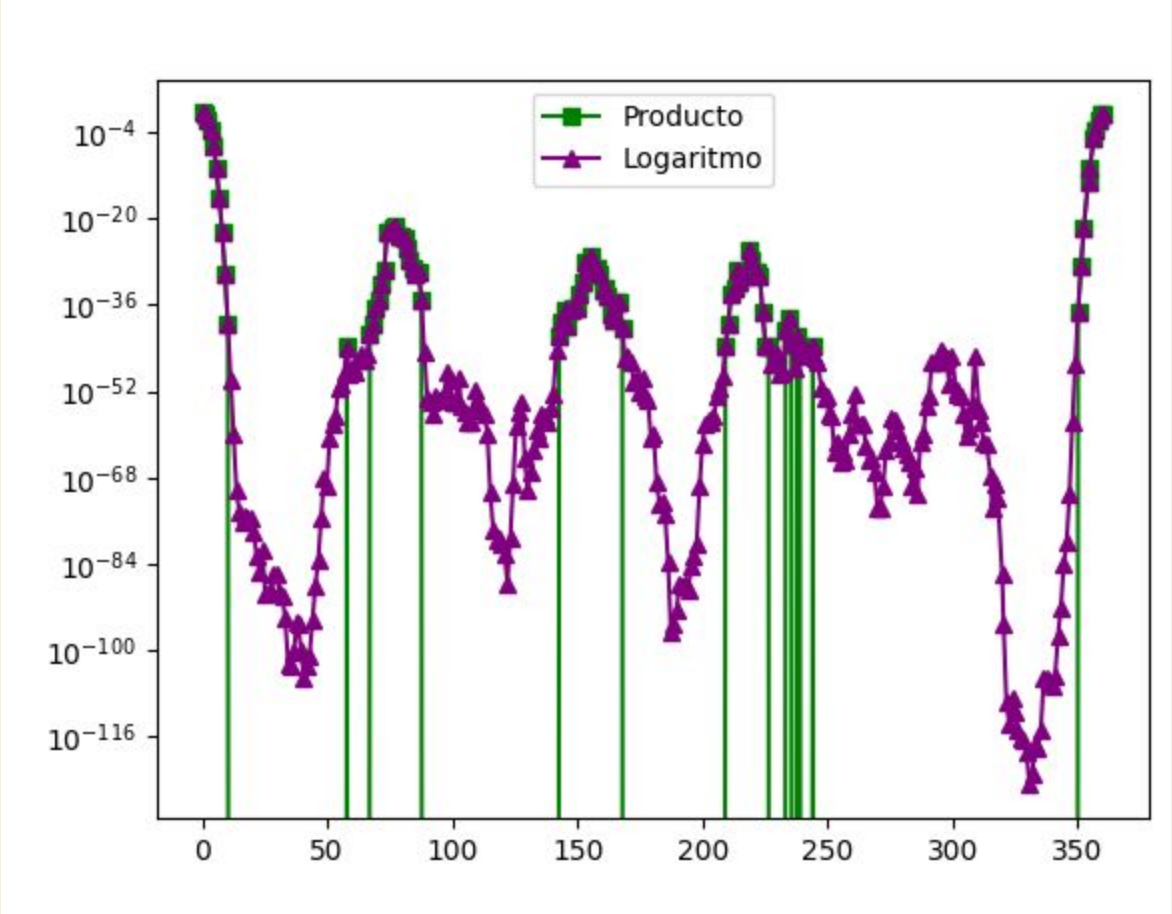
Producto
Logaritmo
10^{-4}
10^{-20}
10^{-36}
10^{-52}
10^{-68}
10^{-84}
10^{-100}
10^{-116}
0
50
100
150
200
250
300
350

$$w^{[i]} = \exp\left(\log w^{[i]} - \max_j \log w^{[j]}\right)$$

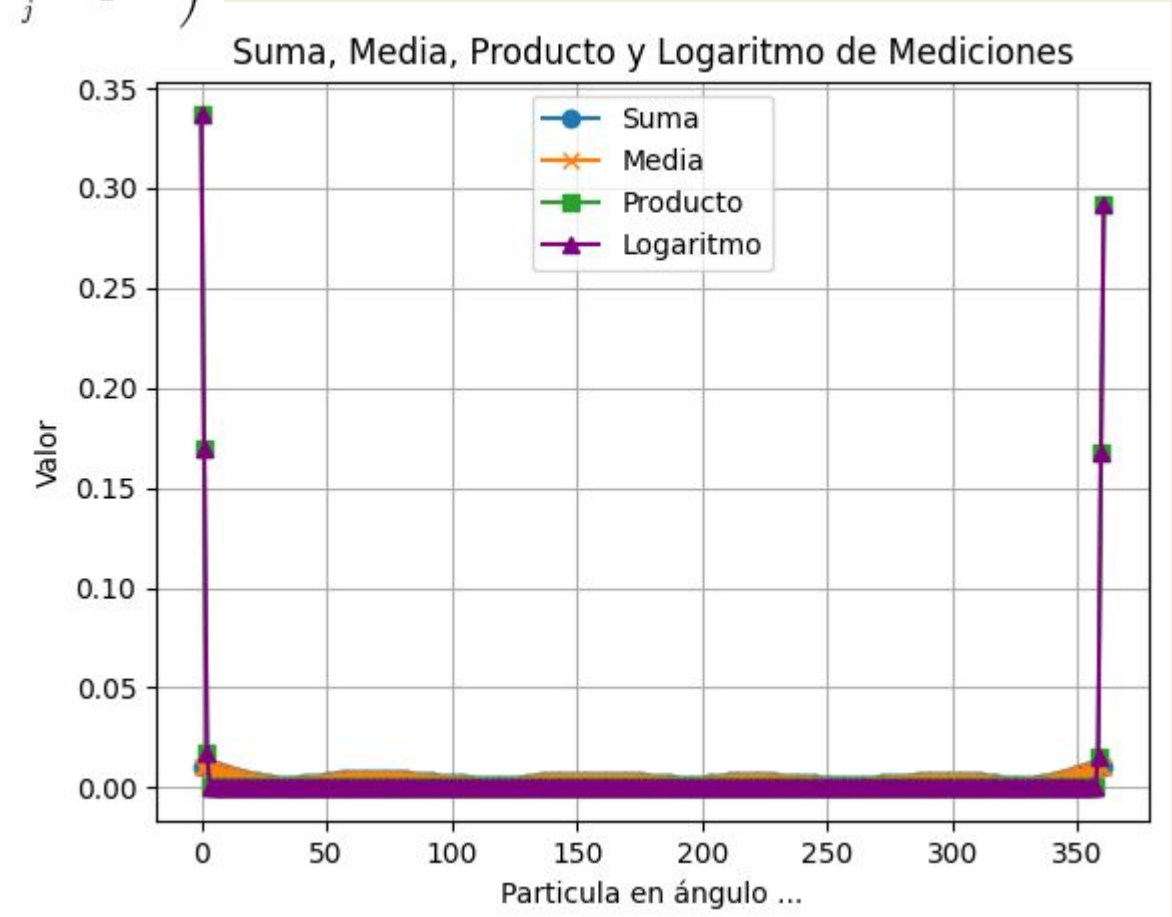

KF, EKF, UKF

sensors MDPI

Article

Knee Angle Estimation with Dynamic Calibration Using Inertial Measurement Units for Running

Matthew B. Rhudy [1,*], Joseph M. Mahoney [2] and Allison R. Altman-Singles [1,3]

1 Mechanical Engineering, The Pennsylvania State University, Berks College, Reading, PA 19610, USA
2 Mechanical Engineering, Alvernia University, Reading, PA 19607, USA; joseph.m.mahoney@gmail.com
3 Kinesiology, The Pennsylvania State University, Berks College, Reading, PA 19610, USA; ara5093@psu.edu
* Correspondence: mbr5002@psu.edu

Abstract: The knee flexion angle is an important measurement for studies of the human gait. Running is a common activity with a high risk of knee injury. Studying the running gait in realistic situations is challenging because accurate joint angle measurements typically come from optical motion-capture systems constrained to laboratory settings. This study considers the use of shank and thigh inertial sensors within three different filtering algorithms to estimate the knee flexion angle for running without requiring sensor-to-segment mounting assumptions, body measurements, specific calibration poses, or magnetometers. The objective of this study is to determine the knee flexion angle within running applications using accelerometer and gyroscope information only. Data were collected for a single test participant (21-year-old female) at four different treadmill speeds and used to validate the estimation results for three filter variations with respect to a Vicon optical motion-capture system. The knee flexion angle filtering algorithms resulted in root-mean-square errors of approximately three degrees. The results of this study indicate estimation results that are within acceptable limits of five degrees for clinical gait analysis. Specifically, a complementary filter approach is effective for knee flexion angle estimation in running applications.

Keywords: inertial measurement units; gait analysis; kinematic constraints; Kalman filtering

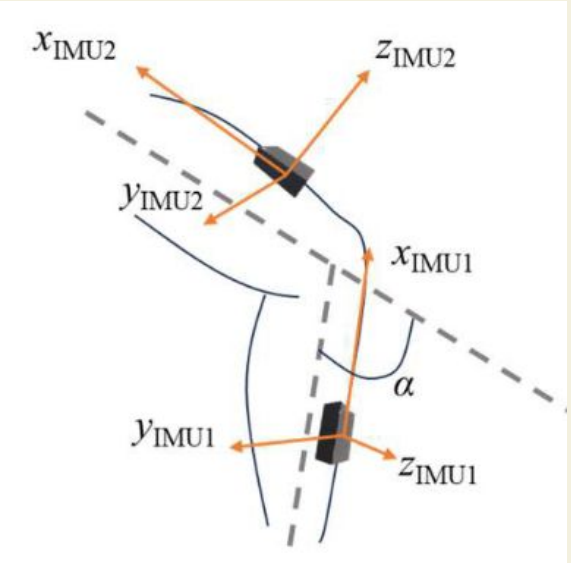

"IMUs typically contain three-axis accelerometers, three-axis rate gyroscopes, and, sometimes, three-axis magnetometers. Although the details of the actual implementation vary, the general principles of IMU knee-flexion-angle estimation research involve the fusion of different combinations of IMU sensor information through filtering techniques, such as the complementary filter (CF), Kalman filter (KF), extended Kalman filter (EKF), and unscented Kalman filter (UKF)"

KF

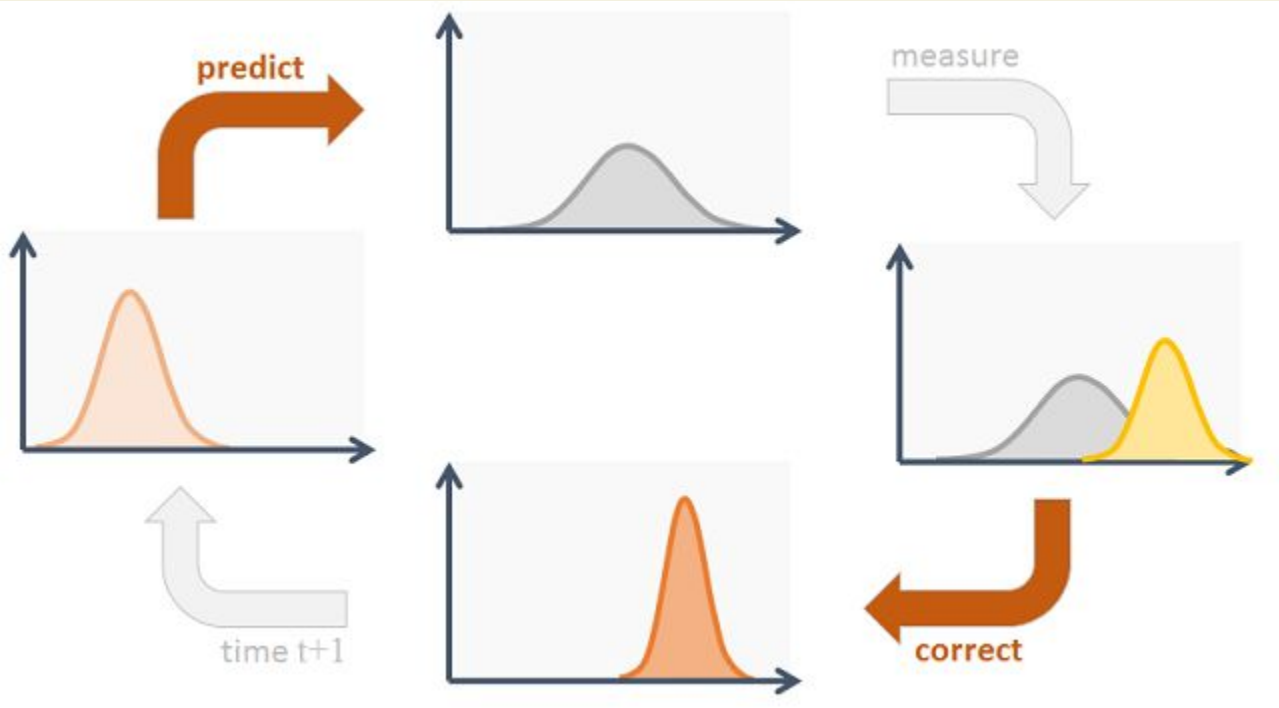

Filtro de partículas

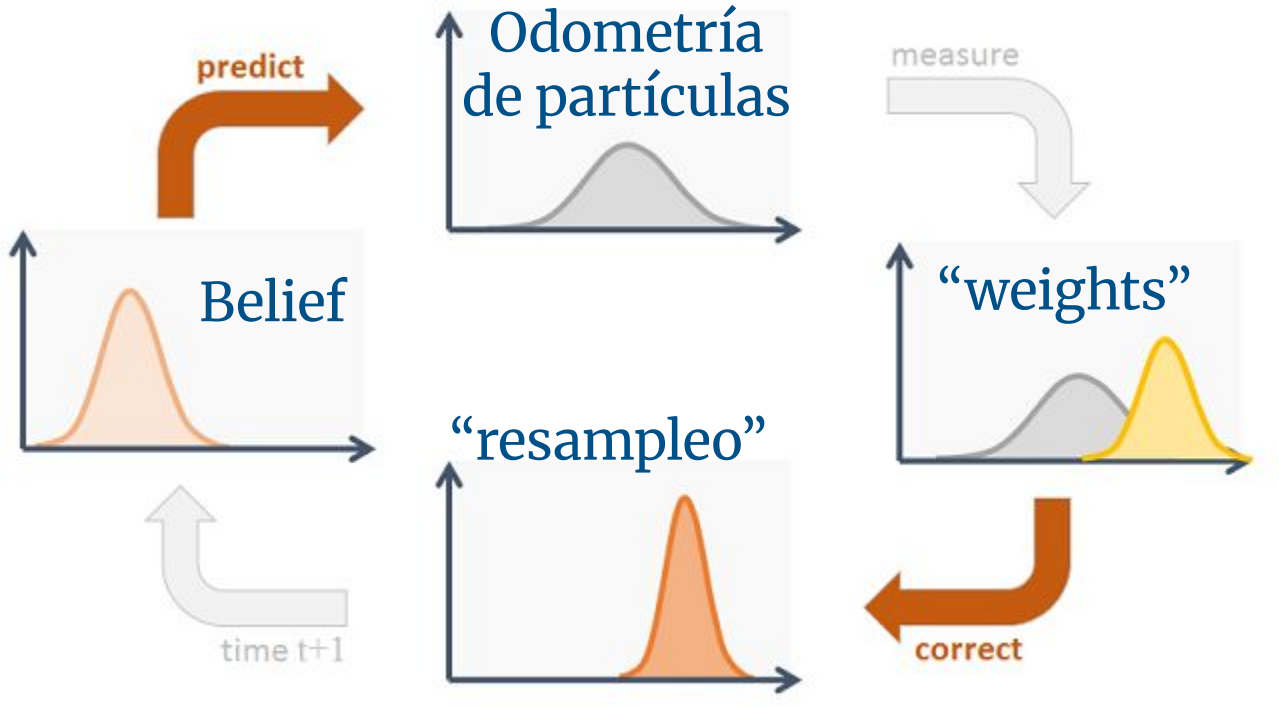

KF

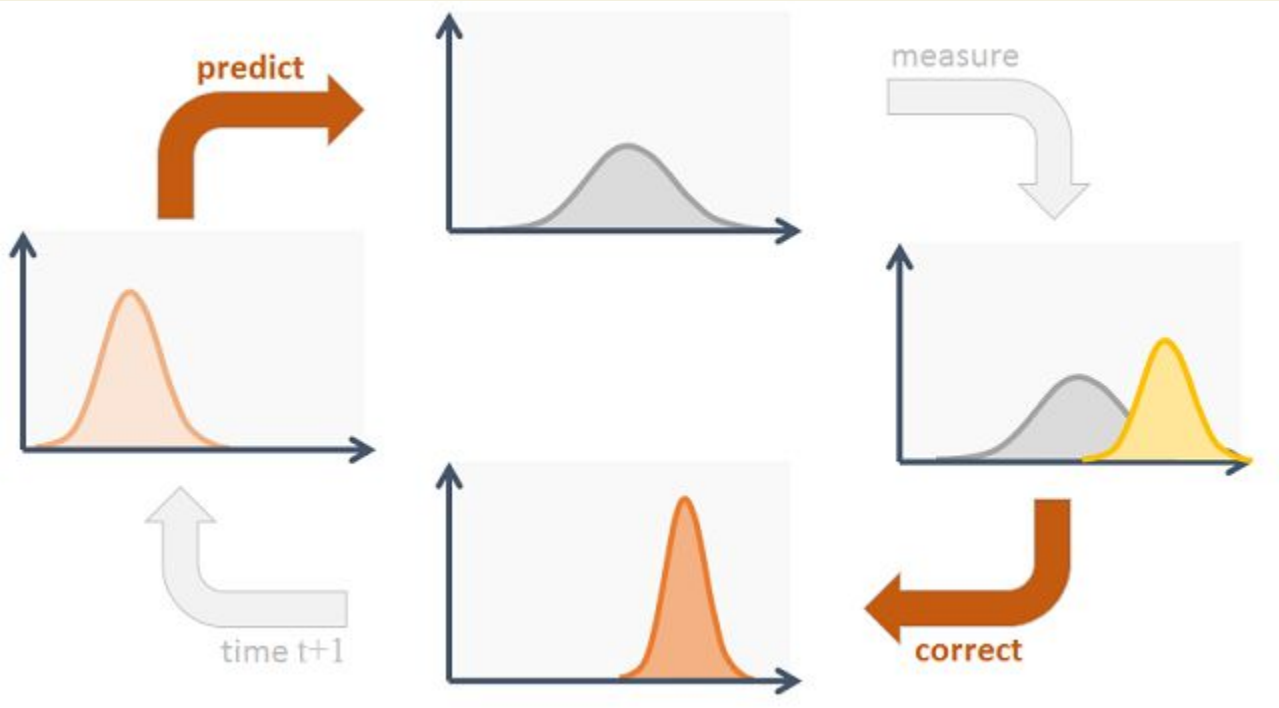

Ejercicio

Un vehículo con dinámica lineal que se mueve en un entorno lineal. Supongamos que $\Delta t = 1$ para simplificar. La posición del vehículo en el tiempo t está dada por x_t. Su velocidad es $\dot{x}_t$ y su aceleración es $\ddot{x}_t$.

Ejercicio

Un vehículo con dinámica lineal que se mueve en un entorno lineal. Supongamos que $\Delta t = 1$ para simplificar. La posición del vehículo en el tiempo t está dada por x_t. Su velocidad es $\dot{x}_t$ y su aceleración es $\ddot{x}_t$.

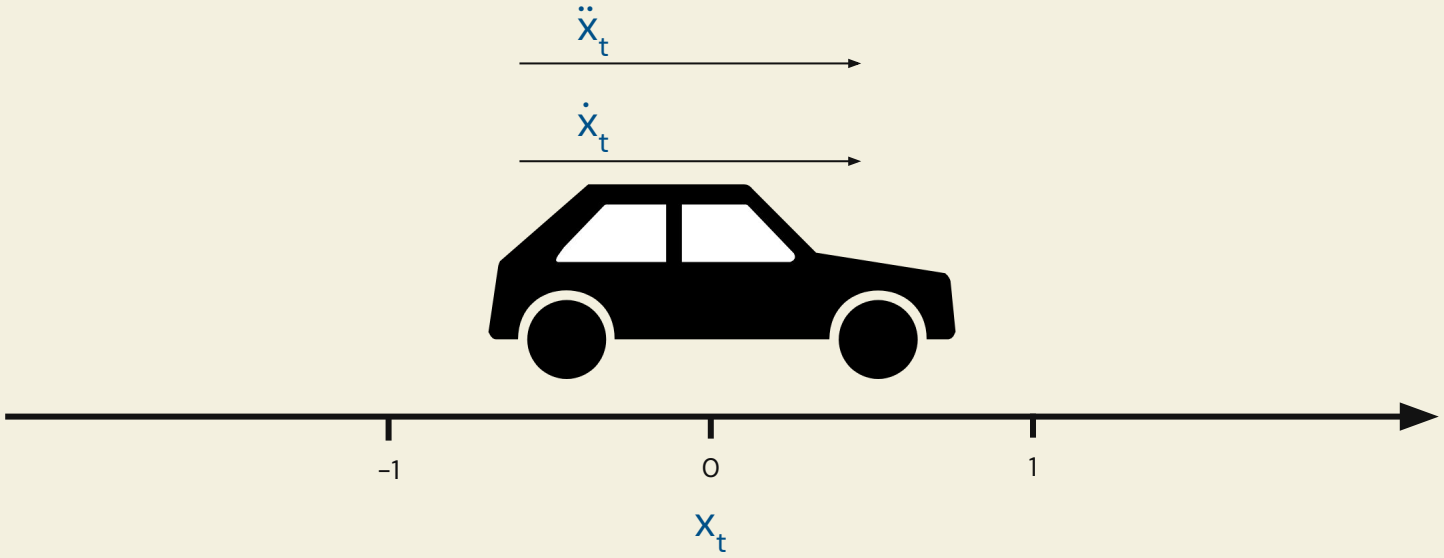

Ejercicio

Un vehículo con dinámica lineal que se mueve en un entorno lineal. Supongamos que $\Delta t = 1$ para simplificar. La posición del vehículo en el tiempo t está dada por x_t. Su velocidad es $\dot{x}_t$ y su aceleración es $\ddot{x}_t$.

Supongamos que la aceleración se establece aleatoriamente en cada instante de tiempo, de acuerdo con una Gaussiana de media cero y varianza 1.

Ejercicio

Un vehículo con dinámica lineal que se mueve en un entorno lineal. Supongamos que $\Delta t = 1$ para simplificar. La posición del vehículo en el tiempo t está dada por x_t. Su velocidad es $\dot{x}_t$ y su aceleración es $\ddot{x}_t$.

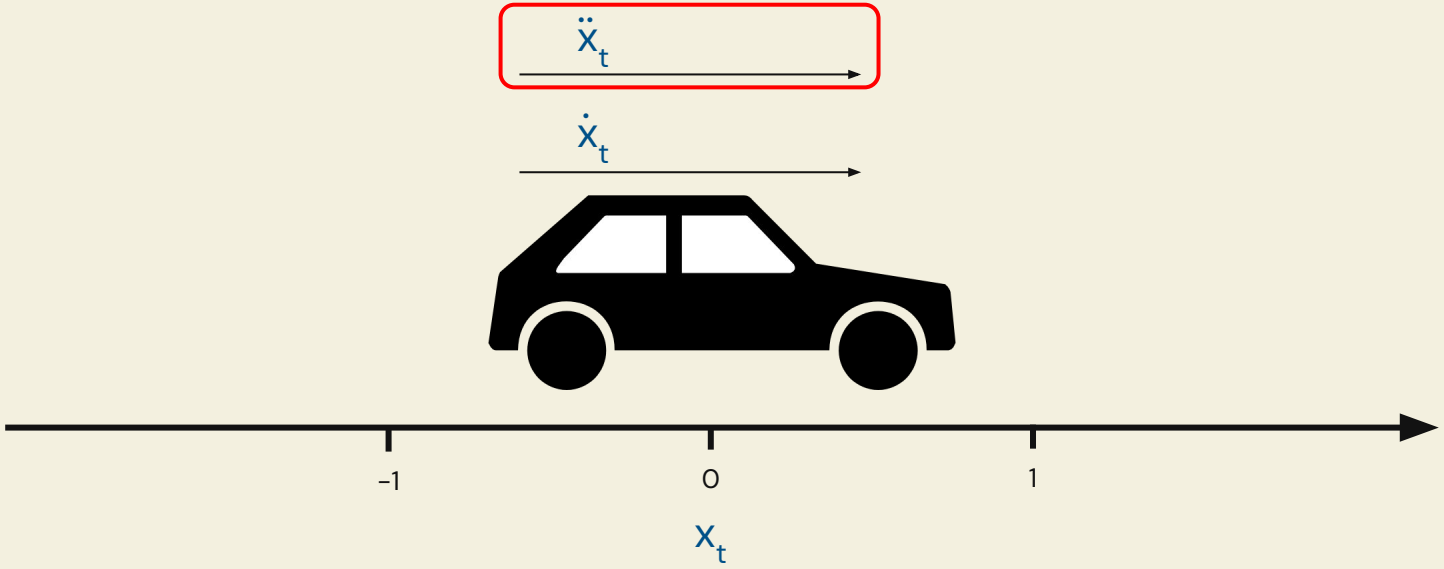

Ejercicio

Un vehículo con dinámica lineal que se mueve en un entorno lineal. Supongamos que $\Delta t = 1$ para simplificar. La posición del vehículo en el tiempo t está dada por x_t. Su velocidad es $\dot{x}_t$ y su aceleración es $\ddot{x}_t$.

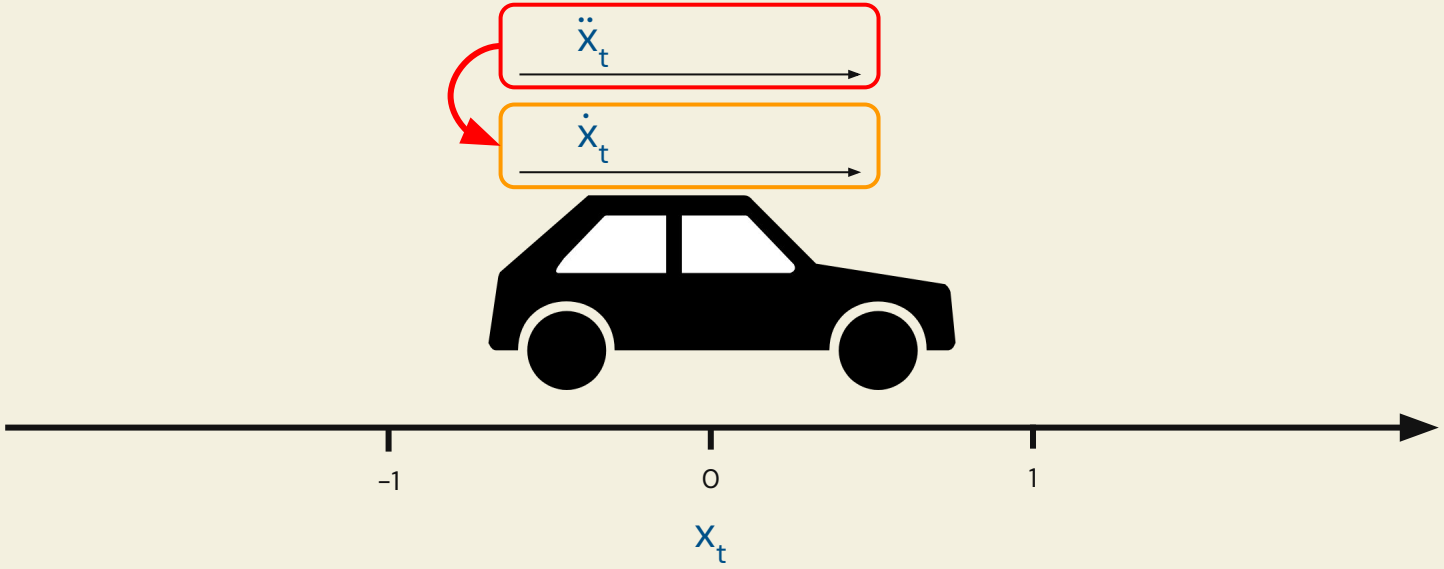

Ejercicio

Un vehículo con dinámica lineal que se mueve en un entorno lineal. Supongamos que $\Delta t = 1$ para simplificar. La posición del vehículo en el tiempo t está dada por x_t. Su velocidad es $\dot{x}_t$ y su aceleración es $\ddot{x}_t$.

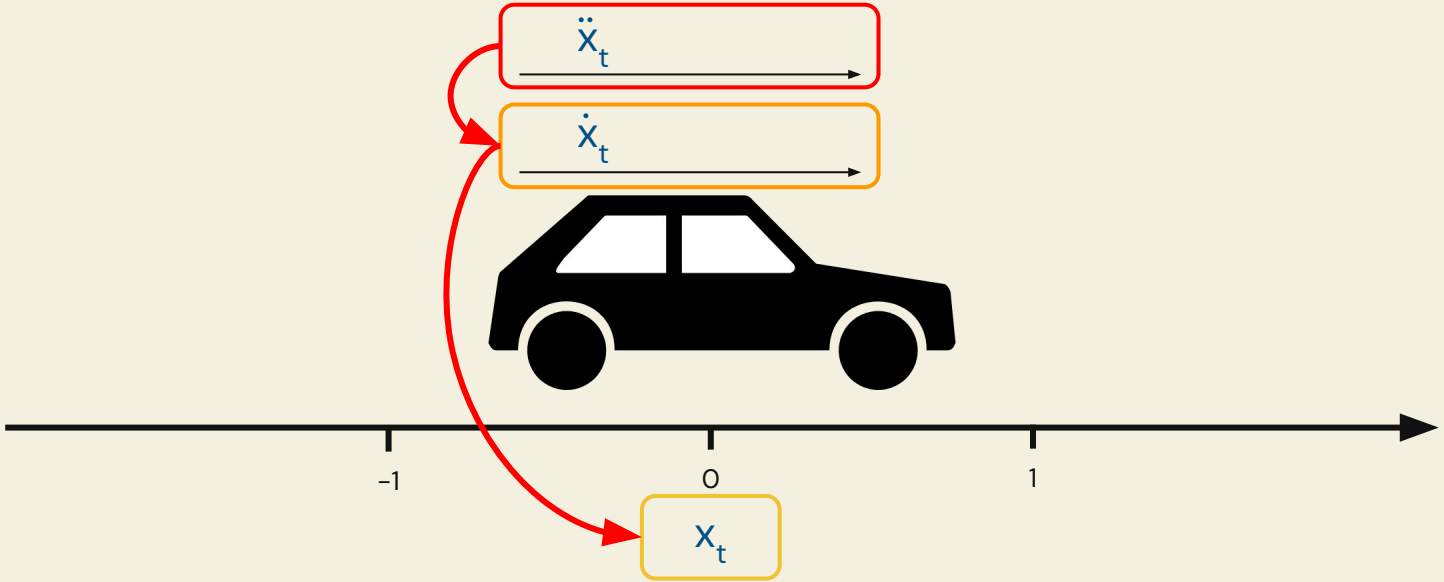

Ejercicio

Un vehículo con dinámica lineal que se mueve en un entorno lineal. Supongamos que $\Delta t = 1$ para simplificar. La posición del vehículo en el tiempo t está dada por x_t. Su velocidad es $\dot{x}_t$ y su aceleración es $\ddot{x}_t$.

Supongamos que la aceleración se establece aleatoriamente en cada instante de tiempo, de acuerdo con una Gaussiana de media cero y varianza 1.

a. ¿Cuál es un vector de estado mínimo para el filtro de Kalman (de modo que el sistema resultante sea Markoviano)?

Ejercicio

a. ¿Cuál es un vector de estado mínimo para el filtro de Kalman (de modo que el sistema resultante sea Markoviano)?

$$\boxed{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

Ejercicio

a. ¿Cuál es un vector de estado mínimo para el filtro de Kalman (de modo que el sistema resultante sea Markoviano)?

$$\boxed{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

Me puede ayudar pensar:

1. ¿Cuál es mi acción?
2. ¿Cuál es mi ruido?
3. ¿Cuál es mi estado?

Ejercicio

a. ¿Cuál es un vector de estado mínimo para el filtro de Kalman (de modo que el sistema resultante sea Markoviano)?

$$\boxed{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

Me puede ayudar pensar:

1. ¿Cuál es mi acción? → Tengo manera de afectar al sistema de manera "voluntaria"
2. ¿Cuál es mi ruido?
3. ¿Cuál es mi estado?

Ejercicio

a. ¿Cuál es un vector de estado mínimo para el filtro de Kalman (de modo que el sistema resultante sea Markoviano)?

$$\boxed{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

Me puede ayudar pensar:

1. ¿Cuál es mi acción? → Tengo manera de afectar al sistema de manera "voluntaria"
2. ¿Cuál es mi ruido? → Si voy a usar un filtro Kalman es porque asumo que hay incertidumbre Gaussiana en algún lado. ¿Cual es la fuente en este caso?
3. ¿Cuál es mi estado?

Ejercicio

a. ¿Cuál es un vector de estado mínimo para el filtro de Kalman (de modo que el sistema resultante sea Markoviano)?

$$\boxed{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

Me puede ayudar pensar:

1. ¿Cuál es mi acción? → Tengo manera de afectar al sistema de manera "voluntaria"
2. ¿Cuál es mi ruido? → Si voy a usar un filtro Kalman es porque asumo que hay incertidumbre Gaussiana en algún lado. ¿Cual es la fuente en este caso?
3. ¿Cuál es mi estado? → ¿A quién afecta la acción y el ruido? ¿Cómo puedo describir al sistema en el cual estoy accionando y en el cual hay ruido? ¿Es markoviano el sistema que elegí?

Ejercicio

a. ¿Cuál es un vector de estado mínimo para el filtro de Kalman (de modo que el sistema resultante sea Markoviano)?

$$\begin{bmatrix} x_t \\ \dot{x}_t \end{bmatrix}$$

Sistema

$$\ddot{x}_t$$

Ruido Gaussiano

Ejercicio

b. Para tu vector de estado, obtén la predicción del estado siguiente

Ejercicio

b. Para tu vector de estado, obtén la predicción del estado siguiente

$$\boxed{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

Ejercicio

b. Para tu vector de estado, obtén la predicción del estado siguiente

$$x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t$$

?

$$\overline{bel}(x_t) = \begin{cases} \bar{\mu}_t = A_t \mu_{t-1} + B_t u_t \\ \bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t \end{cases}$$

Ejercicio

b. Para tu vector de estado, obtén la predicción del estado siguiente

Sistemas Gaussianos Lineales: Dinámica

La dinámica son funciones **lineales** del estado y el control más ruido aditivo:

$$\boxed{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

$$\boxed{p(x_t \mid u_t, x_{t-1}) = N\left(x_t; A_t x_{t-1} + B_t u_t, Q_t\right)}$$

$$\boxed{\begin{array}{c} \overline{bel}(x_t) = \int p(x_t \mid u_t, x_{t-1})\, bel(x_{t-1}) dx_{t-1} \\ \Downarrow \qquad\qquad \Downarrow \\ \sim N\left(x_t; A_t x_{t-1} + B_t u_t, Q_t\right) \quad \sim N\left(x_{t-1}; \mu_{t-1}, \Sigma_{t-1}\right) \end{array}}$$

Sistemas Gaussianos Lineales: Dinámica

$$\overline{bel}(x_t) = \int p(x_t \mid u_t, x_{t-1}) \qquad bel(x_{t-1}) dx_{t-1}$$

$$\Downarrow \qquad\qquad \Downarrow$$

$$\sim N\left(x_t; A_t x_{t-1} + B_t u_t, Q_t\right) \sim N\left(x_{t-1}; \mu_{t-1}, \Sigma_{t-1}\right)$$

$$\Downarrow$$

$$\overline{bel}(x_t) = \eta \int \exp\left\{-\frac{1}{2}(x_t - A_t x_{t-1} - B_t u_t)^T Q_t^{-1} (x_t - A_t x_{t-1} - B_t u_t)\right\}$$

$$\exp\left\{-\frac{1}{2}(x_{t-1} - \mu_{t-1})^T \Sigma_{t-1}^{-1} (x_{t-1} - \mu_{t-1})\right\} dx_{t-1}$$

$$\overline{bel}(x_t) = \begin{cases} \bar{\mu}_t = A_t \mu_{t-1} + B_t u_t \\ \bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t \end{cases}$$

Ejercicio

b. Para tu vector de estado, obtén la predicción del estado siguiente

$$\boxed{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

Distribución Normal

Determinístico

Ejercicio

b. Para tu vector de estado, obtén la predicción del estado siguiente

$$\boxed{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

$$\boxed{\mathbb{E}[x_t] = A_t \mathbb{E}[x_{t-1}] + B_t u_t + \mathbb{E}[\epsilon_t]}$$

Ejercicio

b. Para tu vector de estado, obtén la predicción del estado siguiente

$$\boxed{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

$$\boxed{\mathbb{E}[x_t] = A_t \mathbb{E}[x_{t-1}] + B_t u_t + \cancel{\mathbb{E}[\epsilon_t]}}$$

$$\boxed{\mathbb{E}[x_t] = A_t \mathbb{E}[x_{t-1}] + B_t u_t}$$

$$\boxed{\mu_t = A_t \mu_{t-1} + B_t u_t}$$

Ejercicio

b. Para tu vector de estado, obtén la predicción del estado siguiente

$$x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t$$

$$\mu_t = A_t \mu_{t-1} + B_t u_t$$

$$Var(x_t) = Var(A_t x_{t-1} + \cancel{B u_t} + \epsilon_t)$$

$$Var(x_t) = Var(A_t x_{t-1} + \epsilon_t)$$

Ejercicio

b. Para tu vector de estado, obtén la predicción del estado siguiente

$$\boxed{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

$$\boxed{\mu_t = A_t \mu_{t-1} + B_t u_t}$$

$$\boxed{Var(x_t) = Var(A_t x_{t-1} + \epsilon_t)}$$

Hipótesis de Independencia

$$\boxed{Var(x_t) = Var(A_t x_{t-1}) + Var(\epsilon_t) + \cancel{2Cov(A_t x_{t-1}, \epsilon_t)}}$$

$$\boxed{Var(x_t) = Var(A_t x_{t-1}) + Var(\epsilon_t)}$$

Ejercicio

b. Para tu vector de estado, diseña la probabilidad de transición del estado $p(x_t \mid u_t, x_{t-1})$

$$\boxed{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

$$\boxed{\mu_t = A_t \mu_{t-1} + B_t u_t}$$

$$\boxed{Var(x_t) = Var(A_t x_{t-1}) + Var(\epsilon_t)}$$

$$\boxed{Var(x_t) = A_t Var(x_{t-1}) A_t^T + Var(\epsilon_t)}$$

$$\boxed{\Sigma_t = A_t \Sigma_{t-1} A_t^T + Q_t}$$

Ejercicio

b. Para tu vector de estado, obtén la predicción del estado siguiente

$$x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t$$

$$\mu_t = A_t \mu_{t-1} + B_t u_t$$

$$\Sigma_t = A_t \Sigma_{t-1} A_t^T + Q_t$$

$$\overline{bel}(x_t) = \begin{cases} \bar{\mu}_t = A_t \mu_{t-1} + B_t u_t \\ \bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t \end{cases}$$

Ejercicio

b. Para tu vector de estado, obtén la predicción del estado siguiente

$$\boxed{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

$$\boxed{\overline{bel}(x_t) = \begin{cases} \bar{\mu}_t = A_t \mu_{t-1} + B_t u_t \\ \bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t \end{cases}}$$

$$A = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}$$

$$\varepsilon_t = G\,\ddot{x}_t = \begin{bmatrix} \frac{1}{2}\Delta t^2 \\ \Delta t \end{bmatrix} \ddot{x}_t$$

Ejercicio

$$x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t$$

$$\varepsilon_t = G\,\ddot{x}_t = \begin{bmatrix} \frac{1}{2}\Delta t^2 \\ \Delta t \end{bmatrix} \ddot{x}_t$$

$$\overline{bel}(x_t) = \begin{cases} \bar{\mu}_t = A_t \mu_{t-1} + B_t u_t \\ \bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t \end{cases}$$

$$Q_t = Var(\epsilon_t)$$

Ejercicio

$$x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t$$

$$\varepsilon_t = G\,\ddot{x}_t = \begin{bmatrix} \frac{1}{2}\Delta t^2 \\ \Delta t \end{bmatrix} \ddot{x}_t$$

$$\overline{bel}(x_t) = \begin{cases} \bar{\mu}_t = A_t \mu_{t-1} + B_t u_t \\ \bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t \end{cases}$$

$$Q_t = Var(\epsilon_t) = Var(G\ddot{x}_t)$$

Ejercicio

$$x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t$$

$$\varepsilon_t = G\,\ddot{x}_t = \begin{bmatrix} \frac{1}{2}\Delta t^2 \\ \Delta t \end{bmatrix} \ddot{x}_t$$

$$\overline{bel}(x_t) = \begin{cases} \bar{\mu}_t = A_t \mu_{t-1} + B_t u_t \\ \bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t \end{cases}$$

$$Q_t = Var(\epsilon_t) = Var(G\ddot{x}_t) = G Var(\ddot{x}_t) G^T = G\sigma^2 G^T$$

Ejercicio

$$x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t$$

$$\varepsilon_t = G\,\ddot{x}_t = \begin{bmatrix} \frac{1}{2}\Delta t^2 \\ \Delta t \end{bmatrix} \ddot{x}_t$$

$$\overline{bel}(x_t) = \begin{cases} \bar{\mu}_t = A_t \mu_{t-1} + B_t u_t \\ \bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t \end{cases}$$

$$Q_t = G\,\sigma^2\,G^T$$

Ejercicio

b. Para tu vector de estado, obtén la predicción del estado siguiente

$$\overline{bel}(x_t) = \begin{cases} \bar{\mu}_t = A_t \mu_{t-1} + B_t u_t \\ \bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t \end{cases}$$

$$A = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}$$

$$Q_t = \sigma^2 \begin{bmatrix} \frac{1}{4}\Delta t^4 & \frac{1}{2}\Delta t^3 \\ \frac{1}{2}\Delta t^3 & \Delta t^2 \end{bmatrix}$$

Ejercicio

c. Implementa el paso de predicción del estado del filtro de Kalman. Suponiendo que se conoce en el tiempo $t = 0$, $x_0 = 0$, $\dot{x}_0 = 0$, $\ddot{x}_0 = 0$. Calcula las distribuciones de estado para los tiempos $t = 1, 2, \ldots, 5$.

Algoritmo de filtro de Kalman

1. Algoritmo **Kalman_filter**(μ_{t-1}, Σ_{t-1}, u_t, z_t):

2. Predicción:
3. $\bar{\mu}_t = A_t \mu_{t-1} + B_t u_t$
4. $\bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t$

5. Corrección:
6. $K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + R_t)^{-1}$
7. $\mu_t = \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t)$
8. $\Sigma_t = (I - K_t C_t) \bar{\Sigma}_t$
9. Return μ_t, Σ_t

Ejercicio

Ahora vamos a agregar mediciones a nuestro filtro de Kalman. Supongamos que en el tiempo t podemos recibir una observación ruidosa de x. Se espera que nuestro sensor pueda medir la posición real. Sin embargo, esta medición está corrompida por ruido gaussiano con varianza 10.

Ejercicio

Ahora vamos a agregar mediciones a nuestro filtro de Kalman. Supongamos que en el tiempo t podemos recibir una observación ruidosa de x. Se espera que nuestro sensor pueda medir la posición real. Sin embargo, esta medición está corrompida por ruido gaussiano con varianza 10.

a. Defina el modelo de mediciones.

Ejercicio

Ahora vamos a agregar mediciones a nuestro filtro de Kalman. Supongamos que en el tiempo t podemos recibir una observación ruidosa de x. Se espera que nuestro sensor pueda medir la posición real. Sin embargo, esta medición está corrompida por ruido gaussiano con varianza 10.

a. Defina el modelo de mediciones.

$$\boxed{z_t = C_t x_t + \delta_t}$$

Ejercicio

Ahora vamos a agregar mediciones a nuestro filtro de Kalman. Supongamos que en el tiempo t podemos recibir una observación ruidosa de x. Se espera que nuestro sensor pueda medir la posición real. Sin embargo, esta medición está corrompida por ruido gaussiano con varianza 10.

a. Defina el modelo de mediciones.

$$C = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$R_t = 10$$

Ejercicio

Ahora vamos a agregar mediciones a nuestro filtro de Kalman. Supongamos que en el tiempo t podemos recibir una observación ruidosa de x. Se espera que nuestro sensor pueda medir la posición real. Sin embargo, esta medición está corrompida por ruido gaussiano con varianza 10.

a. Implemente el update de mediciones. Suponga que para t = 5 se observa la medición z = 5. Calcule los parámetros Gaussianos antes y después de la medición.

Algoritmo de filtro de Kalman

1. Algoritmo **Kalman_filter**(μ_{t-1}, Σ_{t-1}, u_t, z_t):

2. Predicción:
3. $\bar{\mu}_t = A_t \mu_{t-1} + B_t u_t$
4. $\bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t$

5. Corrección:
6. $K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + R_t)^{-1}$
7. $\mu_t = \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t)$
8. $\Sigma_t = (I - K_t C_t) \bar{\Sigma}_t$
9. Return μ_t, Σ_t

Algoritmo de filtro de Kalman

$$K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + R_t)^{-1}$$
$$\mu_t = \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t)$$
$$\Sigma_t = (I - K_t C_t) \bar{\Sigma}_t$$

$$bel(x_t) = \eta \quad p(z_t \mid x_t) \qquad \overline{bel}(x_t)$$
$$\Downarrow \qquad\qquad \Downarrow$$
$$\sim N(z_t; C_t x_t, R_t) \qquad \sim N(x_t; \bar{\mu}_t, \bar{\Sigma}_t)$$
$$\Downarrow$$

$$bel(x_t) = \eta \exp\left\{-\frac{1}{2}(z_t - C_t x_t)^T R_t^{-1} (z_t - C_t x_t)\right\} \exp\left\{-\frac{1}{2}(x_t - \bar{\mu}_t)^T \bar{\Sigma}_t^{-1} (x_t - \bar{\mu}_t)\right\}$$

$$bel(x_t) = \begin{cases} \mu_t = \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t) \\ \Sigma_t = (I - K_t C_t) \bar{\Sigma}_t \end{cases} \qquad \text{with} \quad K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + R_t)^{-1}$$

EKF

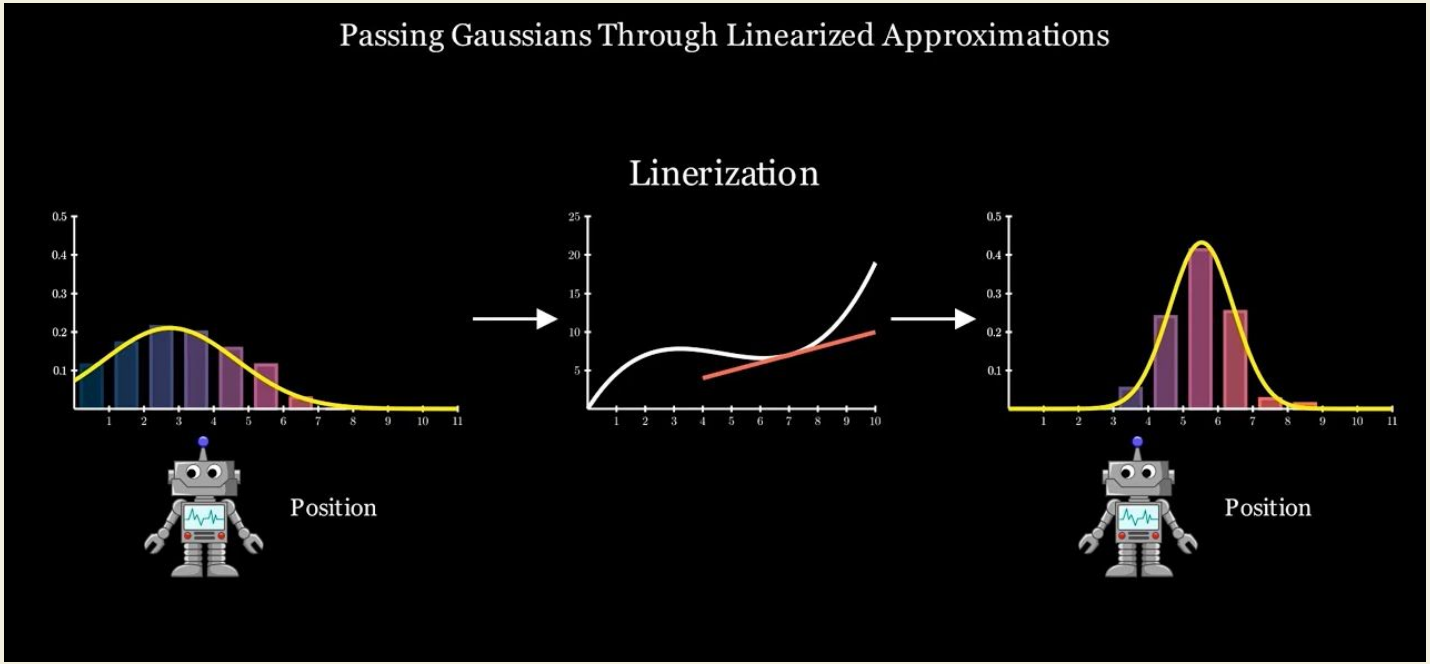
Passing Gaussians Through Linearized Approximations
Linerization
Position
Position

Sistema dinámico No-lineal

$$\cancel{x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t}$$

$$\cancel{z_t = C_t x_t + \delta_t}$$

$$x_t = g(u_t, x_{t-1})$$

$$z_t = h(x_t)$$

Linealización EKF: Expansión de Taylor de primer orden

- Predicción:

$$g(u_t, x_{t-1}) \approx g(u_t, \mu_{t-1}) + \frac{\partial g(u_t, \mu_{t-1})}{\partial x_{t-1}} (x_{t-1} - \mu_{t-1})$$

$$g(u_t, x_{t-1}) \approx g(u_t, \mu_{t-1}) + G_t \, (x_{t-1} - \mu_{t-1})$$

Matrices Jacobianas

- Corrección:

$$h(x_t) \approx h(\bar{\mu}_t) + \frac{\partial h(\bar{\mu}_t)}{\partial x_t} (x_t - \bar{\mu}_t)$$

$$h(x_t) \approx h(\bar{\mu}_t) + H_t \, (x_t - \bar{\mu}_t)$$

Algoritmo EKF

1. **Extended_Kalman_filter**(μ_{t-1}, Σ_{t-1}, u_t, z_t):

2. Predicción:
3. $\bar{\mu}_t = g(u_t, \mu_{t-1})$
4. $\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + Q_t$

5. Corrección:
6. $K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + R_t)^{-1}$
7. $\mu_t = \bar{\mu}_t + K_t (z_t - h(\bar{\mu}_t))$
8. $\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t$
9. Return μ_t, Σ_t

Ejercicio

En el EKF estamos aproximando con la linealización de g y de h. Esto solo funciona si el sistema realmente se puede linealizar y/o mis incertidumbres no me sacan de esta aproximación lineal. Veamos cómo esto se puede romper. Supongamos que tenemos un robot móvil operando en un plano 2D. Su estado es la posición x-y y su dirección tita. Supongamos que conocemos x e y con alta certeza, pero el ángulo tita es desconocido. Esto se refleja en el estado estimado inicial:

$$\mu = \begin{pmatrix} 0 & 0 & 0 \end{pmatrix}$$

$$\Sigma = \begin{pmatrix} 0.01 & 0 & 0 \\ 0 & 0.01 & 0 \\ 0 & 0 & 10000 \end{pmatrix}$$

Ejercicio

a. Haga un gráfico con 1000 samples de su posición final luego de moverse una unidad para “adelante”. Asuma que el robot se mueve perfectamente sin ruido. Las ecuaciones de movimiento son entonces:

$$\begin{pmatrix} x_{t+1} \\ y_{t+1} \\ \theta_{t+1} \end{pmatrix} = \begin{pmatrix} x + cos(\theta) \\ y + sin(\theta) \\ theta \end{pmatrix}$$

Ejercicio

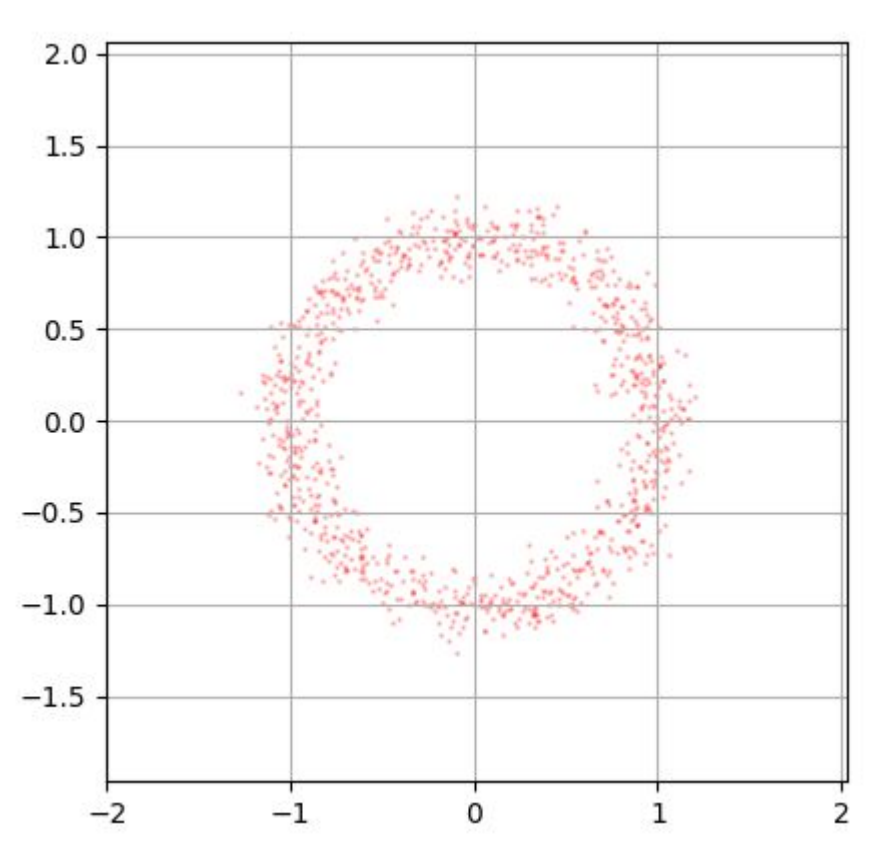

Ejercicio

b. Haga un paso de predicción con un EKF y grafique la elipse de incertidumbre

Algoritmo EKF

1. **Extended_Kalman_filter**(μ_{t-1}, Σ_{t-1}, u_t, z_t):

2. Predicción:
3. $\bar{\mu}_t = g(u_t, \mu_{t-1})$
4. $\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + Q_t$

5. Corrección:
6. $K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + R_t)^{-1}$
7. $\mu_t = \bar{\mu}_t + K_t (z_t - h(\bar{\mu}_t))$
8. $\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t$
9. Return μ_t, Σ_t

Algoritmo EKF

1. **Extended_Kalman_filter**(μ_{t-1}, Σ_{t-1}, u_t, z_t):

2. Predicción:
3. $\bar{\mu}_t = g(u_t, \mu_{t-1})$
4. $\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + Q_t$

5. Corrección:
6. $K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + R_t)^{-1}$
7. $\mu_t = \bar{\mu}_t + K_t (z_t - h(\bar{\mu}_t))$
8. $\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t$
9. Return μ_t, Σ_t

$$G_t = \begin{pmatrix} 1 & 0 & -d\,sin(\theta) \\ 0 & 1 & d\,cos(\theta) \\ 0 & 0 & 1 \end{pmatrix}$$

Ejercicio

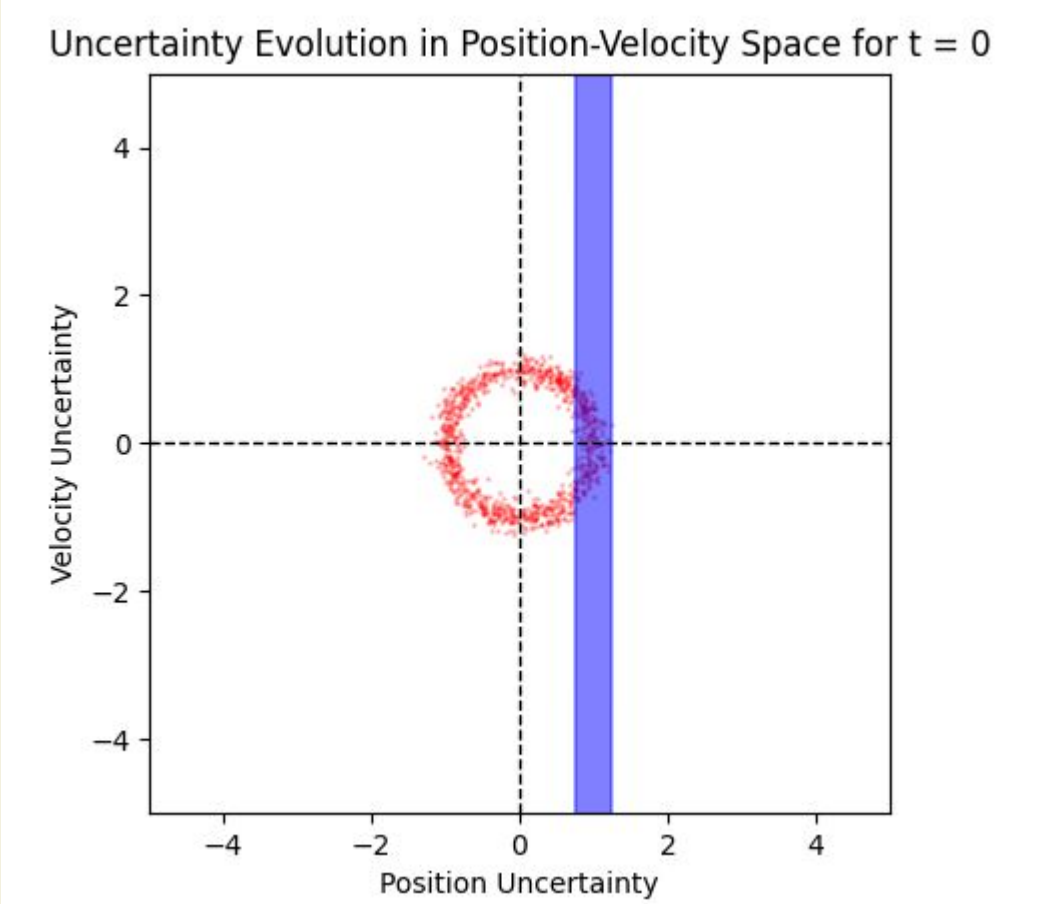
Uncertainty Evolution in Position-Velocity Space for t = 0
Velocity Uncertainty
Position Uncertainty
4
2
0
−2
−4
−4
−2
0
2
4

Ejercicio

c. Agregue una medición. La medición será una proyección ruidosa de la coordenada x del robot, con varianza 0.01. Calcule los parámetros nuevos luego de implementar la medición.

Algoritmo EKF

1. **Extended_Kalman_filter**(μ_{t-1}, Σ_{t-1}, u_t, z_t):

2. Predicción:
3. $\bar{\mu}_t = g(u_t, \mu_{t-1})$
4. $\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + Q_t$

5. Corrección:
6. $K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + R_t)^{-1}$
7. $\mu_t = \bar{\mu}_t + K_t (z_t - h(\bar{\mu}_t))$
8. $\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t$
9. Return μ_t, Σ_t

Algoritmo EKF

1. **Extended_Kalman_filter**(μ_{t-1}, Σ_{t-1}, u_t, z_t):

2. Predicción:
3. $\bar{\mu}_t = g(u_t, \mu_{t-1})$
4. $\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + Q_t$

5. Corrección:
6. $K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + R_t)^{-1}$
7. $\mu_t = \bar{\mu}_t + K_t (z_t - h(\bar{\mu}_t))$
8. $\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t$
9. Return μ_t, Σ_t

$$Ht = \begin{pmatrix} 1 & 0 & 0 \end{pmatrix}$$

$$R_t = 0.01$$

Ejercicio

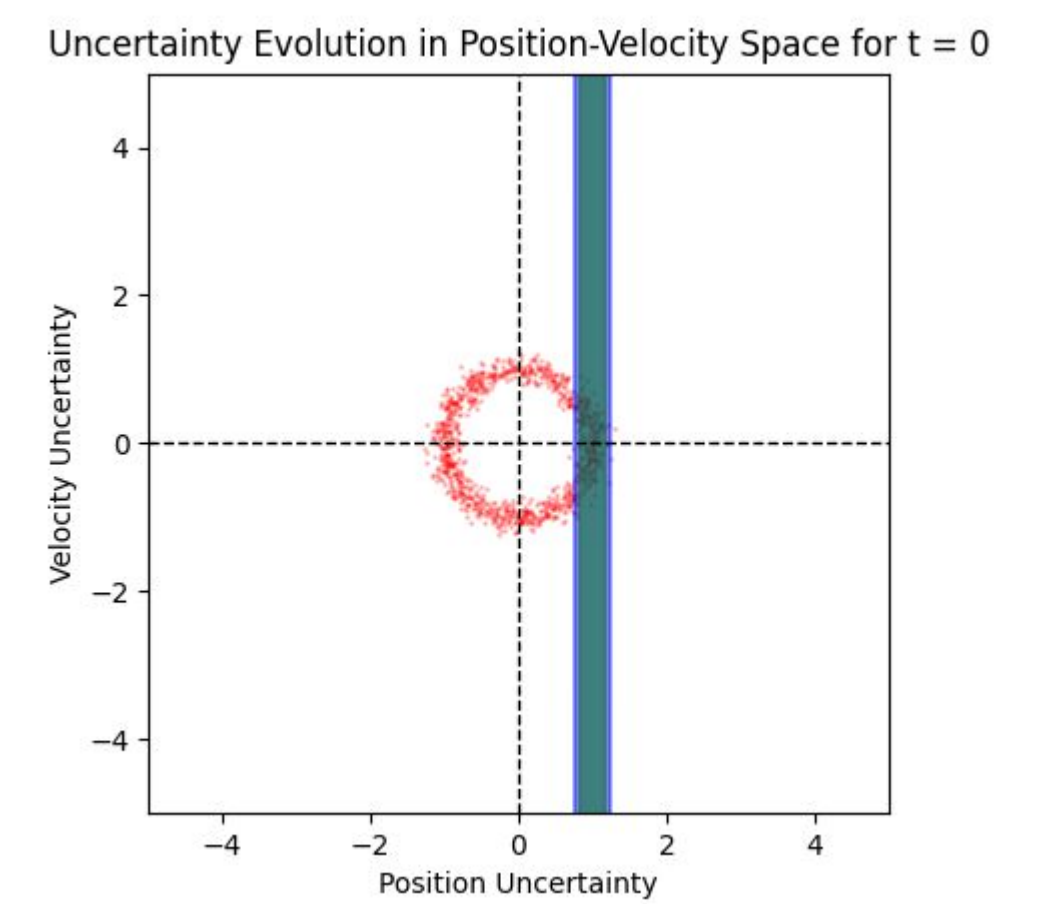
Uncertainty Evolution in Position-Velocity Space for t = 0
Velocity Uncertainty
Position Uncertainty
4
2
0
−2
−4
−4
−2
0
2
4

Ejercicio

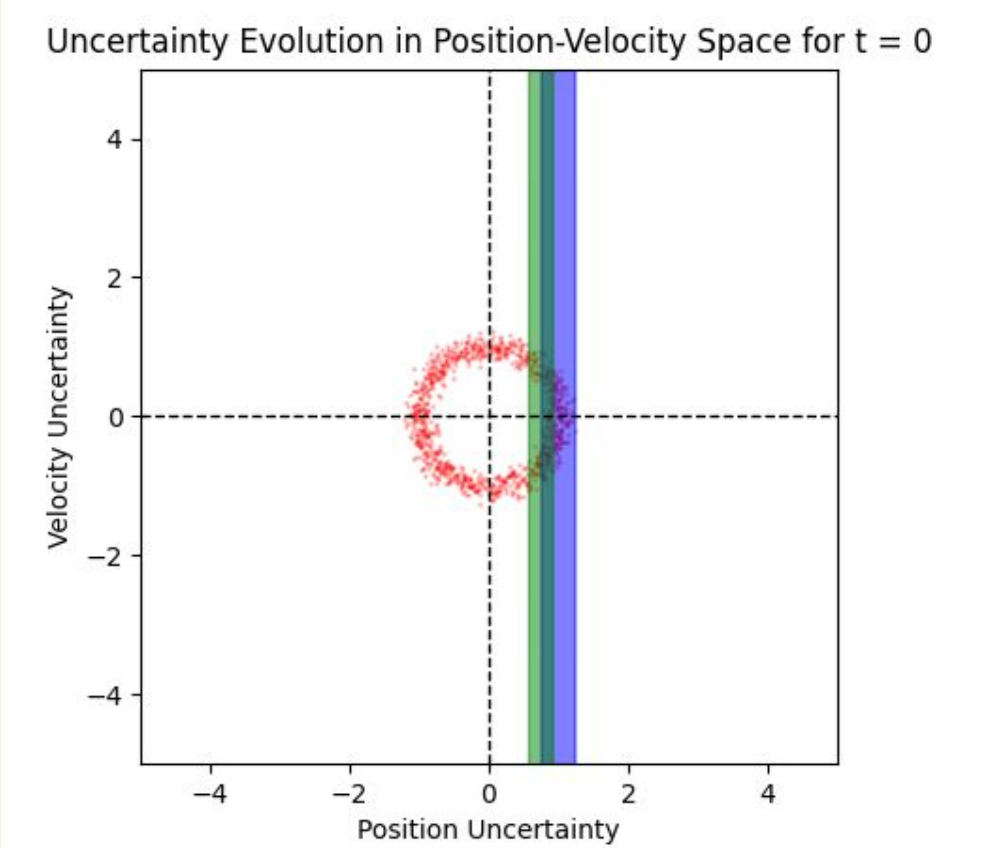
Uncertainty Evolution in Position-Velocity Space for t = 0
Velocity Uncertainty
Position Uncertainty
4
2
0
−2
−4
−4
−2
0
2
4

UKF

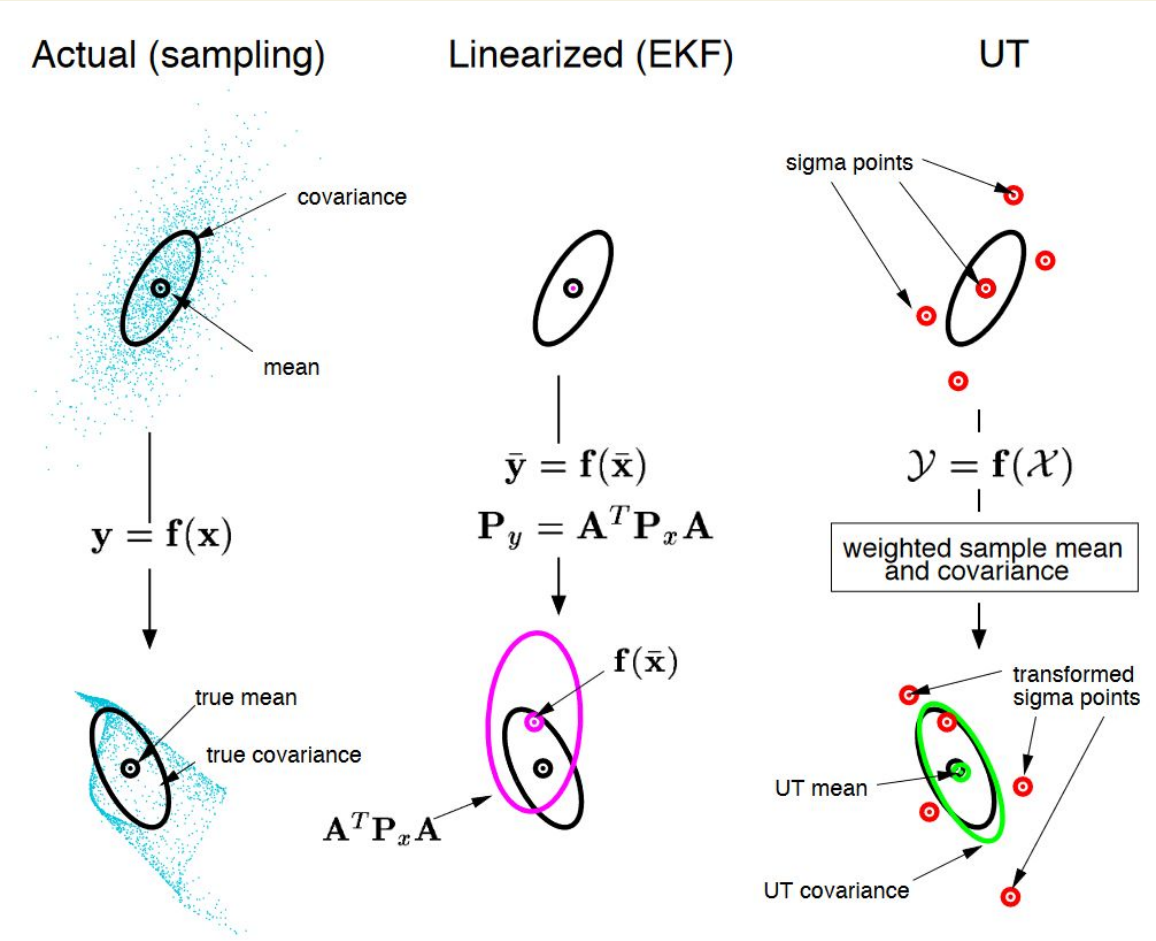
Actual (sampling)
Linearized (EKF)
UT
covariance
mean
$\mathbf{y} = \mathbf{f}(\mathbf{x})$
true mean
true covariance
$\bar{\mathbf{y}} = \mathbf{f}(\bar{\mathbf{x}})$
$\mathbf{P}_y = \mathbf{A}^T\mathbf{P}_x\mathbf{A}$
$\mathbf{f}(\bar{\mathbf{x}})$
$\mathbf{A}^T\mathbf{P}_x\mathbf{A}$
sigma points
$\mathcal{Y} = \mathbf{f}(\mathcal{X})$
weighted sample mean and covariance
transformed sigma points
UT mean
UT covariance

EKF vs UKF

Caso	EKF	UKF
Sistemas ligeramente no-lineales	Bueno	Bueno
Sistemas fuertemente no-lineales	Dificultad de aplicación	Mejor performance que EKF
Sistemas ruidosos, de muchas dimensiones o complejos	Menos confiable	Más robusto
Cantidad de cómputo	Eficiente	Puede ser más pesado

TP4

Extended_Kalman_filter($\mu_{t-1}, \Sigma_{t-1}, u_t, z_t$):

Predicción:

$$\bar{\mu}_t = g(u_t, \mu_{t-1})$$
$$\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + Q_t$$

Corrección:

$$K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + R_t)^{-1}$$
$$\mu_t = \bar{\mu}_t + K_t (z_t - h(\bar{\mu}_t))$$
$$\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t$$

Return μ_t, Σ_t

Opción 1 (Odometría Rápida):

1. Guardo datos de odometria de manera cumulativa (ie: voy sumando cuánto se movió)
2. Cuando llega el dato de medición hago la predicción con el movimiento total y la corrección en un mismo ciclo

Opción 2 (Paralelo):

1. Cuando llega data de odometría ejecuto predicción. Publico el belief nuevo para que todos la vean
2. Cuando llega el dato de medición hago corrección y publico el belief nuevo para que todos lo vean

Hay que tener cuidado con race conditions. Se recomienta trabajar siempre sobre una copia del belief para evitar cambios durante procesamiento